



پیامبر اسلام صلی الله علیه و آله

لاتسرف فی الماء و لو كنت علی نهر جار

آب را هدر نده هر چند کنار رودی پر آب باشی.

مشکات المصابیح، ج ۲، ص ۲۵۵



دانشکده مهندسی صنایع

نیم سال دوم ۱۴۰۴-۱۴۰۵

**چارچوب یادگیری تقویتی عمیق برای مدیریت فشار در شبکه‌های توزیع آب با استفاده
از شیرهای فشارشکن (PRV) و بهینه‌سازی خط‌مشی پروگزیمال (ppo) یکپارچه‌شده
با EPANET**

استاد راهنما:

جناب آقای دکتر صاحبی

دانشجو:

محمد یوسف زاده

شماره دانشجویی:

۴۰۲۶۷۹۹۱۷

چکیده

افزایش بحران کم‌آبی، رشد تقاضای مصرف و فرسودگی زیرساخت‌های آبرسانی، مدیریت شبکه‌های توزیع آب شهری را به یکی از چالش‌های اساسی مدیریت منابع آب تبدیل کرده است. یکی از مهم‌ترین عوامل مؤثر بر تلفات واقعی آب و آب بدون درآمد، فشار هیدرولیکی در شبکه‌های توزیع است که به‌طور مستقیم بر میزان نشت، شکستگی لوله‌ها، خرابی تجهیزات و کاهش عمر مفید تأسیسات تأثیر می‌گذارد. روش‌های سنتی کنترل فشار، عمدتاً مبتنی بر تنظیم ثابت شیرهای فشارشکن بوده و به دلیل تغییرات زمانی مصرف، قادر به تأمین هم‌زمان فشار بهینه و کاهش نشت در شرایط مختلف بهره‌برداری نیستند. در این پژوهش، یک چارچوب هوشمند برای مدیریت فشار در شبکه‌های توزیع آب با استفاده از یادگیری تقویتی عمیق ارائه می‌شود. این چارچوب با بهره‌گیری از الگوریتم **Proximal Policy Optimization (PPO)** و یکپارچه‌سازی آن با مدل هیدرولیکی شبکه در محیط **EPANET**، امکان کنترل تطبیقی شیرهای فشارشکن (**PRV**) را در شرایط متغیر مصرف فراهم می‌سازد. هدف اصلی این رویکرد، کاهش تلفات واقعی آب، حداقل‌سازی آب بدون درآمد، حفظ فشار سرویس در محدوده استاندارد، کاهش تنش‌های هیدرولیکی شبکه و افزایش پایداری بهره‌برداری است. نتایج نشان می‌دهد که استفاده از کنترل هوشمند مبتنی بر یادگیری تقویتی می‌تواند به‌عنوان یک راهکار کارآمد، انعطاف‌پذیر و قابل توسعه برای مدیریت فشار فعال در شبکه‌های توزیع آب شهری مطرح شده و نقش مؤثری در بهبود عملکرد فنی، اقتصادی و زیست‌محیطی سیستم‌های آبرسانی ایفا کند.

کلیدواژه‌ها:

مدیریت فشار، شبکه توزیع آب (**WDN**)، آب بدون درآمد، نشت آب، یادگیری تقویتی عمیق (**DRL**)، **PPO**، **EPANET**، شیر فشارشکن (**PRV**)، کنترل هوشمند، مدیریت فعال فشار

فهرست مطالب

مقدمه.....	۱
مبانی و تعاریف.....	۴
تعریف نشت.....	۴
تعریف آب به حساب نیامده و آب بدون درآمد.....	۴
نشت و کنترل نشت.....	۸
بررسی مهم‌ترین عوامل مؤثر در نشت و تلفات آب شهری.....	۱۱
چارچوب استراتژیک برای کاهش تلفات آب.....	۱۲
نقش محوری مدیریت فعال فشار.....	۱۴
روش‌های اصلی برای کنترل فشار.....	۱۵
نمونه ای عملی از کنترل فشار.....	۱۵
قوانین هیدرولیکی مدل‌سازی شبکه‌های توزیع آب.....	۱۶
سامانه های آب شهری.....	۱۶
شبکه های توزیع آب.....	۱۷
اجزای کنترل کننده جریان شبکه های توزیع آب.....	۱۷
پمپ ها.....	۱۷
مخازن.....	۱۷
شیرآلات و انواع آن.....	۱۸
معرفی شیرهای فشارشکن.....	۱۹
استراتژی‌های کنترل شیر کاهش فشار (PRV).....	۲۱
تعاریف و مبانی ضروری یادگیری تقویتی عمیق.....	۲۱
مبانی یادگیری تقویتی.....	۲۲
عناصر کلیدی یادگیری تقویتی.....	۲۳

عامل (Agent)	۲۳
محیط (Environment)	۲۳
حالت و کنش (State and Action)	۲۳
پاداش (Reward)	۲۳
الگوریتم یادگیری تقویتی (RL Algorithm)	۲۴
تفاوت یادگیری تقویتی (RL) با سایر پارادایم‌های یادگیری ماشین (ML)	۲۴
مفاهیم پایه یادگیری تقویتی	۲۶
فضای عمل	۲۶
سیاست (Policy)	۲۶
سیاست قطعی (Deterministic Policy)	۲۷
سیاست تصادفی (Stochastic Policy)	۲۷
سیاست دسته‌ای (Categorical Policy)	۲۸
سیاست گاوسی (Gaussian Policy)	۲۸
اپیزود (Episode)	۲۹
کارهای اپیزودی و پیوسته (Episodic and Continuous Tasks)	۲۹
افق (Horizon)	۳۰
بازده (Return) و عامل تنزیل (Discount Factor)	۳۰
تابع ارزش (Value Function)	۳۲
تابع Q (Q Function)	۳۲
یادگیری مبتنی بر مدل و بدون مدل (Model-based and Model-free Learning)	۳۳
یادگیری مبتنی بر مدل (Model-based Learning)	۳۳
یادگیری بدون مدل (Model-free Learning)	۳۳
انواع مختلف محیط‌ها (Different Types of Environments)	۳۳

۳۴	محیط قطعی (Deterministic Environment)
۳۴	محیط تصادفی (Stochastic Environment)
۳۴	محیط گسسته (Discrete Environment)
۳۴	محیط پیوسته (Continuous Environment)
۳۴	محیط اپیزودی (Episodic Environment)
۳۴	محیط غیر اپیزودی (Non-episodic Environment)
۳۷	مفاهیم پایه ای یادگیری عمیق
۳۷	نورون‌های بیولوژیکی و مصنوعی
۳۸	شبکه‌های عصبی مصنوعی (ANNs) و لایه‌ها
۳۹	شبکه‌های عصبی بازگشتی (RNNs) و LSTM
۴۰	شبکه‌های عصبی کانولوشنی (CNNs)
۴۱	شبکه‌های مولد تقابلی (GANs)
۴۱	نتیجه‌گیری
۴۲	مزیت روش‌های مبتنی بر سیاست (policy-based)
۴۳	روش actor critic
۴۴	بهینه‌سازی سیاست با ناحیه اعتماد (Trust Region Policy Optimization – TRPO)
۴۵	بهینه‌سازی سیاست نزدیک (Proximal Policy Optimization – PPO)
۴۷	معرفی epanet
۵۰	متدولوژی مرور ادبیات
۵۳	مرور ادبیات
۵۳	پیشینه پژوهشی کنترل فشار
۵۶	ارزیابی کاستی‌های روش‌های سنتی بهینه‌سازی
۵۶	رویکردهای بهینه‌سازی سنتی و متاهیوریستیک

۵۷	برنامه‌ریزی پویا (DP)
۵۷	روش‌های متاهیوریستیک و هیپرهیوریستیک
۵۸	استراتژی‌های کاهش بار محاسباتی
۵۸	مدل‌های جایگزین و هیبریدی
۵۸	چارچوب‌های کنترل پیشرفته
۵۹	یادگیری ماشین و بهینه‌سازی WDS ها
۵۹	یادگیری تقویتی عمیق (DRL) برای کنترل بلادرنج
۶۰	پیشینه ادبیاتی کنترل نشت
۶۲	مدیریت نشتی در شبکه‌های توزیع آب
۶۴	روش‌های ارزیابی نشتی
۶۵	روش‌های تشخیص نشتی
۶۵	روش‌های تشخیص نشتی مبتنی بر سخت‌افزار
۶۷	روش‌های تشخیص نشتی مبتنی بر نرم‌افزار
۷۰	روش‌های پیشگیری از نشتی (کنترل)
۷۲	معیارهای ارزیابی و عملکرد روش‌های مدیریت نشتی
۷۴	مطالعات موردی DRL در سیستم‌های آب شهری
۷۵	کاربردهای DRL در بخش آب
۷۵	DRL در سیستم‌های آب طوفانی
۷۶	DRL در شبکه‌های توزیع آب
۷۸	DRL در سیستم‌های کیفیت آب
۷۹	چالش‌های DRL در شبکه‌های توزیع آب (WDN)
۸۱	ملاحظات استراتژیک برای پذیرش DRL
۸۲	دسته‌بندی پیشنهادی مقالات

۸۴ بررسی شکاف های تحقیقاتی

۸۶ منابع

مقدمه


آب را می‌توان به‌عنوان حیاتی‌ترین کالای عصر حاضر در نظر گرفت، که ارزش آن روزبه‌روز در جوامع مختلف بشری بیشتر محسوس و اهمیت آن فزاینده می‌شود. با توجه به رشد سریع صنعتی و توسعه زیرساخت‌ها، ضروری است که مدیریت ساختارهای زیربنایی به‌صورت بهینه و کامل انجام شود. از جمله این ساختارها، شبکه‌های آب و فاضلاب هستند. با اهمیت این ماده حیاتی، فرآیندهای استحصال، انتقال و توزیع آب باید با مدیریت صحیح و بهره‌گیری از فناوری‌های نوین انجام گیرد. با گذر زمان و افزایش روزافزون بحران‌های ناشی از کمبود آب، نیاز به مدیریت منابع آبی، هوشمندسازی تجهیزات و پایش مستمر آن‌ها در حوضه‌های آب و فاضلاب، بیش از پیش احساس می‌شود.

فشار آب یکی از مهم‌ترین عوامل مؤثر در میزان آب بدون درآمد در شبکه‌های توزیع آب شهری است و بیشترین و سریع‌ترین اثر هیدرولیکی را بر مقدار نشت دارد (سلطانی و مغربی، ۱۳۸۸). بنابراین، فشار در شبکه‌های آبرسانی باید به‌صورت مستمر پایش شود و در محدوده مطلوب نگه داشته شود؛ زیرا افزایش فشار موجب هدررفت آب و شکست لوله و کاهش بیش از حد آن باعث عدم تأمین نیاز مصرف‌کنندگان می‌شود. همواره بخشی از آب تولید شده در مسیر تولید تا مصرف، به‌صورت آب به‌حساب‌نیامده هدر می‌رود. آب به‌حساب‌نیامده به آبی گفته می‌شود که قبل از رسیدن به مصرف‌کننده نشت کرده و اندازه‌گیری نمی‌شود؛ این مسأله علاوه بر محدودیت منابع آبی کشور، هزینه‌های قابل‌توجهی برای شرکت‌های آب و فاضلاب به همراه دارد. از این رو، با توجه به اهمیت روزافزون بحران آب، اتخاذ تدابیری برای جلوگیری از هدررفت آب ضروری است.

مطالعات نشان داده‌اند که میزان نشت در شبکه‌ها بین ۵ تا ۵۰ درصد کل آب تولیدی گزارش شده است. بر اساس بررسی‌های انجام‌شده در سطح کشور طی ده سال گذشته، متوسط نشت در ایران بین ۱۵ تا ۳۰ درصد بوده است (تابش و واسطی، ۱۳۸۵). نشت در شبکه‌های آبرسانی تابع عواملی از جمله فشار آب، قدمت لوله‌ها، کیفیت آب و خاک، کیفیت اجرا، کیفیت لوله‌ها و متعلقات، ضربه و بارهای جانبی مانند ترافیک است. راهکارهای کاهش نشت شامل یافتن مستقیم محل نشت و ترمیم آن، تعویض خطوط آسیب‌دیده و مدیریت فشار (PM) است که مورد اخیر، کاراترین و مقرون‌به‌صرفه‌ترین روش به شمار می‌رود (تابش و واسطی، ۱۳۸۵).

وجود نشت در شبکه‌های توزیع آب شهری اجتناب‌ناپذیر است و کاهش آن با مدیریت پارامترهای هیدرولیکی مانند فشار در کنار پروژه‌های نشت‌یابی، اهمیت ویژه‌ای دارد. کنترل هوشمند فشار، روشی مؤثر برای کاهش نشت و کاهش صدمات ناشی از فشارهای زیاد در شبکه است (سلطانی و مغربی، ۱۳۸۸). مدیریت فشار علاوه بر کنترل نشت، مزایای دیگری مانند کاهش متوسط مصرف انرژی، کاهش هزینه‌های تعمیر و نگهداری شبکه و تأسیسات،

افزایش عمر مفید تأسیسات، افزایش رضایت مشترکین و کاهش هزینه‌های نیروی انسانی دارد. هدف اصلی از کنترل هوشمند فشار، به حداقل رساندن فشار شبکه به میزانی است که در زمان حداقل مصرف، فشار نیز به حداقل برسد.



با توجه به مزایای فراوان مدیریت هوشمند فشار و اهمیت حیاتی آب، بهره‌برداری از این فناوری در شبکه‌های توزیع آب ضروری است. کنترل هوشمند فشار، تکنیکی پیشرفته برای کنترل نشت، کاهش مصرف، کاهش تلفات و کاهش تعداد شکستگی‌ها و خرابی لوله‌هاست. فشار در سیستم‌های توزیع آب (WDS) یکی از دغدغه‌های اصلی تأسیسات آب محسوب می‌شود. این فرآیند می‌تواند مزایای قابل توجهی برای دو بخش اصلی توزیع آب، یعنی شرکت‌های آب و کاربران نهایی، فراهم کند. تنظیم کارآمد فشار در طول روز، فشار کافی را برای ارائه خدمات ثابت و مناسب به مشتریان فراهم می‌کند و همزمان، فشار را تا حدی کاهش می‌دهد که از نشت لوله یا شکست آن جلوگیری شود. در این زمینه، اصطلاح **PM** برای اشاره به این نوع فعالیت‌ها به کار می‌رود. **PM** ممکن است شامل فعالیت‌های مختلفی مانند کنترل پمپ، تنظیم مخزن، احداث حوضچه‌های تعدیل فشار، اجرای طرح ناحیه‌بندی فشار (زون فشار) و کاهش فشار با استفاده از دریچه‌های اتوماتیک باشد.

استفاده از شیرهای کاهش فشار (PRV) روشی گسترده و پرکاربرد است که توسط شرکت‌ها به کار گرفته می‌شود (ویسنه و همکاران، ۲۰۱۶). این شیرها هزینه تولید کمی دارند، نصب و بهره‌برداری آن‌ها آسان است، نشتی خارجی را کاهش می‌دهند و نگهداری آن‌ها ساده است. با این حال، محیط کنترلی باید کاملاً تمیز باشد و رگلاتورها ممکن است در شرایط افت فشار، کنترل دقیق را از دست دهند.

سیستم‌های سنتی کنترل فشار عمدتاً بر شیرهای فشارشکن با خروجی فشار ثابت متکی هستند. از آنجا که فشار در شبکه‌های توزیع تابع مصرف مشترکان است و مصرف نیز تابعی از ساعات شبانه‌روز می‌باشد، خروجی شیرها

معمولاً برای تأمین فشار در ساعات اوج مصرف تنظیم می‌شود. در نتیجه، در نیمه شب فشار غیرضروری به شبکه تحمیل می‌شود که موجب افزایش نشت، خرابی و شکست لوله‌ها می‌گردد. دامنه نوسانات فشار بین سطح حداقل و حداکثر، باعث خستگی شبکه و افزایش احتمال شکست آن می‌شود. به همین دلیل، مدیریت هوشمند فشار با استفاده از شیرهای فشارشکن با خروجی متغیر در طول شبانه‌روز، راهکاری مناسب برای رسیدن به اهداف ذکر شده است.

در مسائل طراحی و مهندسی، شرایطی وجود دارد که پاسخ آن‌ها به‌سادگی و با روش‌های معمول و متعارف قابل محاسبه نیست، زیرا مسأله پیچیده است و متغیرهای فراوانی بر آن تأثیر گذارند.

مبانی و تعاریف

تعریف نشت

امروزه بسیاری از شهرهای کشور، خصوصاً مناطقی که دسترسی محدودی به منابع آب دارند، با کمبود آب شرب روبه‌رو هستند. در تعداد قابل توجهی از این شهرها، برنامه‌های زمان‌بندی‌شده برای قطع آب شرب اجرا می‌شود. یکی از عوامل اصلی کمبود آب شرب، وقوع حوادث و میزان بالای تلفات آب در شبکه‌های توزیع شهری است. عواملی همچون فرسودگی شبکه توزیع و وجود انشعاب‌های غیرمجاز در این مسئله نقش مؤثری دارند. ترکیب کمبود منابع آب، درصد بالای تلفات و هزینه‌های سنگین تأمین آب از دست‌رفته، ضرورت استفاده از روش‌های کارآمد برای کنترل و کاهش تلفات آب در شبکه‌های توزیع شهری را آشکار می‌سازد. یکی از اقدامات مهم در این زمینه، پیشگیری از تلفات آب در شبکه‌های توزیع آب شهری است.

تعریف آب به حساب نیامده و آب بدون درآمد

تأمین پایدار آب برای نسل‌های کنونی و آینده نیازمند بهبود نظام‌های مدیریت آب است. یکی از مهم‌ترین راهکارها، کاهش «آب به حساب نیامده» است؛ یعنی بخشی از آب تولیدشده که قبل از رسیدن به مصرف‌کننده از دست می‌رود یا ثبت نمی‌شود. این مسئله در بسیاری از کشورها، به‌ویژه کشورهای درحال توسعه، یک چالش جدی است و می‌تواند باعث کاهش کارایی شبکه، افزایش هزینه‌ها، تشدید کمبود آب و آسیب به پایداری مالی صنعت آب شود.

کل آب ورودی به سیستم توزیع شرب	توضیحات			وضعیت
	تعریف	مصارف مجاز	حجم آبی که توسط مشترکین مجاز ثبت شده (در کاربری های مختلف خانگی، تجاری و غیره) مصرف می شود.	
			مصارف مجاز اندازه گیری شده/اندازه گیری نشده با درآمد(شامل کلیه مصارفی که آب بهای آن به شرکت آب و فاضلاب پرداخت می شود).	با درآمد
	انواع و مصادیق		مصارف مجاز اندازه گیری شده/اندازه گیری نشده بدون درآمد (مانند مصارف اقشار کم درآمد، آتش نشانی و برخی خدمات عمومی شهری)	بدون درآمد

	تلفات ظاهری: به اختلاف بین حجم کل آب ورودی به سیستم توزیع آب شرب و حجم آب ثبت شده در کنتورها گفته می شود و تحت تأثیر عوامل زیر رخ می دهد: - خطای ثبت و اندازه گیری کنتورها، به صورت ثبت مقدار مصرف کمتر از حد مجاز به دلیل فرسودگی یا کالیبراسیون نامناسب. - خطاهای مدیریتی و انسانی، شامل نقص در سیستم پایش و صورت حساب دهی، اشتباهات در خواندن یا دستکاری کنتورها. - مصرف غیرمجاز آب، شامل سرقت آب از طریق اتصالات غیرقانونی یا دور زدن کنتورها.		تلفات (ظاهری و واقعی)	
	تلفات واقعی: به میزان حجم آبی گفته می شود که به دلیل بروز نواقص در زیرساخت شبکه توزیع آب شرب مستقیماً از دسترس خارج می شود و تحت تأثیر عوامل زیر است: - نشت مرئی و نامرئی (گزارش شده و گزارش نشده) در خطوط لوله انتقال به دلیل آسیب و شکستگی، ناشی از ضربه های فیزیکی یا فشار بیش از حد. - نشت از مخازن ذخیره، انشعابات، شیرآلات و اتصالات شبکه توزیع به دلیل فرسودگی زیرساخت ها. - جنس نامناسب و ایجاد خوردگی در لوله ها، به ویژه لوله های چدنی. - مدیریت فشار نامناسب و وجود فشار بالا در خطوط توزیع، همراه با نوسانات دمایی، زمین لرزه، ناپایداری و حرکت خاک که باعث افزایش فشار بر لوله ها و تشدید نشت می شود.			

در کشورهای توسعه یافته، میزان آب به حساب نیامده حدود ۱۵ درصد است، اما در کشورهای در حال توسعه به دلیل مشکلات زیرساختی، محدودیت مالی و کمبود فناوری، این میزان بین ۲۰ تا ۷۰ درصد گزارش می شود.

تلفات آب به حساب نیامده شامل سه بخش است:

۱. **تلفات واقعی:** مانند نشت و ترکیدگی لوله ها.

۲. **تلفات ظاهری:** مانند مصرف غیرمجاز و خطاهای اندازه گیری.

۳. **مصرف مجاز بدون صورت حساب.**

آب بدون درآمد زیرمجموعه ای از آب به حساب نیامده است که شامل تلفات واقعی و ظاهری می شود و قابلیت کنترل و کاهش دارد. کاهش آب به حساب نیامده موجب افزایش بهره وری، کاهش هزینه های عملیاتی و بهبود دسترسی به آب در مناطق مختلف می شود.

در کشورهای در حال توسعه، بخش عمده آب به حساب نیامده ناشی از تلفات واقعی مانند نشت و ترکیدگی است، در حالی که در کشورهای توسعه یافته، سهم بیشتری به تلفات ظاهری مانند خطاهای اندازه گیری و مصرف غیرمجاز مربوط می شود.

در برخی کشورها، میزان آب به حساب نیامده به بیش از ۵۰ درصد آب ورودی شبکه می رسد که موجب زیان مالی شدید و کاهش کارایی شرکت های آب و فاضلاب می شود؛ نمونه بارز آن، کامرون با حدود ۵۰.۸ درصد تلفات است.

آمار جهانی از حجم آب بدون درآمد در جدول ذیل آمده است (لیمبرگر و وایات، ۲۰۱۸):

منطقه	حجم آب بدون درآمد (میلیون م ^۳ /روز)	حجم آب بدون درآمد (میلیارد م ^۳ /سال)	میانگین سطح آب بدون درآمد (لیتر/نفر/روز)	هزینه/ارزش آب بدون درآمد (میلیارد دلار آمریکا/سال)
آفریقای زیر صحرای	۱۴.۱	۵.۲	۶۴	۱.۴
استرالیا و نیوزیلند	۱.۰	۰.۳	۳۶	۰.۱
قفقاز و آسیای مرکزی	۸.۰	۲.۹	۱۵۲	۰.۸
آسیای شرقی	۵۳.۰	۱۹.۳	۴۲	۶.۲
اروپا	۲۶.۸	۹.۸	۵۰	۳.۴
آمریکای لاتین و کارائیب	۶۹.۱	۲۵.۲	۱۲۱	۸.۰
خاورمیانه و شمال آفریقا	۴۱.۲	۱۵.۰	۹۶	۴.۸
جزایر اقیانوس آرام	۰.۵	۰.۲	۲۱۱	۰.۱
روسیه، اوکراین، بلاروس	۹.۵	۳.۵	۶۵	۱.۱
آسیای جنوبی	۶۳.۴	۲۳.۲	۹۳	۶.۰
آسیای جنوب شرقی	۱۸.۴	۶.۷	۸۱	۲.۰
آمریکا و کانادا	۴۰.۷	۱۴.۸	۱۱۹	۵.۷
مجموع	۳۴۶	۱۲۶	۷۷	۳۹

در ایران نیز وضعیت مشابهی وجود دارد و علی‌رغم وجود قوانین و ساختارهای مسئول، نبود برنامه‌ریزی مؤثر، ضعف زیرساخت‌ها، کمبود فناوری‌های نو و محدودیت مالی، کنترل آب به حساب‌نیامده را دشوار کرده است. چالش‌های اصلی شامل ناشناخته بودن اجزای تشکیل‌دهنده تلفات، پیچیدگی شناسایی نقاط بحرانی شبکه، قدیمی بودن تجهیزات اندازه‌گیری، مصرف غیرمجاز و ضعف سیستم پایش است.

بر اساس چارچوب‌های بین‌المللی مانند IWA و اهداف توسعه پایدار، به‌ویژه SDG ۶، مدیریت مؤثر آب به حساب‌نیامده باید بر تشخیص نشت فعال، ارتقای زیرساخت، بهبود سامانه‌های اندازه‌گیری و سیاست‌گذاری کارآمد متمرکز باشد. در ایران نیز قوانین بالادستی مانند برنامه پنج‌ساله هفتم و سیاست‌های کلی نظام به اصلاح الگوی مصرف و بهبود مدیریت آب تأکید دارند، اما اجرای عملی این سیاست‌ها نیازمند تقویت ساختارهای اداری، فناوری و مالی است.

کاهش آب به حساب‌نیامده علاوه بر بهبود بهره‌وری و کاهش هزینه‌های عملیاتی، نقش مهمی در پایداری اقتصادی، زیست‌محیطی و اجتماعی دارد. تلفات کمتر به معنای مصرف انرژی کمتر، حفظ منابع محدود آب، افزایش ظرفیت مالی برای نگهداری و توسعه شبکه و تقویت امنیت آبی کشور است.


شبکه‌های توزیع آب شهری از مهم‌ترین زیرساخت‌های هر شهر به شمار می‌روند (سلگی و همکاران، ۱۳۹۶). بر اساس آخرین آمار، میزان تولید و فروش آب شرب شهری در کشور به ترتیب ۶.۲ و ۴.۶ میلیارد مترمکعب در سال است. همچنین تولید و فروش آب شرب روستایی به ترتیب برابر با ۱.۴۴ و ۰.۹۸ میلیارد مترمکعب در سال گزارش شده است. بر این اساس، میزان آب به حساب‌نیامده در بخش شهری و روستایی به ترتیب ۲۶ و ۳۲ درصد برآورد می‌شود. این مقادیر نشان‌دهنده سهم قابل توجه آب به حساب‌نیامده در سطح کشور هستند که ناشی از هدررفت‌های واقعی و ظاهری می‌باشند. با توجه به اختلاف قابل توجه میان هزینه تمام‌شده و قیمت فروش آب شرب، شرکت‌های آب و فاضلاب معمولاً با زیان اقتصادی مواجه هستند (مرکز پژوهش‌های مجلس، ۱۳۹۸).

از سوی دیگر، یکی از مهم‌ترین و پرهزینه‌ترین واحدهای شرکت‌های آب و فاضلاب شهری، واحد مدیریت حوادث است. نبود یک فرآیند مکانیزه، دقیق و قابل اعتماد در مدیریت این سیستم، سالانه خسارات چشمگیری به مشترکان و شرکت‌های آب و فاضلاب وارد می‌کند. این مسئله به‌ویژه در شرایط کنونی، با در نظر گرفتن بحران کمبود آب و درصد بالای تلفات آب در شبکه‌های توزیع شهری، اهمیت تحقیقات کاربردی در این حوزه را دوچندان می‌سازد (تابش و همکاران، ۱۳۸۸).

بنابراین، کاهش تلفات در شبکه‌های توزیع آب شهری یکی از رویکردهای اساسی شرکت‌های آب و فاضلاب برای عبور از بحران کم‌آبی، تخصیص بهینه منابع و افزایش درآمد حاصل از فروش آب محسوب می‌شود (جمشیدی، ۱۳۹۳).

نشت و کنترل نشت

نشت یا تلفات آب، به‌عنوان یکی از عناصر اصلی هدررفت واقعی آب، جزء جدایی‌ناپذیر شبکه‌های توزیع آب شهری محسوب می‌شود (شکل ۱). حتی کارآمدترین شبکه‌های توزیع آب نیز همواره با میزان مشخصی از نشت در زیرساخت خود مواجه هستند. برای کاهش نشت و بهبود عملکرد شبکه‌های توزیع، رویکردها و روش‌های گوناگونی ارائه شده است (یوسفی خوش‌قلب و همکاران، ۱۴۰۰).



مقوله نشت در شبکه‌های توزیع آب شهری مسئله‌ای دیرینه و ریشه‌دار در تمام کشورهاست. می‌توان گفت از زمان شکل‌گیری و توسعه شبکه‌های آبرسانی، موضوع نشت نیز به‌طور همزمان ظاهر شده است. با توجه به شرایط بحرانی کشور و کاهش شدید منابع آب شیرین، کنترل تلفات آب در تمامی بخش‌ها اهمیت ویژه‌ای دارد. شبکه‌های

توزیع آب شهری نیز سالانه سهم قابل توجهی از تلفات را به خود اختصاص می‌دهند. افزون بر این، با رشد جمعیت و تشدید بحران منابع آب در بخش بزرگی از کشورهای جهان، اهمیت موضوع نشت در شبکه‌های آبرسانی شهری افزایش یافته است. نشت در این شبکه‌ها علاوه بر اتلاف آب، موجب خسارت‌های اقتصادی قابل توجهی نیز می‌شود (اسدیانی یکتا و تابش، ۱۳۸۹).

این مسئله از نظر اقتصادی، اجتماعی و زیست‌محیطی اهمیت بالایی دارد؛ بنابراین مقابله با آن ضرورتی اجتناب‌ناپذیر است (سرکرده و خدشناس، ۱۳۸۷). امروزه نشت یکی از چالش‌های اصلی سیستم‌های توزیع آب در سراسر جهان به شمار می‌رود و سالانه حجم بزرگی از آب به دلیل آن از بین می‌رود. میزان نشت در کشورهای مختلف متفاوت است و در کشورهای توسعه‌یافته بین ۳ تا ۵۰ درصد از آب ورودی شبکه را شامل می‌شود (مصلحی، ۱۳۹۹).

هر کشور ویژگی‌های زیست‌محیطی، اقتصادی، فرهنگی و اجتماعی خاص خود را دارد و ایران نیز از این قاعده مستثنی نیست. برخی از شرایط کشور که اهمیت مدیریت نشت را بیشتر می‌کند عبارت‌اند از: محدودیت منابع آب سطحی و زیرزمینی و کاهش نزولات جوی، فرسودگی گسترده شبکه‌های توزیع، عدم اطمینان از اجرای صحیح پروژه‌ها در برخی موارد، ویژگی‌های اقلیمی و جغرافیایی ویژه، و عوامل دیگری که تفاوت‌های قابل توجهی در روش‌های نشت‌یابی و کنترل نشت ایجاد می‌کنند. از زاویه‌ای دیگر، آب یک منبع راهبردی است؛ بنابراین در جلوگیری از هدررفت آن صرفاً موضوع هزینه‌های مالی مطرح نیست، بلکه اصل موضوع جلوگیری از اتلاف این منبع ارزشمند است. در نتیجه، به‌کارگیری روش‌های مختلف کنترل نشت ضرورتی اساسی به شمار می‌آید.

کنترل نشت عبارت است از مجموعه‌ای از اقدامات مدیریتی همراه با بهره‌گیری از تجهیزات کنترلی با هدف به حداقل رساندن هدررفت آب در شبکه. در این رویکرد، نشت به‌طور کامل حذف نمی‌شود، اما تحت کنترل مدیریت شبکه قرار می‌گیرد. به‌طور کلی کنترل نشت به دو دسته اصلی تقسیم می‌شود: مدیریت فشار در شبکه و مدیریت عملیات اجرایی.

تلفات آب در شبکه شامل دو نوع تلفات ظاهری و واقعی است. تلفات ظاهری به هدررفت ناشی از خطاهای انسانی و مدیریتی اشاره دارد؛ مانند خطا در قرائت کنتور، خرابی تجهیزات اندازه‌گیری و وجود انشعابات غیرمجاز. در این حالت، بخشی از آب مصرف‌شده به‌طور دقیق اندازه‌گیری نمی‌شود. تلفات واقعی شامل حجم آبی است که بر اثر حوادث و نشت‌های شبکه از دست می‌رود (عادلی و همکاران، ۱۳۹۵). تلفات واقعی ناشی از خروج فیزیکی آب از شبکه و انشعابات مشترکان است و باعث می‌شود بخشی از آب تولیدشده هرگز به مصرف‌کننده نهایی نرسد (راثی فقیهی و همکاران، ۱۳۹۹).

برآوردها نشان می‌دهد نشت در شبکه‌های توزیع آب تا ۷۰ درصد از کل تلفات آب را شامل می‌شود و حجم نشت سالانه در جهان حدود ۳۲ میلیارد مترمکعب است (گوئو، ژانگ، شائو، ژو و دوان، ۲۰۱۳).

در حال حاضر، میزان آب به حساب نیامده شرکت‌های آب و فاضلاب در بخش شهری حدود ۲۵ درصد و در بخش روستایی حدود ۳۲ درصد است (مرکز پژوهش‌های مجلس، ۱۳۹۷).

طی بررسی انجام‌شده، چهار عامل بیشترین تأثیر را بر افزایش پرت یا تلفات آب شهری در سیستم یا شبکه توزیع آب شهری دارند:

۱. عدم مشارکت بهره‌برداران.

۲. ناهماهنگی و نارسایی‌های بین سازمان‌های دخیل در مدیریت منابع آب.

۳. نارسایی در منابع و امکانات سازمانی.

۴. ضعف مدیریت نیروی انسانی (حقیقی و همکاران، ۱۳۸۳).

کمبود منابع آب، همراه با درصد بالای تلفات و هزینه‌های سنگین تأمین آب هدررفته، ضرورت استفاده از روش‌های مناسب برای کنترل و کاهش تلفات آب در شبکه‌های توزیع آب شهری را ایجاد می‌کند. در این راستا، برخی کشورها با برنامه‌ریزی و اجرای اقدامات مؤثر، توانسته‌اند میزان هدررفت آب را تا حدود ۱۰ درصد کاهش دهند. شایان توجه است که بانک جهانی، تلفات معادل ۱۵ درصد را برای کشورهای در حال توسعه قابل‌توجیه می‌داند (منزوی، ۱۳۸۸).

افزون بر این، از مهم‌ترین مزایای کاهش هدررفت آب در شبکه توزیع می‌توان به موارد زیر اشاره کرد: کاهش هزینه‌های اولیه سرمایه‌گذاری، افزایش عمر تأسیسات، تجهیزات و پمپ‌ها، کاهش هزینه‌های بهره‌برداری و نگهداری، کاهش آلودگی ناشی از شکستگی‌ها و افزایش بازدهی و سوددهی شرکت‌های آب و فاضلاب (اوسپا، مروویچ و دسکا، ۲۰۱۹).

مطالعات نشان داده‌اند که کاهش ۱ درصد از سهم ۲۵ درصدی تلفات آب، موجب حفظ ۱ درصد از منابع آب آشامیدنی موجود و نیز کاهش ۱ درصدی هزینه‌های تولید آب خواهد شد که این میزان در مقیاس کلان بسیار قابل توجه است.

از این‌رو، وجود نشت در شبکه‌های توزیع آب شهری امری اجتناب‌ناپذیر است. امروزه کاهش نشت با استفاده از مدیریت پارامترهای هیدرولیکی نظیر فشار از اهمیت ویژه‌ای برخوردار است. از مشکلات اساسی فشار شبکه

می‌توان به توزیع ناعادلانه آب بین مشترکان در مناطق مختلف، افزایش شکستگی لوله‌های آب و هدررفت ناشی از آن و سایر پیامدها اشاره کرد؛ مسائلی که موجب افزایش دغدغه مسئولان در حوزه آبرسانی می‌شود. ورود بیش از حد آب به شبکه‌های توزیع نیز نگرانی جدی برای مسئولان شرکت‌های آب و فاضلاب ایجاد کرده است.

بررسی مهم‌ترین عوامل مؤثر در نشت و تلفات آب شهری

نشت به‌وجودآمده در سیستم و به‌ویژه در لوله‌ها تحت تأثیر مجموعه‌ای از عوامل و شرایط محیطی و شیمیایی رخ می‌دهد. از مهم‌ترین این عوامل می‌توان به موارد زیر اشاره کرد:

(الف) حرکت خاک دور لوله:

حرکت خاک ممکن است بر اثر لغزش زمین در نواحی شیب‌دار یا بر اثر ارتعاشات ناشی از زمین‌لرزه ایجاد شود. با جابه‌جایی خاک اطراف لوله، نیروی زیادی به لوله وارد می‌شود که می‌تواند موجب ایجاد ترک، فاصله در اتصالات یا شکستگی لوله گردد.

(ب) خوردگی تأسیسات:

خوردگی در محیط خاک و آب برای تمامی ساختارهای فلزی (از جمله لوله‌ها و اتصالات مدفون) پدیده‌ای اجتناب‌ناپذیر است. این خوردگی در مورد پمپ‌ها، لوله‌ها و شیرآلات ممکن است در اثر کاویتاسیون یا خوردگی شیمیایی به وقوع بپیوندد. لوله‌های آبرسانی فلزی از داخل بر اثر ترکیبات نامناسب موجود در آب و از بیرون بر اثر املاح نامناسب موجود در خاک دچار خوردگی می‌شوند. خوردگی لوله‌ها با تشکیل پیل‌های گالوانیکی یا پیل‌های غلظتی صورت می‌گیرد؛ به‌گونه‌ای که بخشی از لوله نقش آند و بخشی دیگر یا اتصالات نقش کاتد را ایفا می‌کند. در نتیجه، جریان فلز از آند به سمت کاتد برقرار شده و قسمت آندی خورده می‌شود.

(ج) فشار زیاد سیستم:

فشار آب موجود در لوله‌ها همواره موجب ایجاد تنش‌های طولی و محیطی در لوله می‌شود. در حالت عادی، لوله این تنش‌ها را تحمل می‌کند؛ اما اگر فشار از حد تحمل بالاتر رود، لوله آسیب دیده و ترک، شکستگی یا خرابی شیرآلات و سایر اجزاء شبکه به‌وجود می‌آید.

(د) ضربه:

بخش عمده‌ای از شبکه توزیع آب (یعنی لوله‌ها) از زیر خیابان‌ها عبور می‌کنند. در صورت حفاری مجدد خیابان توسط ارگان‌هایی همچون شرکت گاز، برق یا مخابرات، ممکن است بر اثر بی‌احتیاطی به لوله‌ها آسیب وارد شود.

(ه) قدمت اجزای شبکه:

تمام اجزای شبکه، صرف‌نظر از جنس، با گذشت زمان دچار فرسودگی می‌شوند و آسیب‌پذیری آن‌ها در برابر

فشارهای داخلی و خارجی افزایش می‌یابد؛ به‌طوری‌که حتی با افزایش اندک فشار سیستم یا اعمال بارهای خارجی ممکن است شکستگی رخ دهد.

و) استفاده از مصالح نامناسب برای پوشش و زیرسازی لوله‌ها:
در هنگام نصب لوله‌ها، باید اطراف لوله‌ها با مصالح مناسب پر شود تا تکیه‌گاه مناسبی ایجاد شده و تنش اضافی به لوله منتقل نشود. استفاده از مصالح نامناسب (مانند مصالح درشت‌دانه یا مصالحی با نشست زیاد) موجب ایجاد فشارهای غیریکنواخت بر لوله شده و می‌تواند سبب آسیب‌دیدگی آن گردد.

ز) نصب غلط:
در صورت کارگذاری لوله‌ها توسط افراد غیرحرفه‌ای یا استفاده از روش‌های غیراستاندارد، احتمال دارد آب‌بندی محل اتصال لوله‌ها به‌طور صحیح انجام نشود. در این حالت از ابتدای نصب، نشت‌های ریز در اتصالات مشاهده می‌شود که با گذشت زمان افزایش می‌یابد (سرکرده و خدشناس، ۱۳۸۷).

ح) فرسودگی لوله‌ها:
فرسودگی لوله‌های شبکه توزیع آب شهری یکی از مهم‌ترین چالش‌های مدیریت صنعت آب است. در صورتی که لوله‌های توزیع آب به پایان عمر مفید خود رسیده باشند یا به دلیل افزایش تقاضا و تغییرات زبری لوله‌ها کارایی لازم را نداشته باشند، باید با لوله‌های جدید جایگزین شوند. محدودیت بودجه یکی از اصلی‌ترین دلایل ناکامی طرح‌های نوسازی و ارتقای سیستم‌های توزیع آب است (اعرابی و همکاران، ۱۴۰۰).

چارچوب استراتژیک برای کاهش تلفات آب

یک برنامه مؤثر برای مدیریت و کاهش تلفات آب نیازمند رویکردی چندوجهی و استراتژیک است. ترکیب چندین استراتژی اثبات‌شده در سطح بالا، چارچوبی جامع ایجاد می‌کند که پیچیدگی‌های شبکه‌های توزیع را مورد توجه قرار می‌دهد. این بخش استراتژی‌های بنیادی را که به شرکت آب امکان کنترل سیستم و کاهش سیستماتیک آب بدون درآمد را می‌دهد، شرح می‌دهد (استاتسکو، بوبوک، تاتو، سربو، مارکویه و توما، ۲۰۲۴):

- مناطق اندازه‌گیری ناحیه‌ای (DMAs): تقسیم شبکه توزیع بزرگ به بخش‌های کوچک‌تر و مجزا، یا مناطق اندازه‌گیری ناحیه‌ای، یکی از ارکان اصلی مدیریت تلفات آب است. این تقسیم‌بندی به اپراتورها امکان می‌دهد تا جریان و فشار آب را در هر منطقه ایزوله‌شده به‌طور دقیق اندازه‌گیری کنند، که این امر ارزیابی تلفات در سطح جزئی‌تر و اولویت‌بندی مداخلات را به‌طور مؤثرتری ممکن می‌سازد.

- ارزیابی و تعمیر سریع آسیب‌ها: پروتکل‌های پاسخ سریع به رویدادهای نشت و شکستگی، عملکردی عملیاتی حیاتی است. اقدام سریع حجم آب ازدست‌رفته را کاهش داده، منابع را حفظ می‌کند، و همچنین مدت‌زمان اختلال در خدمات را کاهش داده و رضایت مشتریان را بهبود می‌بخشد.
 - نظارت جامع شبکه: این استراتژی شامل کاربرد سیستماتیک تکنیک‌هایی برای اندازه‌گیری و مدیریت پارامترهای عملیاتی کلیدی، به‌ویژه فشار آب، در نقاط مختلف شبکه توزیع است. نظارت مداوم، دید لازم برای درک دینامیک‌های سیستم و شناسایی ناهنجاری‌های نشان‌دهنده نشت یا سایر خرابی‌ها را فراهم می‌کند.
 - تصمیم‌گیری مبتنی بر داده: جمع‌آوری داده‌های عملیاتی در زمان واقعی، عملکردی ضروری برای هر شرکت آب مدرن است. این داده‌ها مبنای تجربی برای تصمیم‌گیری‌های به‌موقع و درست در مورد تشخیص نشت، مدیریت فشار، و سرمایه‌گذاری‌های زیرساختی فراهم می‌کنند، و شرکت‌ها را از حالت واکنشی به حالت پیش‌فعال هدایت می‌کنند.
 - مقابله با مصرف غیرمجاز: شرکت‌های آب باید روش‌های عملی برای تشخیص، نظارت، و رفع موارد تخلیه غیرقانونی و سرقت آب اجرا کنند. رسیدگی به مصرف غیرمجاز نه تنها درآمد ازدست‌رفته را بازیابی می‌کند، بلکه پرداخت عادلانه برای تأمین آب را در میان همه مشتریان تضمین می‌کند.
 - اجزای باکیفیت و راه‌حل‌ها: قابلیت اطمینان بلندمدت سیستم توزیع آب اساساً به کیفیت اجزای آن وابسته است. استفاده از لوله‌ها، شیرها، و کنتورهای باکیفیت در ساخت و تعمیر، شبکه‌ای مقاوم‌تر و مستحکم‌تر ایجاد می‌کند که احتمال خرابی‌های آینده و تلفات آب مرتبط را کاهش می‌دهد.
 - آموزش و پرورش حرفه‌ای: سرمایه‌گذاری مداوم در تحقیقات علمی، اشتراک دانش، و دسترسی به بهترین روش‌ها برای تجهیز کارکنان شرکت به مهارت‌های موردنیاز برای اجرای استراتژی‌های پیشرفته و پاسخگویی به چالش‌های در حال تحول بخش تأمین آب ضروری است.
- در حالی که هر یک از این استراتژی‌ها نقش حیاتی ایفا می‌کند، یک روش به‌عنوان مؤثرترین ابزار برای مدیریت تلفات آب آشامیدنی برجسته است: مدیریت فعال فشار.

نقش محوری مدیریت فعال فشار

مدیریت فشار مؤثرترین روش منفرد برای کنترل تلفات آب آشامیدنی در شبکه توزیع است. موفقیت آن ریشه در درک اساسی مکانیک خرابی لوله‌ها دارد. این بخش اصول خرابی‌های مرتبط با فشار را تجزیه و تحلیل کرده و اهداف استراتژی کنترل فشار فعال را شرح می‌دهد.

یک بینش کلیدی از تحلیل عملیاتی این است که اکثر شکستگی‌های لوله نه به دلیل فشار مداوم بالا، بلکه به دلیل نوسانات فشار ایجاد می‌شوند. این تغییرات روزانه باعث انقباض و انقباض مداوم مواد لوله شده، که منجر به تنش چرخه‌ای، خستگی مواد، و در نهایت پارگی می‌شود. هرچه فشار در شبکه بالاتر باشد، حجم آب از دست رفته از طریق هر نشت یا شکستگی موجود بیشتر خواهد بود.

این مشکل با یک چالش ذاتی در طراحی اکثر سیستم‌های تأمین آب تشدید می‌شود. شبکه‌ها به گونه‌ای مهندسی شده‌اند که فشار کاری حداقل را در همه نقاط به‌ویژه در نقاط مرتفع یا دورافتاده—در زمان‌های اوج تقاضای مصرف‌کننده حفظ کنند. نتیجه مستقیم این است که در ساعات غیر اوج، مانند اواخر شب و اوایل صبح، سیستم فشارهایی را تجربه می‌کند که به‌طور قابل‌توجهی بالاتر از حد لازم است. این دوره‌های فشار بیش‌ازحد است که اکثریت شکستگی‌های عمده لوله‌ها رخ می‌دهد (استاتسکو، بوبوک، تاتو، سربو، مارکویه و توما، ۲۰۲۴).

مزایای کنترل سیستماتیک فشار دوگانه است. فایده فوری، کاهش تلفات واقعی حجمی است که منابع آب را حفظ کرده و ردپای کربنی مرتبط با استخراج، تصفیه و پمپاژ آب را کاهش می‌دهد. علاوه بر این، مدیریت مؤثر فشار، نرخ ترکیدگی‌های جدید لوله‌ها را کاهش می‌دهد. با کاهش تنش هیدرولیکی بر لوله‌های قدیمی، این استراتژی به تأخیر در تخریب دارایی‌ها، افزایش طول عمر زیرساخت‌های موجود و بهبود ظرفیت هیدرولیکی کلی سیستم کمک می‌کند.

مدیریت فشار مدرن بر دو رکن اساسی استوار است: طراحی ساختاریافته مناطق اندازه‌گیری ناحیه‌ای (DMAs) و کنترل بهینه شیرهای کاهش فشار (PRVs). انگیزه برای یکپارچه‌سازی این دو رکن، قانع‌کننده است. از یک سو، بسیاری از شبکه‌های توزیع آب در حال حاضر از شیرهای کاهش فشار برای کنترل فشار استفاده می‌کنند، بنابراین هر طراحی جدید DMA باید حضور آن‌ها را در نظر بگیرد تا فشار کافی برای همه مشتریان تضمین شود. از سوی دیگر، انتظار می‌رود که یکپارچه‌سازی این دو استراتژی، مدیریت شبکه‌ای مؤثرتر و قوی‌تر را به‌ویژه در شرایط غیرعادی مانند نوسانات تقاضای آب فراهم کند (براردی، لاوچلی، سیمونه، پرونه و جوستولیسی، ۲۰۱۹).

روش‌های اصلی برای کنترل فشار

برای مدیریت مؤثر شبکه‌های توزیع آب پیچیده، صنعت به طور فزاینده‌ای از رویکردهای تجربی—که اغلب مبتنی بر تحلیل بصری و تجربه تکنسین‌ها هستند—به سمت روش‌های ساختاریافته و داده‌محور حرکت می‌کند. این تحول برای توسعه راه‌حلهایی که نه تنها بهینه، بلکه قابل تأیید، سازگار و قوی باشند، حیاتی است. این بخش اجزای اصلی تشکیل‌دهنده استراتژی یکپارچه مدیریت فشار را بررسی می‌کند: طراحی پیشرفته DMA و کنترل پیچیده PRV (براردی، لاوچلی، سیمونه، پرونه و جوستولیسی، ۲۰۱۹).

نمونه ای عملی از کنترل فشار

به طور پروژه کنترل فشار در شهر یاش کشور رومانی است که در مقاله (استاتسکو، بوبوک، تاتو، سربو، مارکویه و توما، ۲۰۲۴) نحوه اجرای آن مورد بررسی قرار گرفته است.

برای مواجهه با چالش‌های سیستم، اپراتورها برنامه کنترل فشار چندجانبه‌ای را اجرا کردند که شامل مداخلات زیر بود:

- تقسیم‌بندی سیستم از طریق نصب شیر: اپراتورها بسته شدن جزئی یا کامل استراتژیک شیرها را برای ایجاد مناطق فشار متمایز انجام دادند. این تکنیک یا ظرفیت انتقال آب در برخی خطوط اصلی را کاهش داد یا یک منطقه تأمین را به بخشی از شبکه با رژیم فشار پایین‌تر منتقل کرد.
- تنظیم ارتفاع پمپاژ: در مناطقی که تقاضای آب با گذشت زمان کاهش یافته بود، ارتفاع پمپاژ به‌طور فعال کنترل و کاهش یافت. این امر از فشار بیش‌ازحد در مناطقی که دیگر به فشارهای بالایی که برای آن‌ها طراحی شده بودند، نیاز نداشتند، جلوگیری کرد.
- نصب شیرهای کاهش فشار (PRVs): شیرهای کاهش فشار به‌عنوان روش اصلی برای کاهش مستقیم فشار نصب شدند. سیستم از انواع مختلفی استفاده کرد، از جمله شیرهایی که فشار پایین‌دست ثابت را فراهم می‌کنند و مدل‌های پیشرفته‌تری که قادر به اجرای افت فشار متغیر هستند، مانند کاهش قابل توجه فشار در ساعات شب.
- برنامه‌ریزی مبدل فرکانس پمپ: برای تجهیزات پمپاژی مجهز به مبدل‌های فرکانس، برنامه‌هایی توسعه داده شد تا به‌طور خودکار فشار تأمین‌شده را در بازه حداقل مصرف از ساعت ۲۳:۰۰ تا ۰۳:۰۰ کاهش دهد، که مستقیماً دوره با بالاترین ریسک برای خرابی‌های مرتبط با فشار را هدف قرار می‌داد.

قوانین هیدرولیکی مدل سازی شبکه های توزیع آب

پیش از بررسی راهبردهای کنترلی، باید درک دقیقی از مدل های فیزیکی و ریاضی حاکم بر رفتار **WDN** داشت. این شبکه ها شامل اجزای حیاتی چون لوله ها، مخازن، سدها، پمپ ها و شیرها هستند که در قالب یک توپولوژی پیچیده به هم متصل اند. عملکرد سیستم توسط دو قانون اصلی فیزیکی توصیف می شود:

۱. تعادل گره ای (حفظ جرم): در هر گره شبکه، مجموع جریان ورودی باید با مجموع جریان خروجی (به اضافه یا منهای مصرف در آن نقطه) برابر باشد.

۲. حفظ انرژی: وقتی آب از یک نقطه به نقطه دیگر در لوله حرکت می کند، بخشی از انرژی خودش را از دست می دهد. این انرژی به خاطر اصطکاک بین آب و دیواره های لوله و تغییرات مسیر (مثلاً زانو یا اتصالات) کم می شود. به این کاهش انرژی می گویند افت هد (**Head Loss**).

این قوانین مبنای مدل های شبیه سازی هیدرولیکی را تشکیل می دهند که رفتار فشار و جریان را در شرایط مختلف بهره برداری پیش بینی می کنند. شناخت این اصول، نخستین گام در طراحی راهبردهای مؤثر کنترل فشار محسوب می شود (موسستل، حامام، دو و موناچلی، ۲۰۲۰).

سامانه های آب شهری

سامانه های آب شهری مجموعه ای یکپارچه از فرآیندها و زیرساخت ها هستند که تأمین، انتقال، تصفیه و توزیع آب را در شهرها مدیریت می کنند. این سامانه ها همچنین جمع آوری و تصفیه فاضلاب و مدیریت رواناب شهری را برعهده دارند. هدف آن ها تضمین پایداری، سلامت عمومی و کارایی عملکرد شبکه های آبرسانی و فاضلاب است.

Urban Water Systems – UWS (سامانه های آب شهری)			
Water Distribution (توزیع آب)	Waste Water Treatment (تصفیه فاضلاب)	Storm Water Systems (سامانه آب های طوفانی)	Raw Water Treatment (تصفیه آب خام)
- مدیریت نشت - کیفیت آب - مدیریت فشار - مدیریت دارایی ها	- ورود فاضلاب - ته نشینی - تصفیه زیستی - گندزدایی - فیلتراسیون	- بهبود زیستگاه - مدیریت منابع آبی - کنترل سیلاب - کنترل رسوب	- انعقاد و لخته سازی - فیلتراسیون - گندزدایی - تنظیم pH

شبکه های توزیع آب

شبکه های توزیع آب در قالب یک سیستم یکپارچه شامل تاسیسات آبیگری و تصفیه خانه ها، مخازن توزیع آب، خطوط لوله های اصلی، پمپ ها، شیرآلات و انشعابات می باشند. که مجموعه ی عملکرد آنها به عنوان سیستم انتقال دهنده آب از منابع تامین به نقاط مصرف می باشد. (اسدی، ۱۳۹۸)

اجزای کنترل کننده جریان شبکه های توزیع آب

به طور کلی، شبکه های توزیع آب از مجموعه ای از تاسیسات شامل آبیگری، تصفیه خانه ها، مخازن توزیع و تانک ها، لوله های انتقال آب، اتصالات، شیرآلات، پمپ ها و انشعابات فرعی تشکیل می شوند. تاسیسات آبیگری، تصفیه خانه ها، لوله ها و انشعابات فرعی از جمله تاسیسات ثابتی هستند که عملکرد آنها بر نحوه مدیریت و کنترل جریان شبکه تأثیری ندارد. مخازن، پمپ ها و شیرآلات نیز از جمله اجزای کنترل کننده شبکه محسوب می شوند که عملکرد هر یک می تواند مصرف شبکه را تحت تأثیر قرار دهد. در این بخش به تعریف عوامل کنترل کننده جریان در شبکه ها پرداخته می شود (اسدی، ۱۳۹۸).

پمپ ها

پمپ ها در خطوط آبرسانی برای تأمین هد اضافی و انتقال آب از یک سطح پایین تر به سطح بالاتر استفاده می شوند. در شبکه های توزیع، پمپ ها ممکن است به دو صورت به کار روند: خارج از شبکه به عنوان پمپ های آبرسانی برای تأمین آب از منابع خارجی، و داخل شبکه به عنوان پمپ های تقویتی برای تأمین فشار مورد نیاز در سیستم.

مخازن

در شبکه های توزیع آب، مخازن توزیع یا مخازن سرویس برای اهدافی مانند ذخیره سازی آب، متعادل سازی جریان یکنواخت تغذیه (جریان ورودی به شبکه) و جریان نایکنواخت مصرف (خروجی)، و همچنین تأمین و متعادل سازی فشار طراحی و احداث می شوند.

شیرآلات و انواع آن

از جمله متعلقات اصلی کنترل کننده جریان در شبکه های توزیع آب، شیرآلات می باشند. میزان باز یا بسته بودن شیرآلات متناسب با مصرف مورد نیاز شبکه از مهم ترین عملکردهای کنترل کننده آن ها محسوب می شود. به طور کلی، شیرآلات در شش دسته بندی اصلی تقسیم می شوند.


این نوع شیرآلات، فشار پایین دست شبکه را متناسب با فشار مورد نیاز (فشار سرویس) برای تأمین مصرف گره ها تنظیم می کنند. زمانی که فشار بالادست شیر از فشار تنظیمی بیشتر باشد، شیر در وضعیت فعال قرار گرفته و می تواند فشار بالادست را به مقدار تنظیم شده محدود کند. زمانی که فشار پایین دست شیر از فشار تنظیمی بیشتر باشد، شیر کاملاً بسته شده و از ایجاد جریان برگشتی جلوگیری می کند. همچنین، زمانی که فشار بالادست شیر با فشار تنظیمی برابر باشد، شیر غیر فعال یا کاملاً باز شده و تأثیری بر کنترل جریان نخواهد داشت.	شیرآلات کاهنده فشار (PRV)
این نوع شیرآلات، فشار بالادست خود را در یک مقدار تنظیم شده نگه می دارند. وضعیت این شیرآلات بر اساس میزان فشار بالادست و پایین دست تغییر می کند. اگر فشار پایین دست کمتر از فشار بالادست باشد، شیر در وضعیت فعال قرار گرفته و فشار بالادست را در مقدار تنظیمی خود نگه می دارد. زمانی که فشار پایین دست بیشتر از فشار تنظیمی شیر و کمتر از فشار بالادست باشد، شیر در وضعیت غیر فعال و کاملاً باز قرار دارد. اگر فشار پایین دست از فشار بالادست بیشتر شود، شیر کاملاً بسته شده و از جریان برگشتی جلوگیری می کند.	شیرآلات نگهدارنده فشار (PSV)
این نوع شیرآلات برای ایجاد افت فشار ثابت در جریان هنگام عبور از شیر استفاده می شوند. جریان عبوری از شیر متناسب با تنظیمات شیر دچار افت ثابت می شود و زمانی فعال است که فشار بالادست از فشار پایین دست بیشتر بوده و اختلاف فشار بین بالادست و پایین دست کمتر از فشار تنظیمی شیر باشد.	-شیرآلات فشارشکن (PBV)
اساس تنظیم این نوع شیرآلات بر دبی جریان شبکه است و دبی عبوری از شیر را به مقدار مشخصی متناسب با نیاز پایین دست محدود می کند.	-شیرآلات کنترل کننده جریان (FCV)

حداکثر ظرفیت دبی عبوری به ظرفیت دبی قطر لوله متصل به شیر بستگی دارد و بیانگر وضعیت کاملاً باز شیر است. در صورتی که دبی تنظیمی شیر بر روی صفر قرار گیرد، هیچ جریانی به پایین دست منتقل نمی شود و شیر کاملاً بسته است.	
نوع دیگری از شیرآلات کنترل جریان وجود دارد که اساس تنظیم آن بر میزان بسته بودن شیر است و با ضریب افت هد تنظیم می شود. محدوده ضریب افت هد این شیرآلات بر اساس مشخصات کارخانه سازنده تعیین می شود.	-شیرآلات کنترل کننده از نوع (TCV)
تنظیم نسبی افت هد در مقابل دبی، معرف عملکرد ویژه این نوع شیرآلات است و در مکان های خاص برای تأمین مصارف با روابط مستقل از روابط هیزن-ویلیامز به کار می رود. به منظور استفاده از این شیرآلات در شبکه های توزیع آب، لازم است نمودار دبی-هد برای هر شیر GPV تعریف شود.	-شیرآلات با عملکرد خاص (GPV)

معرفی شیرهای فشارشکن

پژوهشگران از شیرهای فشارشکن برای کاهش فشار شبکه های توزیع و ارزیابی عملکرد آن ها استفاده کرده اند. ویژگی اصلی این شیرها، قابلیت تنظیم و کنترل میزان فشار خروجی است. نصب دقیق و صحیح شیرهای فشارشکن برای دستیابی به بیشترین کارایی ضروری است. فشار خروجی باید به گونه ای تنظیم شود که حداقل فشار مورد نیاز برای تأمین نیاز مشترکین را فراهم کند.

شیرهای فشارشکن به صورت خودکار فشارهای زیاد و متغیر ورودی را به فشار ثابت و قابل کنترل در خروجی تبدیل می کنند. استفاده از این تجهیزات علاوه بر تسهیل بهره برداری از شبکه ها و خطوط انتقال، موجب حذف هزینه های سنگین خرید زمین و ساخت مخازن فشارشکن می شود. همچنین همان گونه که اشاره شد، کاهش فشار اضافی در شبکه نقش مهمی در جلوگیری از هدررفت قابل توجه آب دارد. (فرشیدخواه، قائینی حصاروئی، فدائی کرمانی، ۱۳۹۸).



در شیرهای فشارشکن، فشار ورودی P_1 ، فشار خروجی P_2 و فشار داخل محفظه پیستون و سیلندر P_3 به صورت متقابل عملکرد شیر را کنترل می‌کنند.

پیلوت وظیفه دارد فشار خروجی را همواره در مقدار تنظیم‌شده P_2 ثابت نگه دارد. بنابراین، زمانی که فشار P_2 در خروجی شیر اصلی افزایش یابد، پیلوت سطح مقطع عبور خود را کاهش می‌دهد. با کوچک شدن این مقطع، فشار P_3 افزایش یافته و در نتیجه پیستون به سمت پایین حرکت می‌کند. این حرکت باعث کاهش سطح مقطع عبور جریان در شیر اصلی شده و فشار P_2 مجدداً تثبیت می‌شود. در لحظه‌ای که تعادل فشارها برقرار شود، حرکت پیستون متوقف می‌گردد.

اگر فشار P_2 به دلیل کاهش مصرف، تمایل به افزایش بیش از مقدار تنظیم‌شده داشته باشد، پیلوت جریان عبوری را کاملاً قطع می‌کند. در این حالت، افزایش فشار P_3 سبب می‌شود پیستون تا بسته شدن کامل شیر اصلی حرکت کند و آب‌بندی کامل انجام شود.

برعکس، اگر فشار P_2 کمتر از مقدار تنظیمی شود، پیلوت مقطع عبور خود را افزایش می‌دهد و متعاقب آن فشار P_3 کاهش می‌یابد. در نتیجه پیستون بیشتر باز شده و جریان بیشتری عبور می‌کند تا فشار P_2 به مقدار تنظیم‌شده برسد. اگر به دلیل افزایش بیش از حد مصرف در شبکه فشار P_2 قابل افزایش نباشد، شیر اصلی به طور کامل باز می‌شود تا حداکثر جریان برقرار گردد. (فرشیدخواه، قائینی حصاروئی، فدائی کرمانی، ۱۳۹۸)

استراتژی‌های کنترل شیر کاهش فشار (PRV)

شیرهای کاهش فشار از تجهیزات کلیدی برای مدیریت فشار در سامانه‌های توزیع آب هستند، به‌ویژه زمانی که فشار شبکه از سطح لازم برای ارائه خدمات مناسب فراتر می‌رود. عملکرد اصلی آن‌ها کاهش انرژی اضافی و حفظ فشار مطلوب در سمت پایین‌دست است. برای کنترل این شیرها دو رویکرد اصلی وجود دارد (براردی، لاوچلی، سیمونه، پرونه و جوستولیسکی، ۲۰۱۹):

۱. **کنترل محلی:** این استراتژی متداول، شیر را برای حفظ فشار هدف مشخص در یک حسگر واقع در پایین‌دست دستگاه تنظیم می‌کند. از آنجا که تقاضای مشتری و افت فشار ناشی از آن در طول روز تغییر می‌کند، این رویکرد نیازمند تعریف یک الگوی زمانی دقیق از فشارهای هدف برای جلوگیری از فشار بیش‌ازحد در دوره‌های تقاضای پایین (مانند شب) و فشار ناکافی در ساعات اوج تقاضا است.
۲. **کنترل از راه دور در زمان واقعی (RRTC):** این استراتژی پیشرفته از فناوری‌های اطلاعات و ارتباطات (ICT) برای تنظیم شیر بر اساس قرائت‌های فشار از یک "گره بحرانی" از راه دور در شبکه توزیع استفاده می‌کند. مزیت کلیدی آن، استحکام است؛ به جای یک الگوی زمانی پیچیده، فشار هدف ثابتی را در گره بحرانی حفظ می‌کند. سیستم به طور خودکار با تغییرات تقاضا سازگار می‌شود و آن را به روش کنترلی قابل‌اعتمادتر و کارآمدتر تبدیل می‌کند.

تعاریف و مبانی ضروری یادگیری تقویتی عمیق


راویچاندیران (۲۰۲۰) در کتاب خود به بررسی یادگیری تقویتی عمیق با پایتون پرداخته و مباحثی مانند اصول پایه‌ای یادگیری تقویتی، شبکه‌های عصبی عمیق، الگوریتم‌های کلیدی مانند **Q-Learning** و **Deep Q-Network (DQN)** و نحوه پیاده‌سازی آن‌ها در محیط‌های شبیه‌سازی شده را به تفصیل توضیح داده است. در این پایان‌نامه، بخش‌هایی از مطالب ارائه‌شده در این کتاب به‌عنوان مرجع اصلی برای تبیین مفاهیم پایه‌ای و چارچوب نظری استفاده شده است تا خواننده بتواند درک کاملی از اصول یادگیری تقویتی و کاربرد آن در مسائل مدل‌سازی و بهینه‌سازی بدست آورد. همچنین، توضیحات و مثال‌های عملی ارائه‌شده در کتاب برای طراحی آزمایش‌ها و پیاده‌سازی مدل‌های مورد استفاده در این پژوهش الهام‌بخش بوده است و به شکل مستقیم یا با اقتباس در بخش‌های مربوط به روش تحقیق و توسعه مدل‌ها مورد استفاده قرار گرفته‌اند.

مبانی یادگیری تقویتی

یادگیری تقویتی (Reinforcement Learning یا RL) یکی از حوزه‌های یادگیری ماشین است. برخلاف سایر الگوهای یادگیری ماشین، مانند یادگیری نظارت‌شده و بدون نظارت، RL به صورت «آزمایش و خطا» و از طریق تعامل مستقیم با محیط خود کار می‌کند.

RL یکی از فعال‌ترین زمینه‌های تحقیق در حوزه‌ی هوش مصنوعی است و باور بر این است که RL ما را یک گام به دستیابی به هوش عمومی مصنوعی نزدیک‌تر خواهد کرد. یادگیری تقویتی در چند سال اخیر به سرعت پیشرفت کرده و دامنه‌ی گسترده‌ای از کاربردها را شامل می‌شود؛ از ساخت سیستم‌های پیشنهاددهنده گرفته تا خودروهای خودران. دلیل اصلی این پیشرفت، ظهور یادگیری تقویتی عمیق است؛ که ترکیبی از یادگیری عمیق و RL می‌باشد. با پیدایش الگوریتم‌ها و کتابخانه‌های جدید RL، این حوزه به وضوح به یکی از امیدبخش‌ترین زمینه‌های یادگیری ماشین تبدیل شده است.

در شکل زیر نحوه دسته بندی کلی را می توانید مشاهده بفرمائید.



عناصر کلیدی یادگیری تقویتی

عامل (Agent)

عامل یک برنامه نرم‌افزاری است که یاد می‌گیرد تصمیم‌های هوشمندانه بگیرد. می‌توان گفت عامل در محیط یادگیری تقویتی همان «یادگیرنده» است. برای مثال، یک بازیکن شطرنج را می‌توان یک عامل در نظر گرفت، زیرا بازیکن یاد می‌گیرد بهترین حرکات (تصمیم‌ها) را انجام دهد تا بازی را برنده شود. به همین شکل، شخصیت ماریو در بازی ویدیویی **Super Mario Bros** را نیز می‌توان عامل دانست، زیرا ماریو محیط بازی را کاوش می‌کند و یاد می‌گیرد بهترین حرکات را برای پیشروی در بازی انجام دهد.

محیط (Environment)

محیط، دنیایی است که عامل در آن قرار دارد. عامل در داخل محیط زندگی و فعالیت می‌کند. به عنوان مثال، در بازی شطرنج، صفحه‌ی شطرنج محیط نامیده می‌شود، زیرا بازیکن شطرنج (عامل) یاد می‌گیرد بازی را در محدوده‌ی همان صفحه انجام دهد. به طور مشابه، در بازی **Super Mario Bros**، دنیای ماریو محیط او محسوب می‌شود.

حالت و کنش (State and Action)

حالت، یک موقعیت یا لحظه در محیط است که عامل می‌تواند در آن قرار داشته باشد. گفتیم که عامل در محیط قرار دارد و محیط می‌تواند شامل موقعیت‌های مختلفی باشد که عامل در آن‌ها قرار می‌گیرد. این موقعیت‌ها را حالت می‌نامیم. برای مثال، در بازی شطرنج، هر آرایش مهره‌ها روی صفحه یک حالت محسوب می‌شود. حالت معمولاً با نماد **S** نشان داده می‌شود.

عامل با محیط تعامل دارد و با انجام یک کنش از یک حالت به حالت دیگر منتقل می‌شود. در محیط بازی شطرنج، کنش همان حرکتی است که بازیکن (عامل) انجام می‌دهد. کنش معمولاً با نماد **a** نمایش داده می‌شود.

پاداش (Reward)

آموختیم که عامل با انجام یک کنش با محیط تعامل می‌کند و از یک حالت به حالت دیگر منتقل می‌شود. بر اساس کنشی که انجام می‌دهد، عامل یک پاداش دریافت می‌کند. پاداش چیزی نیست جز یک مقدار عددی؛ برای مثال $+1$ برای یک کنش خوب و -1 برای یک کنش بد.

الگوریتم یادگیری تقویتی (RL Algorithm)

مراحل انجام یک الگوریتم معمولی یادگیری تقویتی به شکل زیر است:

۱. ابتدا عامل با انجام یک کنش با محیط تعامل می‌کند.
۲. با انجام این کنش، عامل از یک حالت به حالت دیگری منتقل می‌شود.
۳. سپس عامل بر اساس کنشی که انجام داده است، یک پاداش دریافت می‌کند.
۴. بر اساس مقدار پاداش، عامل تشخیص می‌دهد که کنش انجام شده خوب بوده است یا بد.
۵. اگر کنش خوب باشد، یعنی اگر عامل پاداش مثبت دریافت کند، عامل آن کنش را ترجیح می‌دهد و تمایل دارد آن را دوباره انجام دهد. در غیر این صورت، عامل تلاش می‌کند کنش‌های دیگری را امتحان کند تا پاداش مثبت دریافت کند.

یادگیری تقویتی اساساً یک فرآیند یادگیری بر پایه‌ی آزمون و خطا است.

در نهایت، هدف عامل این است که پاداش دریافتی خود را بیشینه کند. اگر عامل پاداش خوبی دریافت کند، یعنی کنش مناسبی انجام داده است. اگر عامل کنش‌های خوبی انجام دهد، در نتیجه می‌تواند بازی را ببرد. بنابراین عامل با بیشینه کردن پاداش خود، یاد می‌گیرد که چگونه بازی را برنده شود.

تفاوت یادگیری تقویتی با سایر پارادایم‌های یادگیری ماشین

ما می‌توانیم یادگیری ماشین (ML) را به سه نوع دسته‌بندی کنیم:

- یادگیری نظارت شده (Supervised learning)
- یادگیری نظارت نشده (Unsupervised learning)
- یادگیری تقویتی (RL)


در یادگیری نظارت شده، ماشین از داده‌های آموزشی یاد می‌گیرد. داده‌های آموزشی شامل جفت‌های برچسب‌گذاری شده (labeled) از ورودی‌ها و خروجی‌ها هستند. بنابراین، ما مدل (عامل) را با استفاده از داده‌های آموزشی به گونه‌ای آموزش می‌دهیم که مدل بتواند یادگیری خود را به داده‌های جدید و دیده‌نشده تعمیم دهد.

این روش، یادگیری نظارت شده نامیده می‌شود زیرا داده‌های آموزشی مانند یک ناظر عمل می‌کنند، چون دارای جفت‌های برچسب‌دار از ورودی‌ها و خروجی‌ها هستند و مدل را در یادگیری وظیفه مورد نظر راهنمایی می‌کنند.

مشابه یادگیری نظارت شده (**supervised learning**)، در یادگیری نظارت نشده (**unsupervised learning**) نیز، ما مدل (عامل) را بر اساس داده‌های آموزشی، آموزش می‌دهیم. اما در مورد یادگیری نظارت نشده، داده‌های آموزشی هیچ برچسبی (**labels**) ندارند؛ یعنی فقط شامل ورودی‌ها هستند و نه خروجی‌ها. هدف یادگیری نظارت نشده، تعیین الگوهای پنهان در ورودی است.

یک تصور غلط رایج وجود دارد که یادگیری تقویتی (**RL**) نوعی یادگیری نظارت نشده است، اما اینطور نیست. در یادگیری نظارت نشده، مدل ساختار پنهان را می‌آموزد، در حالی که در یادگیری تقویتی، مدل با بیشینه کردن پاداش یاد می‌گیرد.

می‌توان گفت که هم در یادگیری نظارت شده و هم در یادگیری نظارت نشده، مدل (عامل) بر اساس مجموعه داده آموزشی (**training dataset**) یاد می‌گیرد، در حالی که در یادگیری تقویتی، عامل با تعامل مستقیم با محیط یاد می‌گیرد. بنابراین، یادگیری تقویتی اساساً یک تعامل بین عامل و محیط آن است.



مفاهیم پایه یادگیری تقویتی

فضای عمل

می‌توان فضاهای عمل را به دو نوع دسته‌بندی کرد:

- فضای عمل گسسته (Discrete action space)
- فضای عمل پیوسته (Continuous action space)

فضای عمل گسسته: زمانی که فضای عمل شامل اعمالی است که گسسته هستند، به آن فضای عمل گسسته گفته می‌شود. به عنوان مثال، در محیط شبکه‌ای، فضای عمل ما شامل چهار عمل گسسته «بالا»، «پایین»، «چپ» و «راست» است، بنابراین این محیط دارای فضای عمل گسسته است.

فضای عمل پیوسته (Continuous action space): زمانی که فضای عمل شامل اعمالی با مقادیر پیوسته باشد، به آن فضای عمل پیوسته گفته می‌شود. به عنوان مثال، فرض کنید یک عامل را برای رانندگی یک خودرو آموزش می‌دهیم؛ در این حالت فضای عمل شامل اعمالی با مقادیر پیوسته است، مانند سرعت رانندگی یا زاویه‌ای که باید فرمان را بچرخانیم. در شرایطی که فضای عمل شامل چنین اعمال پیوسته‌ای باشد، آن را فضای عمل پیوسته می‌نامیم.

سیاست (Policy)

سیاست رفتار عامل را در یک محیط تعریف می‌کند و مشخص می‌کند که عامل در هر وضعیت چه عملی را انجام دهد. به عنوان مثال، در محیط شبکه‌ای، ما وضعیت‌های A تا I و چهار عمل ممکن داریم. سیاست ممکن است به عامل بگوید در وضعیت A به پایین حرکت کند، در وضعیت D به راست حرکت کند و به همین ترتیب.

برای تعامل اولیه با محیط، یک سیاست تصادفی (random policy) را مقداردهی اولیه می‌کنیم، یعنی سیاست تصادفی به عامل می‌گوید در هر وضعیت یک عمل تصادفی انجام دهد. در این حالت، در اولین تکرار، عامل در هر وضعیت یک عمل تصادفی انجام می‌دهد و تلاش می‌کند با توجه به پاداشی که دریافت می‌کند، بفهمد عمل انجام‌شده خوب است یا بد.

با گذشت چندین تکرار، عامل یاد می‌گیرد که در هر وضعیت اعمال خوب انجام دهد که پاداش مثبت می‌دهند. در نتیجه، می‌توان گفت که پس از چندین تکرار، عامل یک سیاست خوب (**good policy**) یاد می‌گیرد که پاداش مثبت می‌دهد.

این سیاست خوب، سیاست بهینه (**optimal policy**) نامیده می‌شود. سیاست بهینه، سیاستی است که به عامل پاداش خوبی می‌دهد و او را به هدف می‌رساند.

بنابراین، سیاست بهینه به عامل می‌گوید که در هر وضعیت عمل صحیح را انجام دهد تا پاداش خوبی دریافت کند. سیاست‌ها را می‌توان به دو دسته تقسیم کرد:

- سیاست قطعی (**Deterministic policy**)

- سیاست تصادفی (**Stochastic policy**)

سیاست قطعی (Deterministic Policy)

سیاستی که تاکنون بررسی کردیم، یک سیاست قطعی است. سیاست قطعی به عامل می‌گوید که در هر وضعیت یک عمل مشخص را انجام دهد. به عبارت دیگر، سیاست قطعی وضعیت را به یک عمل خاص نگاشت می‌کند و معمولاً با μ نمایش داده می‌شود.

با داشتن یک وضعیت s در زمان t ، سیاست قطعی به عامل می‌گوید یک عمل مشخص a را انجام دهد. این را می‌توان به شکل زیر نوشت:

$$a_t = \mu(s_t)$$

سیاست تصادفی (Stochastic Policy)

برخلاف سیاست قطعی، سیاست تصادفی وضعیت را مستقیماً به یک عمل مشخص نگاشت نمی‌کند؛ بلکه وضعیت را به یک توزیع احتمالی روی فضای عمل نگاشت می‌دهد.

یعنی، همان‌طور که آموختیم در سیاست قطعی، با داشتن یک وضعیت، عامل همیشه همان عمل مشخص را انجام می‌دهد. اما در سیاست تصادفی، با داشتن یک وضعیت، سیاست یک توزیع احتمالی روی فضای عمل

بازمی‌گرداند. بنابراین، به جای اینکه عامل هر بار که به وضعیت مشخصی می‌رسد همان عمل را انجام دهد، در هر بار بازدید از وضعیت، عامل اعمال متفاوتی را انجام می‌دهد که انتخاب آن‌ها بر اساس توزیع احتمالی ارائه‌شده توسط سیاست تصادفی است.

بنابراین، سیاست تصادفی وضعیت را به یک توزیع احتمالی روی فضای عمل نگاشت می‌دهد و معمولاً با π نمایش داده می‌شود. فرض کنید یک وضعیت s و یک عمل a در زمان t داریم، در این صورت می‌توان سیاست تصادفی را به شکل زیر نوشت:

$$a_t \sim \pi(a_t | s_t)$$

یا به صورت دیگر:

$$\pi(a_t | s_t)$$

سیاست تصادفی را می‌توان به دو نوع دسته‌بندی کرد:

- سیاست دسته‌ای (Categorical Policy)
- سیاست گاوسی (Gaussian Policy)

سیاست دسته‌ای (Categorical Policy)

یک سیاست تصادفی زمانی سیاست دسته‌ای نامیده می‌شود که فضای عمل گسسته باشد. به عبارت دیگر، سیاست تصادفی از یک توزیع احتمال دسته‌ای (categorical probability distribution) روی فضای عمل برای انتخاب اعمال استفاده می‌کند، زمانی که فضای عمل گسسته است.

سیاست گاوسی (Gaussian Policy)

یک سیاست تصادفی زمانی سیاست گاوسی نامیده می‌شود که فضای عمل پیوسته باشد. به عبارت دیگر، سیاست تصادفی از یک توزیع احتمال گاوسی (Gaussian probability distribution) روی فضای عمل برای انتخاب اعمال استفاده می‌کند، زمانی که فضای عمل پیوسته است.

برای درک بهتر، یک مثال ساده می‌زنیم: فرض کنید عامل ما در حال آموزش برای رانندگی یک خودرو است و فضای عمل شامل یک عمل پیوسته است، یعنی سرعت خودرو که مقدار آن می‌تواند از ۰ تا ۱۵۰ کیلومتر بر ساعت تغییر کند. در این حالت، سیاست تصادفی از توزیع گاوسی روی فضای عمل استفاده می‌کند تا سرعت خودرو (عمل) را انتخاب کند.

اپیزود (Episode)

عامل با انجام اعمال مختلف با محیط تعامل می‌کند، از وضعیت اولیه شروع کرده و به وضعیت نهایی می‌رسد. این تعامل عامل-محیط که از وضعیت اولیه تا وضعیت نهایی ادامه دارد، اپیزود نامیده می‌شود.

به‌عنوان مثال، در یک بازی ویدیویی مسابقه خودرو، عامل بازی را با شروع از وضعیت اولیه (نقطه شروع مسابقه) آغاز می‌کند و به وضعیت نهایی (نقطه پایان مسابقه) می‌رسد. این مسیر یک اپیزود محسوب می‌شود. اپیزود اغلب با نام مسیر (trajectory) نیز شناخته می‌شود و با τ نشان داده می‌شود.

عامل می‌تواند بازی را برای تعداد نامحدودی از اپیزودها انجام دهد و هر اپیزود مستقل از سایر اپیزودها است. اما چرا عامل باید بازی را برای چندین اپیزود انجام دهد؟ برای یادگیری سیاست بهینه، یعنی سیاستی که به عامل می‌گوید در هر وضعیت عمل صحیح را انجام دهد، عامل باید بازی را برای اپیزودهای متعدد اجرا کند.

به‌عنوان مثال، فرض کنید بازی مسابقه خودرو را انجام می‌دهیم؛ بار اول ممکن است برنده نشویم، بنابراین بازی را چندین بار انجام می‌دهیم تا با محیط بازی بیشتر آشنا شویم و استراتژی‌های مناسبی برای برد پیدا کنیم. به همین ترتیب، در اپیزود اول، عامل ممکن است موفق نشود و برای یادگیری محیط و استراتژی‌های برنده شدن، چندین اپیزود بازی می‌کند.

اگر بازی را از وضعیت اولیه در زمان $t = 0$ شروع کنیم و در زمان T به وضعیت نهایی برسیم، اطلاعات اپیزود شامل تعامل عامل-محیط، یعنی وضعیت، عمل و پاداش، از وضعیت اولیه تا وضعیت نهایی است:

$$(s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_T)$$

کارهای اپیزودی و پیوسته (Episodic and Continuous Tasks)

یک وظیفه در یادگیری تقویتی (RL) را می‌توان به دو نوع دسته‌بندی کرد:

۱. کار اپیزودی (Episodic Task)

۲. کار پیوسته (Continuous Task)

کار اپیزودی: همان طور که از نامش مشخص است، کار اپیزودی دارای وضعیت نهایی (ترمینال) است. به عبارت دیگر، این وظایف از اپیزودها تشکیل شده‌اند و بنابراین یک وضعیت پایانی دارند. به عنوان مثال، در بازی مسابقه خودرو، از نقطه شروع (وضعیت اولیه) آغاز می‌کنیم و به مقصد (وضعیت ترمینال) می‌رسیم.

کار پیوسته: بر خلاف کارهای اپیزودی، کارهای پیوسته هیچ اپیزودی ندارند و بنابراین وضعیت نهایی نیز ندارند. به عنوان مثال، یک ربات دستیار شخصی هیچ وضعیت ترمینالی ندارد و همیشه به تعامل خود با محیط ادامه می‌دهد.

افق (Horizon)

افق، تعداد گام‌های زمانی است که عامل با محیط تعامل دارد. افق را می‌توان به دو نوع تقسیم کرد:

- افق محدود (Finite Horizon)
- افق نامحدود (Infinite Horizon)

افق محدود: اگر تعامل عامل-محیط در یک گام زمانی مشخص متوقف شود، افق محدود نامیده می‌شود. به عنوان مثال، در کارهای اپیزودی، عامل از وضعیت اولیه در زمان $t = 0$ شروع می‌کند و به وضعیت نهایی در زمان T می‌رسد. از آنجا که تعامل عامل-محیط در زمان T متوقف می‌شود، این یک افق محدود محسوب می‌شود.

بازده (Return) و عامل تنزیل (Discount Factor)

بازده (Return): بازده به مجموع پاداش‌هایی گفته می‌شود که عامل در طول یک اپیزود دریافت می‌کند و معمولاً با R یا G نمایش داده می‌شود. فرض کنید عامل از وضعیت اولیه در زمان $t = 0$ شروع کرده و به وضعیت نهایی در زمان T می‌رسد. در این صورت، بازده عامل به صورت زیر محاسبه می‌شود:

$$R(\tau) = r_0 + r_1 + r_2 + \dots + r_T$$

یا به شکل جمع:

$$R(\tau) = \sum_{t=0}^T r_t$$

بازده نشان‌دهنده مجموع پاداش‌هایی است که عامل در طول مسیر اپیزود دریافت می‌کند و معیاری برای سنجش عملکرد عامل در محیط است.

بنابراین می‌توان گفت که هدف عامل ما حداکثر کردن بازده (return) است، یعنی بیشینه کردن مجموع پاداش‌ها (پاداش تجمعی) که در طول یک اپیزود دریافت می‌کند.

بازده زمانی بیشینه می‌شود که در هر وضعیت، عمل صحیح انجام شود. با استفاده از سیاست بهینه (optimal policy) می‌توان عمل صحیح را در هر وضعیت انجام داد. بنابراین، با استفاده از سیاست بهینه می‌توان بازده را حداکثر کرد. به عبارت دیگر، سیاست بهینه سیاستی است که با انجام عمل صحیح در هر وضعیت، بیشترین بازده (مجموع پاداش‌ها) را به عامل می‌دهد.

اما چگونه می‌توان بازدهی که به سمت بینهایت جمع می‌شود را بیشینه کرد؟ برای این منظور، یک مفهوم جدید به نام عامل تنزیل γ (discount factor) معرفی می‌کنیم و بازده را به شکل زیر بازنویسی می‌کنیم:

$$R(\tau) = \gamma^0 r_0 + \gamma^1 r_1 + \gamma^2 r_2 + \dots + \gamma^t r_t + \dots = \sum_{t=0}^{\infty} \gamma^t r_t$$

چگونه عامل تنزیل γ به ما کمک می‌کند؟

عامل تنزیل باعث می‌شود بازده از رسیدن به بینهایت جلوگیری کند و تعیین می‌کند که چه میزان به پاداش‌های آینده نسبت به پاداش‌های فوری اهمیت داده شود. مقدار عامل تنزیل بین ۰ و ۱ قرار دارد:

- وقتی γ کوچک (نزدیک به ۰) باشد، به پاداش‌های فوری اهمیت بیشتری داده می‌شود و پاداش‌های آینده کمتر اهمیت دارند.
- وقتی γ بزرگ (نزدیک به ۱) باشد، به پاداش‌های آینده اهمیت بیشتری داده می‌شود و پاداش‌های فوری نسبتاً کم اهمیت‌تر هستند.

این مکانیزم به عامل اجازه می‌دهد تصمیمات بهینه‌ای بگیرد که تعادلی منطقی بین پاداش‌های فوری و آینده برقرار کند.

تابع ارزش (Value Function)

تابع ارزش، که به آن تابع ارزش وضعیت (**state value function**) نیز گفته می‌شود، ارزش یک وضعیت را نشان می‌دهد. ارزش یک وضعیت برابر با بازدهی است که یک عامل از آن وضعیت با پیروی از یک سیاست π به دست می‌آورد.

تابع ارزش معمولاً با $V(s)$ نمایش داده می‌شود و به شکل زیر تعریف می‌شود:

$$V^{\pi}(s) = \mathbb{E}[R(\tau) \mid s_0 = s]$$

که در آن $s_0 = s$ نشان می‌دهد وضعیت شروع، s است. ارزش یک وضعیت، ارزش وضعیت (**state value**) نامیده می‌شود و معیاری برای سنجش سودمندی یک وضعیت تحت یک سیاست مشخص است.

حال چگونه می‌توان ارزش تمام وضعیت‌ها در مسیر (**trajectory**) خود را محاسبه کرد؟ همان‌طور که آموختیم، ارزش یک وضعیت برابر است با بازده (مجموع پاداش‌ها) که عامل از آن وضعیت با پیروی از سیاست π به دست می‌آورد.

به طور خلاصه ارزش یک وضعیت برابر است با بازده مسیر شروع شده از آن وضعیت.

تابع Q (Q Function)

تابع **Q**، که به آن تابع ارزش وضعیت-عمل (**state-action value function**) نیز گفته می‌شود، ارزش یک جفت وضعیت-عمل را نشان می‌دهد. ارزش یک جفت وضعیت-عمل برابر است با بازدهی که عامل از وضعیت s شروع کرده و با انجام عمل a و پیروی از سیاست π به دست می‌آورد.

تابع **Q** معمولاً با $Q(s, a)$ نمایش داده می‌شود و به آن مقدار (**Q value**) یا ارزش وضعیت-عمل گفته می‌شود. فرمول آن به شکل زیر است:

$$Q^{\pi}(s, a) = \mathbb{E}[R(\tau) \mid s_0 = s, a_0 = a]$$

توجه داشته باشید که تنها تفاوت بین تابع ارزش (**value function**) و تابع **Q** این است که در تابع ارزش، ارزش یک وضعیت محاسبه می‌شود، در حالی که در تابع **Q**، ارزش یک جفت وضعیت-عمل محاسبه می‌شود.

یادگیری مبتنی بر مدل و بدون مدل (Model-based and Model-free) (Learning)

حال به دو نوع متفاوت از یادگیری در یادگیری تقویتی می‌پردازیم:

۱. یادگیری مبتنی بر مدل (Model-based Learning)

۲. یادگیری بدون مدل (Model-free Learning)

یادگیری مبتنی بر مدل (Model-based Learning)

در یادگیری مبتنی بر مدل، عامل دارای یک توصیف کامل از محیط است. همان‌طور که می‌دانیم، احتمال انتقال به ما می‌گوید که با انجام عمل a از وضعیت S به وضعیت بعدی S' با چه احتمالی منتقل می‌شویم و تابع پاداش مشخص می‌کند که هنگام انتقال از S به S' با انجام عمل a ، چه پاداشی دریافت می‌کنیم. وقتی عامل دینامیک مدل محیط خود، یعنی احتمال‌های انتقال و تابع پاداش، را بداند، این نوع یادگیری را یادگیری مبتنی بر مدل می‌نامیم. بنابراین، در یادگیری مبتنی بر مدل، عامل از دینامیک مدل برای یافتن سیاست بهینه استفاده می‌کند.

یادگیری بدون مدل (Model-free Learning)

در یادگیری بدون مدل، عامل هیچ اطلاعاتی درباره دینامیک مدل محیط ندارد. یعنی عامل بدون داشتن دانش از احتمال‌های انتقال یا تابع پاداش، تلاش می‌کند سیاست بهینه را پیدا کند.

انواع مختلف محیط‌ها (Different Types of Environments)

همان‌طور که در ابتدای بحث آموختیم، محیط دنیای عامل است و عامل درون آن زندگی یا فعالیت می‌کند. محیط‌ها را می‌توان به انواع مختلفی دسته‌بندی کرد.

محیط قطعی (Deterministic Environment)

در یک محیط قطعی، وقتی عامل عمل a را در وضعیت s انجام می‌دهد، کاملاً مطمئن هستیم که همیشه به وضعیت s' منتقل می‌شود. به عبارت دیگر، هیچ عدم قطعیتی در نتیجه اعمال عامل وجود ندارد و انتقال‌ها کاملاً پیش‌بینی‌پذیر هستند.

محیط تصادفی (Stochastic Environment)

در یک محیط تصادفی، نمی‌توان گفت که با انجام عمل a در وضعیت s ، عامل همیشه به وضعیت مشخصی منتقل می‌شود، زیرا یک عنصر تصادفی یا عدم قطعیت با محیط وجود دارد. به عبارت دیگر، نتیجه یک عمل ممکن است متفاوت باشد و انتقال‌ها با احتمالات مشخصی اتفاق می‌افتند.

محیط گسسته (Discrete Environment)

محیط گسسته، محیطی است که فضای عمل آن گسسته باشد. به عنوان مثال، در محیط شبکه‌ای (grid world)، فضای عمل شامل اعمال گسسته [بالا، پایین، چپ، راست] است، بنابراین این محیط گسسته محسوب می‌شود.

محیط پیوسته (Continuous Environment)

محیط پیوسته، محیطی است که فضای عمل آن پیوسته باشد. برای مثال، فرض کنید یک عامل را برای رانندگی خودرو آموزش می‌دهیم؛ در این حالت، فضای عمل شامل چندین عمل پیوسته مانند تغییر سرعت خودرو، زاویه چرخاندن فرمان و غیره است. در چنین محیطی، فضای عمل پیوسته است و محیط نیز پیوسته محسوب می‌شود.

محیط اپیزودی (Episodic Environment)

در یک محیط اپیزودی، عمل فعلی عامل بر اعمال آینده تأثیری ندارد و به همین دلیل به آن محیط غیر متوالی (non-sequential environment) نیز گفته می‌شود.

محیط غیر اپیزودی (Non-episodic Environment)


در یک محیط غیر اپیزودی، عمل فعلی عامل بر اعمال آینده تأثیر دارد و به همین دلیل به آن محیط متوالی

(**sequential environment**) نیز گفته می‌شود. به عنوان مثال، صفحه شطرنج یک محیط متوالی است، زیرا عمل فعلی بازیکن بر اعمال بعدی او در بازی تأثیر می‌گذارد.

محیط‌های تک‌عاملی و چندعاملی: (**Single and Multi-agent Environments**)

- محیط تک‌عاملی: (**Single-agent Environment**) زمانی که محیط فقط شامل یک عامل باشد، به آن محیط تک‌عاملی گفته می‌شود.
- محیط چندعاملی: (**Multi-agent Environment**) زمانی که محیط شامل چندین عامل باشد، به آن محیط چندعاملی گفته می‌شود.

در شکل زیر یک دسته بندی جامع از تمام الگوریتم های یادگیری تقویتی ارائه می شود.




مفاهیم پایه ای یادگیری عمیق

یادگیری عمیق، زیرمجموعه‌ای از یادگیری ماشین، با بهره‌گیری از شبکه‌های عصبی برای پردازش حجم عظیم داده‌ها، حوزه‌های مختلف را متحول کرده است. این بخش مفاهیم اساسی یادگیری عمیق را خلاصه می‌کند، از جمله نورون‌های بیولوژیکی و مصنوعی، شبکه‌های عصبی مصنوعی (ANNs)، شبکه‌های عصبی بازگشتی (RNNs)، شبکه‌های حافظه کوتاه‌مدت بلند (LSTM)، شبکه‌های عصبی کانولوشنی (CNNs) و شبکه‌های مولد تقابلی (GANs). بر اساس ادبیات موجود، این بخش پایه‌های نظری، اجزای معماری و مکانیسم‌های آموزش این مدل‌ها را بررسی می‌کند. تحلیل نشان می‌دهد که چگونه این مبانی عملکرد برتر در وظایفی مانند طبقه‌بندی، پیش‌بینی توالی و تولید داده را امکان‌پذیر می‌سازند.


الگوریتم‌های یادگیری عمیق به دلیل پیشرفت‌های محاسباتی و دسترسی به داده‌های زیاد، برجسته شده‌اند و در وظایف پیچیده از روش‌های سنتی پیشی می‌گیرند. این الگوریتم‌ها ریشه در ساختار سیستم‌های عصبی بیولوژیکی دارند و فرآیندهای عصبی را برای استخراج الگوها از داده‌ها شبیه‌سازی می‌کنند. فصل مربوط به مبانی یادگیری عمیق، کاوشی ساختاریافته ارائه می‌دهد که از واحدهای پایه آغاز می‌شود و به معماری‌های پیشرفته می‌رسد. این گزارش این عناصر را بررسی می‌کند و بر فرمول‌های ریاضی و کاربردهای عملی آن‌ها تأکید دارد.

نورون‌های بیولوژیکی و مصنوعی

نورون‌های بیولوژیکی واحدهای محاسباتی پایه مغز انسان هستند که ورودی‌ها را از طریق دندریت‌ها پردازش می‌کنند، سیگنال‌ها را در سوما یکپارچه می‌سازند و خروجی‌ها را از طریق آکسون‌ها منتقل می‌کنند. هر نورون ورودی‌های وزنی دریافت می‌کند که جمع شده و آستانه‌گذاری می‌شود تا پتانسیل عمل تولید شود.



نورون‌های مصنوعی این فرآیند را به صورت ریاضی شبیه‌سازی می‌کنند. یک نورون مصنوعی جمع وزنی ورودی‌ها به علاوه بایاس را محاسبه می‌کند و سپس تابع فعال‌سازی بر آن اعمال می‌شود.



$$\begin{aligned} z &= \sum x_i w_i + b \\ y &= f(z) \end{aligned}$$

که در آن x_i ورودی‌ها، w_i وزن‌ها، b بایاس و f تابع فعال‌سازی است. این مدل، الهام گرفته از کارهای اولیه بر روی پرسپترون‌ها، پایه شبکه‌های پیچیده‌تر را تشکیل می‌دهد.

شبکه‌های عصبی مصنوعی (ANNs) و لایه‌ها

ANNها نورون‌ها را در لایه‌ها سازماندهی می‌کنند: ورودی، پنهان و خروجی. لایه ورودی داده‌ها را دریافت می‌کند، لایه‌های پنهان ویژگی‌ها را استخراج می‌کنند و لایه خروجی پیش‌بینی‌ها را تولید می‌کند.

ANNs چندین لایه پنهان دارند که یادگیری ویژگی‌های سلسله‌مراتبی را امکان‌پذیر می‌سازد.


توابع فعال‌سازی غیرخطی بودن را معرفی می‌کنند:

- **سیگموئید**: تابع سیگموئید یکی از قدیمی‌ترین و پرکاربردترین توابع فعال‌سازی است که مقدار خروجی را به بازه $[0, 1]$ محدود می‌کند. این تابع به دلیل شکل **S** مانند خود، برای پیش‌بینی احتمال در مسائل طبقه‌بندی دودویی بسیار مناسب است.
- **تانژانت هذلولی**: تابع **tanh** نسخه مقیاس‌دار و متمرکز شده سیگموئید است که خروجی را در بازه $[-1, 1]$ قرار می‌دهد. به دلیل مرکزیت در صفر، گرادیان‌های متعادل‌تری تولید می‌کند و در لایه‌های پنهان شبکه‌های عمیق اولیه بسیار رایج بود.

- **ReLU** : واحد خطی یکسوسازی شده محبوب ترین تابع فعال سازی در شبکه های مدرن است که برای مقادیر مثبت خطی و برای مقادیر منفی صفر عمل می کند. این تابع به طور چشمگیری مشکل گرادیان ناپدیدشونده را کاهش داد و آموزش شبکه های بسیار عمیق را ممکن ساخت.
 - **Softmax**: تابع سافت مکس تعمیم سیگموئید برای مسائل چندکلاسه است. این تابع بردار ورودی را به یک توزیع احتمال نرمالایز شده تبدیل می کند به طوری که جمع احتمالات دقیقاً برابر ۱ شود. تقریباً در تمام لایه های خروجی مسائل طبقه بندی چندکلاسه استفاده می شود.
- انتشار روبه جلو خروجی ها را لایه به لایه با عملیات ماتریسی محاسبه می کند، در حالی که انتشار روبه عقب وزن ها را از طریق نزول گرادیان تنظیم می کند تا تابع هزینه ای مانند میانگین مربعات خطا کمینه شود.


شبکه های عصبی بازگشتی (RNNs) و LSTM

RNN ها داده های ترتیبی را با حفظ حالت پنهان مدیریت می کنند که وابستگی های زمانی را ثبت می کند.




حالت پنهان در زمان t به صورت $h_t = \tanh(Ux_t + Wh_{t-1})$ است که حفظ اطلاعات را امکان پذیر می سازد.

با این حال، **RNN** ها از گرادینان های ناپدیدشونده رنج می برند. این مشکل را با دروازه های ورودی، فراموشی و خروجی حل می کنند که جریان اطلاعات را تنظیم می کنند. حالت سلول حافظه بلندمدت را حفظ می کند و **LSTM** ها را برای وظایفی مانند مدل سازی زبان مؤثر می سازد.



شبکه های عصبی کانولوشنی (CNNs)

CNN ها در پردازش تصاویر برتر هستند و از لایه های کانولوشنی استفاده می کنند که فیلترها را برای استخراج ویژگی هایی مانند لبه ها اعمال می کنند. کانولوشن شامل لغزش هسته بر روی ماتریس ورودی و محاسبه محصولات نقطه ای است.




لایه های **pooling** ابعاد را کاهش می دهند؛ **pooling** حداکثری مقدار حداکثر را در پنجره انتخاب می کند و **invariance** را افزایش می دهد. لایه های تمام متصل سپس بر اساس ویژگی های استخراج شده طبقه بندی می کنند. **padding** و **stride** اندازه خروجی را کنترل می کنند و کارایی را بهبود می بخشند.

شبکه‌های مولد تقابلی (GANs)

GANها شامل ژنراتور و **discriminator** هستند که به صورت تقابلی آموزش می‌بینند. (Goodfellow et al., ۲۰۱۴)

ژنراتور داده‌ها را از نویز تولید می‌کند تا **discriminator** را فریب دهد، که ورودی‌ها را واقعی یا جعلی طبقه‌بندی می‌کند. تابع هزینه، فریب ژنراتور را کمینه و دقت **discriminator** را بیشینه می‌کند.



این بازی مین-مکس زمانی همگرا می‌شود که ژنراتور توزیع داده‌های واقعی را تکرار کند و کاربردهایی مانند سنتز تصاویر را امکان‌پذیر سازد.

نتیجه گیری

مبانی یادگیری عمیق از نورون‌های ساده تا معماری‌های پیچیده‌ای را شامل می‌شود که قادر به مدیریت انواع داده‌ها هستند. این مدل‌ها از طریق آموزش تکراری و بهینه‌سازی، هوش مصنوعی را متحول کرده‌اند. تحقیقات آینده ممکن است بر بهبود کارایی و حل محدودیت‌هایی مانند تفسیرپذیری تمرکز کند.

برای معرفی و تعریف الگوریتم **ppo** ابتدا از تعاریف اولیه آغاز خواهیم کرد.

مزیت روش‌های مبتنی بر سیاست (policy-based)

در رویکردهای مبتنی بر ارزش، سیاست به صورت غیرمستقیم و از طریق تابع **Q** به دست می‌آید. این روش زمانی با مشکل روبه‌رو می‌شود که فضای حالات یا اعمال بسیار بزرگ باشد، زیرا محاسبه **Q** برای همه حالت-عمل‌ها از نظر محاسباتی دشوار یا حتی غیرممکن است. حتی با استفاده از شبکه‌های عصبی مانند **DQN** نیز خروجی شبکه باید مقادیر **Q** همه اعمال را ارائه دهد و این موضوع در فضاهای بزرگ یا پیچیده به‌ویژه فضای عمل پیوسته، کارایی روش را کاهش می‌دهد. فضای عمل پیوسته در مسائل واقعی رایج است و گسسته‌سازی آن معمولاً باعث از دست رفتن اطلاعات یا افزایش بیش از حد تعداد اعمال می‌شود، بنابراین روش‌های مبتنی بر ارزش برای این نوع مسائل مناسب نیستند.

روش‌های مبتنی بر سیاست این محدودیت‌ها را برطرف می‌کنند، زیرا در آن‌ها سیاست به صورت مستقیم پارامتریزه شده و شبکه عصبی توزیع احتمال روی اعمال را تولید می‌کند. در این رویکرد دیگر نیازی به محاسبه تابع **Q** نیست. سیاست معمولاً تصادفی است و همین تصادفی بودن فرایند اکتشاف را بدون نیاز به سیاست‌هایی مانند **epsilon-greedy** پوشش می‌دهد. همچنین این رویکرد هم برای فضای عمل گسسته و هم برای فضای عمل پیوسته قابل استفاده است.

Policy Gradient به عنوان مهم‌ترین روش مبتنی بر سیاست معرفی می‌شود. در این روش سیاست با پارامترهای θ نمایش داده می‌شود و هدف بیشینه‌سازی بازده مورد انتظار کل مسیرهایی است که بر اساس این سیاست طی می‌شوند. شبکه عصبی سیاست احتمال انتخاب هر عمل را در هر حالت تولید می‌کند. از آنجا که داده برچسب‌خورده در اختیار نیست، یادگیری با جمع‌آوری اپیزودهای تعامل با محیط انجام می‌شود. اگر یک مسیر بازده مثبت داشته باشد، احتمال اعمالی که در طول آن مسیر انتخاب شده‌اند افزایش می‌یابد و اگر بازده منفی باشد، احتمال آن‌ها کاهش پیدا می‌کند. این تغییرات از طریق محاسبه گرادیان لگاریتم احتمال اعمال انتخاب‌شده و ضرب آن در بازده مسیر انجام می‌شود. در نهایت پارامترهای شبکه با صعود گرادیانی به‌روزرسانی می‌شوند. تقریب گرادیان با نمونه‌گیری چندین مسیر و محاسبه میانگین گرادیان‌ها در تمامی حالت‌ها و زمان‌ها صورت می‌گیرد. هدف این است که شبکه سیاستی بیاموزد که به صورت متوسط مسیرهایی با بازده بالاتر تولید کند.

در جمع‌بندی، **Policy Gradient** روشی است که بدون نیاز به تابع ارزش، سیاست را مستقیماً یاد می‌گیرد، با فضاهای عمل پیچیده و پیوسته سازگار است، فرآیند اکتشاف را به صورت طبیعی فراهم می‌کند و زیربنای بسیاری از الگوریتم‌های پیشرفته یادگیری تقویتی مانند **REINFORCE**، **A2C**، **PPO** و **DDPG** است.

روشی actor critic

روش بازیگر-نقدکننده (**Actor-Critic**) یکی از الگوریتم‌های پرکاربرد در یادگیری تقویتی عمیق است که ترکیبی از مزایای روش‌های مبتنی بر سیاست و مبتنی بر ارزش محسوب می‌شود. این روش از دو شبکه اصلی تشکیل شده است:

شبکه بازیگر (**Actor**) که مسئول پیدا کردن سیاست بهینه است و با استفاده از گرادیان سیاست پارامترهای خود را به‌روزرسانی می‌کند.

شبکه نقدکننده (**Critic**) که وظیفه ارزیابی سیاست تولیدشده توسط بازیگر را دارد و ارزش حالت‌ها (**State Value**) را تخمین می‌زند. بازخورد شبکه نقدکننده به بازیگر کمک می‌کند تا سیاست خود را به صورت تدریجی و آنلاین بهبود دهد.

ویژگی کلیدی روش بازیگر-نقدکننده این است که پارامترهای هر دو شبکه در هر گام از اپیزود به‌روزرسانی می‌شوند، نه فقط پس از پایان اپیزود کامل مانند روش **REINFORCE** با خط پایه. این قابلیت باعث می‌شود یادگیری سریع‌تر و کاراتر باشد و امکان استفاده از تخمین بوت‌استرپی (**Bootstrapped Return**) برای بازده فراهم شود، به جای انتظار برای بازده کامل مسیر.

شبکه نقدکننده با محاسبه تفاوت بین ارزش هدف حالت و ارزش پیش‌بینی شده توسط خود، خطای خود را اندازه‌گیری می‌کند و سپس با گرادیان نزولی پارامترهای خود را به‌روزرسانی می‌کند. شبکه بازیگر نیز با استفاده از این بازخورد، پارامترهایش را برای بهبود سیاست به‌روزرسانی می‌کند.

در یادگیری تقویتی عمیق، الگوریتم‌های مبتنی بر گرادیان سیاست نقش محوری دارند و پیشرفت‌های متعددی برای بهبود ثبات و کارایی آن‌ها ایجاد شده است. روش **Actor-Critic** با ترکیب دو شبکه بازیگر و نقدکننده، امکان یادگیری آنلاین و تدریجی سیاست بهینه را فراهم می‌کند و با استفاده از بازخورد شبکه نقدکننده، واریانس گرادیان کاهش می‌یابد و سیاست بهبود می‌یابد.

بهینه‌سازی سیاست با ناحیه اعتماد – Trust Region Policy Optimization (TRPO)

TRPO یکی از الگوریتم‌های پرکاربرد در یادگیری تقویتی عمیق است و در واقع یک الگوریتم گرادیان سیاست (Policy Gradient) محسوب می‌شود که بهبود یافته روش گرادیان سیاست با خط پایه است. همان‌طور که در فصل قبل دیدیم، گرادیان سیاست یک روش **on-policy** است؛ یعنی در هر تکرار، ما سیاست فعلی خود را بهبود می‌دهیم و از همان سیاست برای تولید مسیرها (**trajectories**) استفاده می‌کنیم.

در روش گرادیان سیاست، پارامترهای شبکه با قانون به‌روزرسانی زیر به‌روزرسانی می‌شوند:

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta)$$

که در آن $\nabla_{\theta} J(\theta)$ گرادیان سیاست و α نرخ یادگیری یا **step size** است. اگر نرخ یادگیری زیاد باشد، تغییرات سیاست بزرگ خواهد بود و اگر کم باشد، تغییرات کوچک خواهند بود. انتخاب اندازه بهینه گام اهمیت زیادی دارد.

مشکل بزرگ بودن گام:

اگر در هر تکرار، تغییرات پارامترها زیاد باشد، تفاوت بین سیاست قدیمی و جدید زیاد خواهد شد. این موضوع می‌تواند باعث مدل کلاپس (**model collapse**) شود، زیرا پارامترهای سیاست قدیمی و جدید به شدت متفاوت می‌شوند. به همین دلیل در گرادیان سیاست معمولاً گام‌ها کوچک انتخاب می‌شوند تا تغییرات سیاست کنترل شود، اما این باعث یادگیری کند می‌شود.

TRPO این مشکل را با اعمال یک محدودیت (**constraint**) حل می‌کند که تضمین می‌کند سیاست جدید و قدیمی نباید بیش از حد متفاوت باشند، حتی وقتی می‌خواهیم یک به‌روزرسانی بزرگ انجام دهیم. برای اندازه‌گیری تفاوت سیاست‌ها از تفاوت (**Kullback-Leibler (KL Divergence)**) استفاده می‌کنیم **KL Divergence** نشان می‌دهد که دو توزیع احتمال تا چه اندازه با هم تفاوت دارند.

در TRPO، محدودیت این است که **KL Divergence** بین سیاست قدیمی و جدید باید کمتر یا مساوی یک مقدار ثابت δ باشد. این محدودیت به نام محدودیت ناحیه اعتماد (**Trust Region Constraint**) شناخته می‌شود. بنابراین، TRPO تلاش می‌کند تغییرات سیاست بزرگ باشد ولی در عین حال پارامترهای سیاست جدید و قدیمی در ناحیه اعتماد باقی بمانند.

مزیت اصلی **TRPO** این است که تضمین بهبود مونوتونیک سیاست (**Monotonic Policy**) دارد؛ یعنی در هر تکرار، سیاست بهبود می‌یابد بدون اینکه مدل ناپایدار شود.

بهینه‌سازی سیاست نزدیک (Proximal Policy Optimization – PPO)

Proximal Policy Optimization (PPO) یک الگوریتم یادگیری تقویتی مبتنی بر گرادیان سیاست است که به‌طور گسترده برای آموزش عامل‌های هوشمند در محیط‌های با فضای عمل گسسته یا پیوسته استفاده می‌شود. این الگوریتم مستقیماً پارامترهای سیاست عامل را به‌روزرسانی می‌کند تا عامل بیشترین پاداش تجمعی را دریافت کند و به همین دلیل به دسته الگوریتم‌های **policy gradient** تعلق دارد. در حقیقت، **PPO** را می‌توان به‌عنوان نسخه‌ای بهبود یافته و پایدار از روش‌های **policy gradient** کلاسیک در نظر گرفت که محدودیت‌های بزرگی در به‌روزرسانی سیاست ایجاد نمی‌کند و از ناپایداری در آموزش جلوگیری می‌کند.

PPO یکی از پیشرفته‌ترین الگوریتم‌های گرادیان سیاست است که بر **TRPO** بهبود یافته و سادگی و کارایی بیشتری دارد. مشابه **TRPO**، **PPO** نیز تضمین می‌کند که به‌روزرسانی‌های سیاست در ناحیه اعتماد باقی بمانند، اما برخلاف **TRPO**، از محدودیت‌های صریح در تابع هدف استفاده نمی‌کند.

PPO با طراحی هوشمندانه تابع هدف و مکانیزم کلیپینگ (**clipping**) یا دیگر تکنیک‌ها، امکان انجام به‌روزرسانی‌های بزرگ بدون خروج سیاست جدید از ناحیه اعتماد را فراهم می‌کند، در حالی که اجرای آن بسیار ساده‌تر و سریع‌تر از **TRPO** است. این ویژگی‌ها باعث شده **PPO** به یکی از الگوریتم‌های اصلی یادگیری تقویتی مدرن تبدیل شود.

PPO معمولاً در قالب یک چارچوب **actor-critic** پیاده‌سازی می‌شود. در این چارچوب، **actor** همان شبکه سیاست است که مسئول انتخاب عمل بر اساس حالت فعلی است و **critic** همان تابع ارزش است که ارزش هر حالت را تخمین می‌زند و به **actor** کمک می‌کند تا با استفاده از این بازخورد، سیاست خود را بهبود دهد. به این ترتیب، **PPO** از ترکیب مزایای **policy gradient** و **actor-critic** استفاده می‌کند: با استفاده از **actor**، سیاست به‌طور مستقیم بهینه می‌شود و با استفاده از **critic**، تخمین‌های پایدارتری از ارزش حالت‌ها برای کاهش واریانس گرادیان‌ها فراهم می‌شود.

مکانیزم اصلی **PPO** بر پایه تابع هدف جانشین (**surrogate objective**) با محدودسازی تغییرات سیاست است. برای هر نمونه جمع‌آوری شده از محیط، نسبت احتمال اجرای عمل توسط سیاست جدید نسبت به سیاست قدیمی محاسبه می‌شود:

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{old}}(a_t | s_t)}$$

سپس با استفاده از مکانیزم **clipping**، اگر این نسبت از بازه $[1 - \epsilon, 1 + \epsilon]$ خارج شود، مقدار اضافی کنار گذاشته می‌شود تا سیاست جدید از سیاست قدیم فاصله زیادی نگیرد. این کار از به‌روزرسانی‌های بسیار بزرگ و ناپایدار جلوگیری می‌کند و باعث می‌شود یادگیری هم پایدار و هم مؤثر باشد.

دو نوع الگوریتم **PPO** وجود دارد که در ذیل توضیح داده شده است:

PPO شامل دو نسخه اصلی است که هر کدام مکانیزمی برای حفظ به‌روزرسانی‌های سیاست در ناحیه اعتماد (**Trust Region**) دارند:

PPO-clipped

در این روش، برای اطمینان از اینکه سیاست جدید از سیاست قدیمی خیلی فاصله نگیرد، از یک تابع **clipping** استفاده می‌شود. این تابع محدود می‌کند که نسبت تغییرات سیاست در هر به‌روزرسانی از یک محدوده مشخص فراتر نرود، بنابراین سیاست جدید و قدیمی همیشه نزدیک به هم باقی می‌مانند.

PPO-penalty

در این روش، به جای محدودیت مستقیم، عبارت **KL constraint** به یک جریمه (**penalty**) در تابع هدف تبدیل می‌شود. ضریب جریمه به‌صورت تطبیقی در طول آموزش به‌روزرسانی می‌شود تا تضمین شود که به‌روزرسانی‌های سیاست در ناحیه اعتماد باقی می‌مانند.

هر دو روش هدف یکسانی دارند: حفظ پایداری و سرعت یادگیری با جلوگیری از تغییرات بیش از حد سیاست در هر به‌روزرسانی، اما مکانیزم اعمال محدودیت در آن‌ها متفاوت است.

فرآیند آموزش در **PPO** شامل جمع‌آوری تجربیات با سیاست فعلی، محاسبه مزیت عملکرد (**advantage**) برای هر عمل و انجام چند مرحله گرادیان با استفاده از **minibatch** ها روی تابع هدف **clipped** است. برخلاف الگوریتم‌هایی مانند **TRPO**، **PPO** نیازی به محاسبات پیچیده دوم‌مرحله‌ای (مثل هسین یا گرادیان مزدوج) ندارد و اجرای آن ساده و سریع است.

مزیت‌های اصلی **PPO** شامل پایداری بالا، قابلیت اجرا در فضای عمل پیوسته و گسسته، کارایی مناسب نسبت به داده‌ها و سهولت پیاده‌سازی است. با این حال، انتخاب دقیق ابرپارامترها (مانند ϵ برای **clipping**)، نرخ

یادگیری و اندازه (batch) برای عملکرد بهینه ضروری است و چون PPO یک الگوریتم on-policy است، معمولاً فقط می‌تواند از داده‌هایی که با سیاست فعلی تولید شده‌اند استفاده کند.

در مجموع، PPO یک روش قدرتمند، پایدار و کارآمد برای یادگیری تقویتی است که با حفظ تعادل بین بهبود سیاست و ثبات یادگیری، و با استفاده از چارچوب actor-critic و اصول policy gradient، در بسیاری از کاربردها از کنترل ربات‌ها تا آموزش عامل‌های بازی و مدل‌های زبانی بزرگ به‌طور گسترده استفاده می‌شود.

معرفی epanet

درک نشت تنها با مشاهده اثرات هیدرولیکی این رویدادها در سراسر شبکه توزیع آب (WDN) از طریق تحلیل هیدرولیکی امکان‌پذیر است. مدل‌های هیدرولیکی شبکه توزیع آب اغلب برای این منظور ایجاد می‌شوند و از نرم‌افزارهایی استفاده می‌کنند که از سیستم‌های شبکه برق مشتق شده‌اند (والسکی، ۲۰۰۳). این مدل‌ها با ترکیب داده‌های جغرافیایی مانند ارتفاع و نقشه‌های شبکه، داده‌های ذاتی شبکه مانند اطلاعات لوله‌ها (قطر، طول، زبری) و اجزای شبکه، داده‌های عملیاتی مانند سرعت پمپ‌ها و تنظیمات شیرها، و داده‌های مشتری مانند الگوهای تقاضا ساخته می‌شوند تا ویژگی‌های هیدرولیکی شبکه توزیع آب شبیه‌سازی شود. این اطلاعات در ابتدا از نقشه‌های سیستم به دست می‌آید، اما در سال‌های اخیر سیستم اطلاعات جغرافیایی (GIS) محبوب‌ترین گزینه بوده است. مدل GIS لایه‌های موضوعی داده‌ها را به صورت جغرافیایی به یکدیگر متصل می‌کند تا روابط بین داده‌ها مشخص شود. بنابراین، می‌تواند تحلیل‌های پرس‌وجو و آماری را با مزایای جغرافیایی ارائه‌شده توسط نقشه‌ها ترکیب کند (ESRI، ۲۰۲۳). داده‌های عملیاتی می‌توانند از سیستم‌های SCADA (کنترل و جمع‌آوری داده‌های نظارتی) در سیستم‌های کنترل تأسیسات آب استخراج شوند. در نهایت، داده‌ها همچنین از سیستم‌های اطلاعات مشتری (CIS) جمع‌آوری می‌شوند تا الگوی تقاضای مشتری اندازه‌گیری یا پیش‌بینی شود. داده‌ها از شبکه‌های آزمایشی در جامعه تحقیقاتی و شرکت آب Northumbrian Water جمع‌آوری شد تا مدل‌های هیدرولیکی برای آزمایش‌ها توسعه یابند.


ابزارهای نرم‌افزاری هیدرولیکی به‌راحتی در میان تأسیسات آب و جامعه تحقیقاتی در دسترس هستند و نسخه‌های رایگان و تجاری از آن‌ها موجود است. برخی از حل‌کننده‌های هیدرولیکی می‌توانند جریان‌های چندفازی با خواص هیدرولیکی متفاوت را شبیه‌سازی کنند، اما این پژوهش تنها به مدلسازی جریان آب (تک‌فازی) می‌پردازد. علاوه بر این، چندین نرم‌افزار تجاری شامل ماژول تشخیص نشت داخلی هستند که با استفاده از استراتژی‌های بهینه‌سازی، نشت‌ها را شناسایی می‌کنند.

نرم‌افزار **EPANET** یکی از پرکاربردترین ابزارهای شبیه‌سازی شبکه‌های توزیع آب (**Water Distribution Networks – WDN**) است که توسط آژانس حفاظت محیط زیست ایالات متحده (**EPA**) توسعه یافته و امکان تحلیل هیدرولیکی و کیفیتی شبکه‌های آب را فراهم می‌کند (راسمن، ۲۰۰۰). این نرم‌افزار قادر است جریان آب تحت فشار، هد (**Head**) و فشار در نقاط مختلف شبکه، سرعت جریان در لوله‌ها و عملکرد تجهیزات شبکه مانند پمپ‌ها و شیرها را شبیه‌سازی کند. علاوه بر تحلیل هیدرولیکی، **EPANET** قابلیت مدل‌سازی کیفیت آب را نیز دارد، از جمله انتشار مواد شیمیایی مانند کلر و محاسبه زمان ماند آب در شبکه، که برای تضمین کیفیت آب و مدیریت ایمنی شبکه حیاتی است (راسمن، ۲۰۰۰).

ساختار مدل‌سازی در **EPANET** شامل اجزای اصلی شبکه از جمله گره‌ها (**Nodes**) که مصرف‌کننده‌ها، مخازن و منابع آب را نمایش می‌دهند، لوله‌ها (**Pipes**) با مشخصات هندسی و هیدرولیکی، پمپ‌ها (**Pumps**)، شیرها (**Valves**) و مخازن و مخازن مرتفع (**Reservoirs & Tanks**) است. این اجزا با استفاده از داده‌های هندسی، هیدرولیکی و عملیاتی شبکه برای شبیه‌سازی رفتار واقعی جریان آب و کیفیت آن ترکیب می‌شوند (والسکی و همکاران، ۲۰۰۳).

EPANET امکان شبیه‌سازی زمانی (**Time-Based Simulation**) را فراهم می‌کند که با آن می‌توان تغییرات جریان و فشار شبکه را در طول زمان با توجه به تقاضای مصرف‌کنندگان و تغییرات عملیاتی پمپ‌ها و شیرها پیش‌بینی کرد. علاوه بر این، این نرم‌افزار از رابط‌های برنامه‌نویسی (**APIs**) پشتیبانی می‌کند که امکان ارتباط با زبان‌های برنامه‌نویسی مانند پایتون را برای اتوماسیون فرآیندهای تحلیلی و توسعه ابزارهای سفارشی

فراهم می‌کند (راسمن، ۲۰۰۰).



مزایای **EPANET** شامل رایگان بودن، قابلیت استفاده در پروژه‌های تحقیقاتی و صنعتی، مستندسازی گسترده و توانایی توسعه ابزارهای اختصاصی است. با این حال، محدودیت‌هایی نیز دارد؛ از جمله اینکه شبیه‌سازی جریان‌های چندفازی یا رفتار غیرعادی جریان‌ها در شبکه محدود است و برای دقت بالا نیازمند داده‌های دقیق شبکه است (والسکی و همکاران، ۲۰۰۳). به طور کلی، **EPANET** به‌عنوان یک ابزار استاندارد در مهندسی آب و مدیریت شبکه‌های توزیع، امکان تحلیل جامع هیدرولیکی و کیفیتی را فراهم می‌کند و یکی از محبوب‌ترین نرم‌افزارها در تحقیقات و صنعت آب به شمار می‌رود.

برای اهداف این پژوهش، استفاده از حل‌کننده هیدرولیکی معیار **EPANET** ضروری است، زیرا این نرم‌افزار هم در تحقیقات و هم در صنعت به‌طور گسترده مورد استفاده قرار می‌گیرد و آن را به گزینه‌ای مناسب تبدیل می‌کند. علاوه بر این، وجود رابط‌های برنامه‌نویسی کاربردی (**API**) بین **EPANET** و زبان پایتون، ارتباط بین محیط سفارشی و نرم‌افزار **EPANET** را تسهیل می‌کند.

متدولوژی مرور ادبیات

مرور ادبیات این پژوهش با هدف شناسایی، گردآوری و سازمان‌دهی مطالعات پیشین مرتبط با کنترل فشار، نشت و شبکه‌های توزیع آب و نیز بررسی رویکردهای مدل‌سازی و محاسباتی مورد استفاده در این حوزه انجام شده است. با توجه به ماهیت گزارش سمینار کارشناسی ارشد و تمرکز آن بر تبیین مسیر پژوهش، رویکرد مرور ادبیات از نوع مرور روایتی هدفمند انتخاب شد. این رویکرد امکان تمرکز بر مطالعات مرتبط و کلیدی را بدون الزام به اجرای یک مرور نظام‌مند کامل فراهم می‌کند.

فرآیند مرور ادبیات به صورت ترکیبی و چندمرحله‌ای انجام شد. در مرحله نخست، جستجوی منابع علمی به صورت دستی در منابع فارسی و انگلیسی انجام گرفت. این جستجو شامل بررسی مقالات ژورنالی، مقالات کنفرانسی، گزارش‌های فنی و پایان‌نامه‌های مرتبط با شبکه‌های توزیع آب بود. منابع از وبسایت‌ها و پایگاه‌های علمی مختلف گردآوری شدند تا پوشش مناسبی از ادبیات موجود فراهم شود.

منابع مورد بررسی در این پژوهش شامل مقالات علمی به زبان انگلیسی، مقالات فارسی معتبر منتشر شده در مجلات علمی-پژوهشی، و پایان‌نامه‌های معتبر دانشگاهی به هر دو زبان انگلیسی و فارسی بوده است.

در مجموع، ۵۲ منبع مورد مطالعه و تحلیل قرار گرفت.

بازه زمانی منابع، از مطالعات پایه و کلاسیک تا منابع معاصر را دربرمی‌گیرد، با تأکید ویژه بر منابعی که در پنج سال اخیر (۲۰۲۵-۲۰۲۰) منتشر شده‌اند.

برای جستجوی منابع، مجموعه‌ای از کلیدواژه‌های تخصصی در دو زبان فارسی و انگلیسی مورد استفاده قرار گرفت. کلیدواژه‌های انگلیسی شامل **Pressure Management**، **Water Distribution Network**، **Leakage Reduction**، **Smart Water Systems**، **Reinforcement Learning** و **Deep** بودند.

همچنین، کلیدواژه‌های فارسی نظیر «کنترل فشار آب»، «شبکه توزیع آب» و «نشت آب» برای شناسایی منابع داخلی به کار گرفته شدند. در فرآیند جستجو، ابتدا عناوین و چکیده منابع بررسی شد و در صورت ارتباط موضوعی، متن کامل آن‌ها برای مطالعه دقیق‌تر انتخاب گردید.

برخی از مقالات که در بررسی اولیه نیمه مرتبط بودند هم بایگانی شدند تا دقیق‌تر بررسی شوند.


در مرحله دوم، به منظور افزایش دقت و کارایی فرآیند مرور، از ابزارهای مبتنی بر هوش مصنوعی به عنوان ابزار کمکی در مطالعه و بررسی مقالات استفاده شد. این ابزارها برای انجام فعالیت‌هایی نظیر مرور سریع متون، خلاصه‌سازی محتوای مقالات و استخراج مفاهیم و موضوعات اصلی به کار گرفته شدند. استفاده از هوش

مصنوعی صرفاً در نقش ابزار پشتیبان تحلیلی بوده و تصمیم‌گیری نهایی در خصوص انتخاب، حذف و دسته‌بندی منابع توسط پژوهشگر انجام شده است.

پس از گردآوری اولیه منابع، فرآیند پالایش مطالعات بر اساس میزان ارتباط آن‌ها با اهداف پژوهش صورت گرفت. مقالاتی که به‌طور مستقیم به موضوع کنترل فشار، نشت، شبکه‌های توزیع آب یا مدل‌سازی هیدرولیکی با استفاده از **EPANET** پرداخته بودند، در فرآیند مرور باقی ماندند. سایر منابع که ارتباط مستقیمی با موضوع پژوهش نداشتند یا صرفاً جنبه توصیفی داشتند، کنار گذاشته شدند.

در مرحله پایانی، منابع منتخب به‌صورت سازمان‌یافته ثبت و برای استفاده در فصل مرور ادبیات دسته‌بندی شدند. این دسته‌بندی بر اساس محورهای کلی پژوهش و بدون ورود به تحلیل نتایج مطالعات انجام گرفت و صرفاً با هدف ساختاردهی به ادبیات موجود و فراهم‌سازی زمینه لازم برای تدوین مبانی نظری و چارچوب پژوهش صورت پذیرفت.

پایگاه های اینترنتی مقالات	آدرس الکترونیکی
arxiv	https://arxiv.org
ieeexplore	https://ieeexplore.ieee.org
sciencedirect	https://www.sciencedirect.com
researchgates	https://www.researchgate.net
scispace	https://scispace.com/
سیویلیکا	https://civilica.com/
sid	https://www.sid.ir/



پیشینه پژوهشی کنترل فشار

تحلیل مرسوم سامانه‌های توزیع آب، که به‌عنوان تحلیل مبتنی بر تقاضا (**DDA**) شناخته می‌شود، بر پایه فرض بنیادی‌ای قرار دارد: در همه گره‌های شبکه، تقاضای موردنیاز همواره به‌طور کامل تأمین می‌شود؛ بدون توجه به فشار هیدرولیکی موجود.

این ساده‌سازی در شرایط نرمال قابل قبول است، اما در هنگام وقوع کمبود فشار (در اثر خرابی اجزاء، افزایش تقاضا یا تنش‌های دیگر)، عملکرد واقعی شبکه را منعکس نمی‌کند. در این شرایط، **DDA** ممکن است فشار منفی یا تأمین کامل تقاضا را هم‌زمان نشان دهد که با واقعیت فیزیکی شبکه در تضاد است.

برای رفع این نقیصه، تحلیل وابسته به فشار (**PDA**) جریان واقعی گره را تابعی از فشار موجود در گره در نظر می‌گیرد و شبیه‌سازی واقعی‌تری ارائه می‌دهد. اهمیت راهبردی **PDA** بسیار زیاد است، زیرا مبنای ارزیابی دقیق‌تر در حوزه‌هایی همچون پایش قابلیت اطمینان سیستم، تحلیل آسیب‌پذیری، مدیریت نشت، کالیبراسیون پارامترها و بهینه‌سازی چندهدفه می‌باشد (عبدی سید، گوپتا و تانیمبو، ۲۰۱۵).

در شبکه‌های توزیع آب، مدیریت فشار یکی از عناصر بنیادی بهره‌برداری به شمار می‌رود و روش‌های گوناگونی برای کنترل آن توسعه یافته‌اند؛ روش‌هایی که از کنترل ساده و کلاسیک آغاز شده و تا سامانه‌های پیشرفته، بلادرنگ و مبتنی بر هوش مصنوعی امروزی گسترش یافته‌اند.

در پایه‌ای‌ترین سطح، کنترل کلاسیک (**Classical Control**) قرار دارد که اغلب با بهره‌گیری از کنترل‌کننده‌های تناسبی یا تناسبی-انتگرالی-مشتقی (**P** و **PID**) اجرا می‌شود. در این روش، فشار در یک نقطه شبکه اندازه‌گیری و بر اساس اختلاف آن با مقدار مرجع، میزان باز یا بسته بودن شیر کاهش فشار (**PRV**) تنظیم می‌شود. اگر فشار بیش از حد افزایش یابد، شیر بسته‌تر و اگر کاهش یابد، بازتر می‌شود تا فشار به مقدار مطلوب برسد. این روش ساده، کم‌هزینه و اجرایی است، اما تنها قادر به تنظیم یک متغیر در یک نقطه مشخص بوده و برای شبکه‌های گسترده با نواحی متعدد فشار کارایی محدودی دارد (موسیتل، حمام، دو و موناچلی، ۲۰۲۰). با افزایش پیچیدگی شبکه‌ها، محدودیت‌های کنترل کلاسیک آشکار شد و نیاز به رویکردهایی ایجاد گردید که بتوانند چندین متغیر را به‌صورت هم‌زمان مدیریت کنند؛ این موضوع زمینه‌ساز توسعه کنترل‌های پیشرفته (**Advanced Control**) شد. روش‌هایی نظیر کنترل پیش‌بین مدل (**MPC**) و منطق فازی (**Fuzzy Logic**) در این دسته قرار می‌گیرند. در **MPC**، رفتار آینده شبکه با کمک یک مدل ریاضی پیش‌بینی

شده و تنظیمات بهینه پیش از وقوع اختلال اعمال می‌شود. مهم‌ترین نقطه قوت این روش مدیریت هم‌زمان چند پارامتر مانند فشار، دبی و انرژی است، اما دقت عملکرد آن کاملاً به صحت مدل ریاضی وابسته است و هر اختلاف میان مدل و شرایط واقعی باعث افت کیفیت کنترل می‌شود.

در مرحله بعد، رویکرد کنترل بهینه (**Optimal Control**) مطرح شد. در این روش، مسئله کنترل به صورت یک مسئله ریاضی مانند برنامه‌ریزی غیرخطی (**NLP**) یا آمیخته (**MINLP**) تعریف می‌شود و هدف معمولاً کمینه‌سازی فشار یا نشت در کل شبکه است. برای حل این مسائل از الگوریتم‌های ریاضی یا فراابتکاری مانند الگوریتم ژنتیک استفاده می‌شود. هرچند این روش از نظر تئوری بهترین پاسخ ممکن را فراهم می‌کند، اما به دلیل محاسبات سنگین، برای کنترل بلادرنگ یا شبکه‌های بسیار بزرگ مناسب نیست.

با پیشرفت فناوری‌های اندازه‌گیری و ارتباطات، کنترل بلادرنگ (**Real-Time Control**) توسعه یافت. این رویکرد بر پایه داده‌های لحظه‌ای حاصل از سامانه‌هایی مانند **SCADA** عمل می‌کند. در این حالت، اطلاعات فشار، دبی و الگوهای مصرف به‌طور پیوسته جمع‌آوری شده و دستورات کنترلی بی‌درنگ به تجهیزات ارسال می‌شود. این توانایی، واکنش سریع به تغییرات واقعی شبکه (تفاوت مصرف در روز و شب) را امکان‌پذیر می‌سازد، اما به زیرساخت سخت‌افزاری و نرم‌افزاری پیشرفته و ارتباطات مطمئن و بلادرنگ نیاز دارد.

تازه‌ترین و پیشرفته‌ترین نسل کنترل، کنترل بدون مدل (**Model-Free Control**) است. در این رویکرد از معادلات فیزیکی پیچیده استفاده نمی‌شود؛ بلکه سیستم با تکیه بر داده‌های واقعی و ابزارهای هوش مصنوعی مانند شبکه‌های عصبی، الگوی مناسب واکنش به تغییرات فشار را یاد می‌گیرد. این روش شبیه یک سامانه یادگیرنده عمل می‌کند که با تجربه، تصمیم‌های بهتر و سازگارتر اتخاذ می‌کند. انعطاف‌پذیری و سرعت واکنش بالا از مزایای اصلی این روش است، اما برای آموزش به داده‌های حجیم نیاز دارد و در صورت تغییر ساختار شبکه، باید مجدداً آموزش ببیند.

در مجموع، مسیر تکامل روش‌های کنترل فشار نشان می‌دهد که کنترل کلاسیک بر واکنش مستقیم استوار است، کنترل پیشرفته و بهینه بر مدل‌سازی ریاضی و پیش‌بینی تکیه دارد، کنترل بلادرنگ با داده‌های واقعی سازگار می‌شود و کنترل بدون مدل با بهره‌گیری از هوش مصنوعی بدون نیاز به مدل فیزیکی دقیق به صورت تطبیقی عمل می‌کند. هدف نهایی، دستیابی به سامانه‌هایی هوشمند، خودتنظیم و مقاوم در برابر تغییرات شبکه است (موسّتل، حامام، دو و موناچلی، ۲۰۲۰).

در یک نگاه انتقادی به روش‌های موجود کنترل فشار، چند چالش اساسی به چشم می‌خورد. نخست، تعادل میان دقت و هزینه محاسباتی است. بسیاری از روش‌های پیشرفته برای کاهش بار محاسباتی مجبور به

خطی‌سازی معادلات غیرخطی هستند و این کار بخشی از دقت را قربانی می‌کند؛ بنابراین همیشه نوعی سازش میان سرعت و صحت وجود دارد. چالش دوم، نبود ارزیابی تحت عدم قطعیت است.

اغلب مدل‌ها در شبیه‌سازی‌هایی با الگوهای تقاضای ثابت آزمایش می‌شوند، در حالی که مصرف واقعی آب پیوسته و به شدت متغیر است؛ بنابراین پایداری سامانه در شرایط واقعی به طور کامل مشخص نیست. چالش سوم، ناهمخوانی مدل با واقعیت (**Model Mismatch**) است. فرسودگی لوله‌ها، تغییر زبری، رسوب‌گذاری و سایر عوامل سبب می‌شوند که مدل ریاضی با شرایط واقعی فاصله بگیرد و این اختلاف عملکرد کنترل مبتنی بر مدل را کاهش می‌دهد.

برای پشت‌سر گذاشتن این چالش‌ها، سه مسیر پژوهشی مهم پیشنهاد شده است. نخست، در نظر گرفتن عدم قطعیت تقاضا در مدل‌های کنترلی است؛ به جای استفاده از داده‌های قطعی، مدل‌های احتمالاتی می‌توانند پایداری بیشتری در برابر نوسانات ایجاد کنند. دوم، کاربرد امولاتورها یا شبیه‌سازهای داده‌محور است که با کمک شبکه‌های عصبی عمیق رفتار هیدرولیکی شبکه را بازتولید می‌کنند و امکان شبیه‌سازی و بهینه‌سازی بسیار سریع را فراهم می‌سازند. سوم، کنترل مبتنی بر یادگیری تقویتی (**Reinforcement Learning**) است؛ روشی که بدون نیاز به مدل دقیق، با تعامل با شبکه بهترین اقدام را یاد می‌گیرد و در صورت تغییر شرایط فیزیکی، سیاست کنترلی خود را تطبیق می‌دهد.

در نهایت، رویکردهای نوین نشان می‌دهند که آینده کنترل فشار در شبکه‌های توزیع آب به تلفیق مهندسی هیدرولیک با یادگیری ماشین و تحلیل عدم قطعیت وابسته است تا سامانه‌هایی هوشمند، تطبیق‌پذیر و مقاوم در برابر تغییرات محیطی و فیزیکی طراحی شوند.

تکنیک	استراتژی	ملاحظات	محدودیت‌ها	کاربردها	نوع تکنیک
کنترل کلاسیک	بر اساس کنترل تک‌پارامتری (روشن‌خاموش) یا کنترل‌کننده‌های PID.	پایده‌سازی آن ساده است.	با این حال، برای سامانه‌های شبکه توزیع آب (WDN) در مقیاس بزرگ مناسب نیست.	مناسب برای سیستم‌های کوچک مقیاس با کنترل یک پارامتر در هر زمان.	مدل محور فیزیکی
کنترل پیشرفته	یک مدل برای تقلید رفتار سیستم مورد نیاز است. بر اساس دانش پیشین از الزامات موجود در سیستم، این کنترل‌کننده‌ها متغیر کنترل شده را	پایده‌سازی آن دشوار است و دقت مدل تعیین‌کننده دقت نتایج خواهد بود.	دشواری در پایده‌سازی.	مناسب برای شبکه‌های بزرگ مقیاس.	مدل محور فیزیکی

				تنظیم می کنند تا خطا میان مقدار مرجع و مقدار مورد نیاز کاهش یابد.	
مدل محور فیزیکی	برای شبکه های بزرگ مقیاس مناسب است.	منابع محاسباتی، تعداد متغیرهای کنترلی را در کاربردهای دارای محدودیت زمانی محدود می کنند.	نیازمندی های محاسباتی این دسته از روش ها بسیار سنگین بوده است. بنابراین، این روش ممکن است برای کاربردهای بلندرنگ ایدئال نباشد.	بر پایه اصول حساب دیفرانسیل و انتگرال، بهترین پارامترهای عملیاتی انتخاب می شوند. این پارامترها ممکن است تحت قیود مختلف یا بدون هیچ قیدی انتخاب شوند.	کنترل بهینه
مدل محور فیزیکی	می تواند در هر سیستمی که زیرساخت بلندرنگ در آن موجود است استفاده شود.	قوانین کنترلی قابل اعمال محدود به توان پردازشی موجود هستند.	سرمایه گذاری قابل توجهی برای به کار انداختن این سیستم ها مورد نیاز است.	بر اساس اندازه گیری هایی که به صورت بلندرنگ از طریق SCADA یا سایر کاربردها به دست می آیند، قانون کنترلی اعمال می شود و دستورهای لازم برای تنظیم تولید می گردد.	کنترل بلندرنگ
داده محور	مناسب برای شبکه ای با تغییرات حداقلی در طراحی توپولوژیکی است.	در انطباق دادن شبیه ساز یادشده با تغییر توپولوژی شبکه، چالش هایی وجود دارد.	برای دستیابی به یک شبیه ساز دقیق، مجموعه داده آموزشی بزرگی مورد نیاز است.	بر پایه استفاده از شبیه سازها برای تقلید مدل قانون کنترلی انتخاب شده است.	کنترل بدون مدل

ارزیابی کاستی های روش های سنتی بهینه سازی

این بخش مرور ادبیاتی، یک تحلیل انتقادی از تکامل تکنیک های بهینه سازی در مدیریت شبکه های توزیع آب (WDS) ارائه می دهد. روند پیشرفت روش ها از الگوریتم های سنتی و متاهیوریستیک ها، که پایه بسیاری از رویکردهای پیشرفته امروزی هستند، تا چارچوب های نوین مبتنی بر داده و یادگیری ماشین ردیابی می شود. هدف این بررسی، روشن کردن نقاط قوت و محدودیت هر دسته از روش ها و برجسته کردن مسیر تحول به سمت رویکردهایی است که بار محاسباتی را کاهش داده و امکان کنترل بلندرنگ را فراهم می کنند.

رویکردهای بهینه سازی سنتی و متاهیوریستیک

بسیاری از تلاش های اولیه و حتی بخش قابل توجهی از رویکردهای پیشرفته کنونی در بهینه سازی عملکرد WDS ها بر الگوریتم های متعارف و روش های متاهیوریستیک تکیه دارند. این روش ها در حل مسائل پیچیده

برنامه‌ریزی و کنترل اثربخشی قابل توجهی دارند، اما چالش‌های اصلی آن‌ها عمدتاً به شدت محاسباتی بالا مربوط می‌شود و کاربرد آن‌ها در سناریوهای زمان واقعی و شبکه‌های بزرگ محدود است (هَگگاتو و همکاران، ۲۰۲۰).

برنامه‌ریزی پویا (DP)

برنامه‌ریزی پویا به دلیل توانایی در یافتن بهینه‌های جهانی، به ویژه برای مسائل با تعداد متغیر کم، برای برنامه‌ریزی پمپ‌ها در **WDS** ها استفاده شده است. نسخه‌های تکراری **DP** برای مقابله با «نفرین ابعاد» در سیستم‌های بزرگ توسعه یافته‌اند. با این حال محدودیت‌های زیر همچنان وجود دارد:

- نفرین ابعاد **DP**: در مقیاس‌بندی به شبکه‌های بزرگ با چندین متغیر به سرعت غیرقابل مدیریت می‌شود.
- محدودیت محذب بودن: کاربرد **DP** اغلب به مسائل با توابع هدف محذب محدود است و ممکن است همه سناریوهای عملیاتی را پوشش ندهد.
- هزینه محاسباتی بالا: حتی نسخه‌های مدرن **DP** به محاسبات گسترده نیاز دارند و برای بسیاری از کاربردهای عملی پرهزینه‌اند.

روش‌های متاهوریستیک و هیپرهیوریستیک

متاهوریستیک‌ها، مانند الگوریتم تکامل تفاضلی (**DE**)، بهینه‌سازی ازدحام ذرات (**PSO**) و روش نلدر-مید، قدرت بالایی در یافتن بهینه‌های جهانی دارند. روش‌های هیپرهیوریستیک، با بهینه‌سازی خودکار پارامترهای الگوریتم، توانسته‌اند همگرایی را بهبود دهند. اما عیب اصلی این رویکردها بار محاسباتی بسیار بالا و نیاز به ارزیابی‌های هیدرولیکی مکرر است که اغلب امکان کاربرد مستقیم در **WDS** های واقعی را محدود می‌کند. الگوریتم‌های مبتنی بر روش‌های ابتکاری (**Heuristic**)، مانند الگوریتم ژنتیک و کلونی مورچه‌ها، در این حوزه مورد مطالعه قرار گرفته‌اند اما محدودیت‌های عملی مهمی دارند. ضعف‌های اصلی این رویکردها شامل موارد زیر است:

- تنظیم پیچیده پارامترها: عملکرد مؤثر این الگوریتم‌ها وابسته به تنظیمات دقیق پارامترهای داخلی است. این حساسیت موجب می‌شود که استفاده از آن‌ها در محیط‌هایی با تغییرات سریع و شرایط نامطمئن دشوار باشد.
- وابستگی به اطلاعات دقیق درباره منبع آلودگی: بسیاری از مدل‌های سنتی مستلزم دانستن اطلاعات جزئی مانند محل دقیق، زمان تزریق و حجم آلاینده هستند. تعیین این اطلاعات در شرایط اضطراری زمان‌بر است و با ماهیت واکنش سریع موردنیاز در تضاد قرار می‌گیرد (هو، کای، زنگ، یان، گانگ و وانگ، ۲۰۲۰).
- عملکرد ضعیف در شرایط عدم قطعیت: این روش‌ها عمدتاً برای محیط‌های قطعی طراحی شده‌اند. در مواجهه با نوسانات مصرف، داده‌های ناقص حسگرها یا تغییرات ناگهانی، دقت و پایداری آن‌ها به‌طور محسوسی کاهش می‌یابد.

استراتژی‌های کاهش بار محاسباتی

برای کاهش محدودیت‌های محاسباتی روش‌های سنتی، محققان دو مسیر اصلی را دنبال کرده‌اند: ساده‌سازی مدل‌های هیدرولیکی یا به‌کارگیری چارچوب‌های کنترل پیشرفته.

مدل‌های جایگزین و هیبریدی

مدل‌های جایگزین، به عنوان تقریب ارزان‌تر از شبیه‌سازی‌های کامل، زمان ارزیابی الگوریتم‌های بهینه‌سازی را کاهش می‌دهند. استفاده از شبکه‌های عصبی مصنوعی (ANN) یا مدل‌های هیبریدی که داده‌های حسگر زنده را با شبیه‌سازی ترکیب می‌کنند، امکان کاهش هزینه محاسباتی بدون از دست دادن دقت قابل توجه را فراهم می‌کند.

چارچوب‌های کنترل پیشرفته

کنترل پیش‌بینی مدل (MPC) با تقسیم مسئله به افق‌های زمانی کوچک، توانایی مدیریت WDS های بزرگ را در زمان واقعی فراهم می‌کند. همچنین روش‌هایی مانند برنامه‌ریزی تکراری گسترش‌یافته لکسیکوگرافیک (iELGP) در مدیریت متغیرهای پیوسته، مانند سرعت پمپ‌ها یا میزان تزریق کلر، عملکرد بهینه در مسائل پیچیده را تضمین می‌کنند. این چارچوب‌ها زمینه را برای استفاده از یادگیری ماشین فراهم می‌کنند.

یادگیری ماشین و بهینه‌سازی WDS ها

ورود یادگیری ماشین، به ویژه یادگیری تقویتی، تغییر پارادایمی در بهینه‌سازی WDS ها ایجاد کرده است. به جای تکیه بر شبیه‌سازی‌های پرهزینه، این روش‌ها از داده‌ها برای یادگیری سیاست‌های کنترل بهینه استفاده می‌کنند و مسیر جدیدی به سمت کنترل بلادرنگ و خودکار باز می‌کنند.

کاربردهای اولیه یادگیری تقویتی

- کنترل سوئیچینگ پمپ‌ها: استفاده از عامل RL مبتنی بر ANN برای روشن/خاموش کردن پمپ‌ها بر اساس سطوح مخزن و تقاضای سیستم.
 - کنترل مخازن: عملکرد قابل مقایسه با برنامه‌ریزی پویا تصادفی.
 - بهینه‌سازی چندمنظوره: استفاده از تکرار قائم مناسب (FQI) برای مدیریت اهداف متغیر و نامطمئن.
- با وجود این موفقیت‌ها، این روش‌ها همچنان به شبیه‌سازی WDS برای آموزش وابسته بودند و مشکل گلوگاه محاسباتی را حل نکردند.

یادگیری تقویتی عمیق (DRL) برای کنترل بلادرنگ

استفاده از عامل‌های DRL، مانند Dueling Deep Q-Network (DDQN)، امکان کنترل زمان واقعی بدون نیاز به شبیه‌سازی‌های هیدرولیکی را فراهم می‌کند. عامل پس از آموزش قادر است با استفاده از داده‌های زنده، اقدامات بهینه را انجام دهد. ویژگی‌های کلیدی این رویکرد عبارتند از:

- کاهش شدید نیاز به ارزیابی مدل هیدرولیکی.
 - توانایی یادگیری سیاست‌های کنترلی نو و بالقوه بهتر.
 - عملکرد سریع‌تر و مؤثرتر نسبت به روش‌های سنتی مانند نلدر-مید.
- این پیشرفت، نقطه عطفی در تکامل بهینه‌سازی WDS ها به شمار می‌رود و مسیر روشن به سمت هوش عملیاتی مبتنی بر داده‌ها را نشان می‌دهد.
- انتخاب رویکرد محاسباتی مناسب برای مدیریت شرایط اضطراری در شبکه‌های توزیع آب یک تصمیم راهبردی و حساس است. هرچند در سال‌های گذشته از الگوریتم‌های بهینه‌سازی سنتی برای زمان‌بندی شیرها و

هیدرانت‌ها استفاده شده است، اما ماهیت ذاتی این روش‌ها اغلب با ویژگی‌های پویا، غیرقطعی و زمان‌حساس رویدادهای واقعی هم‌خوانی ندارد.

جدول زیر رویکردهای بهینه‌سازی اصلی را در مقابل هم قرار می‌دهد و ویژگی‌های کلیدی شناسایی شده از ادبیات را خلاصه می‌کند.

روشناسی دسته	نقطه قوت اصلی	محدودیت کلیدی	وابستگی به داده
برنامه‌ریزی پویا	بهینه جهانی را برای مسائل کوچک فراهم می‌کند	"لعنت ابعاد"؛ محدود به مسائل محدب	نیاز به مدل هیدرولیکی برای انتقال‌های حالت دارد.
فراابتکاری‌ها	در یافتن بهینه‌های نزدیک به جهانی برای مسائل پیچیده قوی است	بار محاسباتی بالا از ارزیابی‌های هیدرولیکی	نیاز به مدل هیدرولیکی برای ارزیابی راه‌حل دارد.
کنترل پیشرفته (MPC/iELGP)	کنترل زمان واقعی را برای سیستم‌های در مقیاس بزرگ امکان‌پذیر می‌سازد	وابسته به توسعه و دقت مدل‌های پیش‌بینی	نیاز به مدل پیش‌بینی و داده‌های عملیاتی زنده دارد.
یادگیری تقویتی عمیق (DRL)	کنترل زمان واقعی و بدون شبیه‌سازی در حین عملیات	نیاز به آموزش گسترده با استفاده از داده‌های تاریخی یا شبیه‌سازی، اغلب هدایت‌شده توسط الگوریتم بهینه‌سازی مرجع	نیاز به داده‌های اندازه‌گیری زنده برای عملیات زمان واقعی دارد.

در مقابل، یادگیری تقویتی عمیق (DRL) پارادایم کاملاً متفاوتی ارائه می‌دهد. موفقیت این رویکرد در حل مسائل پیچیده تصمیم‌گیری و زمان‌بندی (نظیر سیستم‌های بازی AlphaGo) ظرفیت بالای آن برای مدیریت شبکه‌های توزیع آب را نشان می‌دهد. برخلاف روش‌های بهینه‌سازی ایستا، DRL به عامل اجازه می‌دهد از طریق تعامل مستمر با محیط، سیاست کنترلی بهینه را یاد بگیرد. این ویژگی موجب می‌شود DRL از نظر ذاتی برای محیط‌های پویا، نامطمئن و زمان‌حساس مناسب‌تر باشد. این گذار از محاسبات ایستا به یادگیری پویا، مبنای اصلی چارچوب پیشنهادی است (هَگگاتو و همکاران، ۲۰۲۰).

پیشینه ادبیاتی کنترل نشت

زندگی روی زمین بدون آب امکان‌پذیر نیست، چرا که آب یکی از نیازهای اساسی برای بقا و ادامه حیات تمام موجودات روی سیاره به شمار می‌آید. این موضوع بدون شک دلیل اصلی است که زمین تنها سیاره شناخته‌شده برای حمایت از حیات است. در سطح جهانی، کمبود آب به دلایلی همچون برداشت بیش از حد، رشد جمعیت و

تغییرات آب و هوایی رخ می‌دهد. این کمبود تأمین نیازهای آب بخش‌های صنعتی، جوامع انسانی و فعالیت‌های کشاورزی را با چالش مواجه می‌کند (یونیسف، ۲۰۲۵).

آب با کیفیت بالا برای سلامت انسان و توسعه اقتصادی اهمیت حیاتی دارد. به طوری که در سراسر جهان، دو میلیارد نفر به آب آشامیدنی دسترسی ندارند و ۳.۶ میلیارد نفر فاقد امکانات بهداشتی مدیریت‌شده هستند (یونسکو، ۲۰۲۳). پیش‌بینی‌ها نشان می‌دهد که تا سال ۲۰۵۰، مناطق شهری ۶۸ درصد از جمعیت جهان را در خود جای خواهند داد (یوان-واتر، ۲۰۲۵).

یکی از مسائل عمده مرتبط با کمبود آب، وقوع نشتی‌ها در شبکه‌های توزیع آب (WDNs) است که می‌تواند منجر به هدررفت قابل توجه آب شود، به‌ویژه در مناطق شهری که تقریباً ۳۰ درصد از کل مصرف آب به دلیل نشتی‌ها از بین می‌رود (علی و همکاران، ۲۰۲۲). در انگلستان و ولز، روزانه تقریباً ۲.۵ میلیارد لیتر آب به دلیل نشتی از دست می‌رود (کریس، ۲۰۲۰).

آب غیردرآمدی (NRW) به آبی اشاره دارد که تولید می‌شود اما به مصرف‌کننده نمی‌رسد و شامل زیان‌های واقعی (مانند نشتی‌ها) و زیان‌های ظاهری (مانند سرقت یا خطاهای کنتور) است (فراه و شهرور، ۲۰۲۴؛ هیرنر و لامبرت، ۲۰۰۰؛ ال-واشالی و همکاران، ۲۰۱۶).

نشتی عامل اصلی NRW محسوب می‌شود و اغلب در اتصالات، شیرها و خطوط خدمات به دلیل فرسودگی لوله‌ها، نصب ضعیف، شرایط خاک، نوسانات فشار و تنش‌های خارجی رخ می‌دهد (جوزف و همکاران، ۲۰۲۲؛ نگم و همکاران، ۲۰۲۳). این زیان‌ها فشار بیشتری بر منابع آب شیرین وارد می‌کنند که پیش‌تر تحت تأثیر استفاده بیش از حد و تغییرات آب و هوایی قرار گرفته‌اند.

مدیریت نشتی یک فرآیند جامع است که شامل سه مؤلفه اصلی می‌شود: ارزیابی، تشخیص و پیشگیری (گوپتا و کولات، ۲۰۱۸).

ارزیابی به کمی‌سازی زیان‌ها با استفاده از روش‌هایی مانند جریان حداقل شبانه (MNF) و مدل تخمین انفجار و زمینه (BACE) می‌پردازد. استراتژی‌های تشخیص از بازرسی دستی تا سیستم‌های مبتنی بر حسگر و مدل‌های داده‌محور متغیر هستند. پیشگیری بر کنترل پیشگیرانه فشار و بهینه‌سازی سیستم تمرکز دارد (فراه و شهرور، ۲۰۲۴؛ نگم و همکاران، ۲۰۲۳؛ سرافیم و همکاران، ۲۰۲۴؛ گائو و همکاران، ۲۰۲۲). روش‌های متداول ممکن است نشتی‌ها را تنها پس از بروز زیان قابل توجه تشخیص دهند، قادر به مدیریت شبکه‌های پیچیده و نامطمئن در زمان واقعی نباشند یا با مشکلاتی در مقیاس‌پذیری، هزینه و سازگاری با شرایط متغیر مواجه شوند (فراه و

شهرور، ۲۰۲۴؛ جوزف و همکاران، ۲۰۲۲؛ نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۰؛ یوسف و هو، ۲۰۲۲).

این مسئله نیازمند رویکردهای پویا و هوشمندی است که توانایی عمل در شرایط عدم قطعیت را داشته باشند (نگم و همکاران، ۲۰۲۴). در سال‌های اخیر، ادغام هوش مصنوعی (AI) و یادگیری ماشین (ML) در پرداختن به چالش‌های شبکه‌های توزیع آب نویدبخش بوده است (مایکل و همکاران، ۲۰۲۴). در این میان، یادگیری تقویتی عمیق (DRL) به‌عنوان رویکردی ویژه برجسته شده است که قابلیت‌های یادگیری عمیق را با چارچوب تصمیم‌گیری یادگیری تقویتی ترکیب می‌کند تا مشکلات کنترل پویای پیچیده را حل کند.

DRL نشان داده است که قادر به مدیریت مسائل غیرخطی پیچیده است و نتایج موافقی در زمینه‌هایی مانند رباتیک، سیستم‌های کنترل و زیرساخت‌های هوشمند به دست آورده است (نگم و همکاران، ۲۰۲۴؛ بلغادیل و همکاران، ۲۰۲۳). همچنین از DRL برای بهینه‌سازی WDN‌ها و پیشگیری از نشتی استفاده شده است (نگم و همکاران، ۲۰۲۴؛ پاروازه و همکاران، ۲۰۲۳؛ ماونگ‌کانگ و همکاران، ۲۰۲۳؛ نگم و همکاران، ۲۰۲۳). این روش می‌تواند عملیات‌هایی مانند کنترل شیر، زمان‌بندی پمپ و نگهداری لوله را با هدف پیشگیری از نشتی‌ها در حالی که کارایی کلی سیستم را افزایش می‌دهد، بهینه کند (بلغادیل و همکاران، ۲۰۲۳؛ نگم و همکاران، ۲۰۲۳؛ هُجگاتو و همکاران، ۲۰۲۰؛ هو و همکاران، ۲۰۲۳؛ پاتل و همکاران، ۲۰۲۳).

با وجود اثربخشی DRL در بهینه‌سازی عملیات WDN، کاربرد خاص آن در تشخیص و پیشگیری از نشتی هنوز کمتر بررسی شده است که فرصت ارزشمندی برای تحقیقات آینده ایجاد می‌کند. با وجود کاربرد فزاینده AI و ML در سیستم‌های آب، هنوز بررسی متمرکزی وجود ندارد که نشان دهد چگونه DRL می‌تواند مدیریت نشتی در شبکه‌های توزیع آب را بهبود دهد. بیشتر بررسی‌های موجود، از جمله (نگم و همکاران، ۲۰۲۴)، چالش‌ها و فرصت‌های گسترده DRL در سیستم‌های آب شهری را مورد بحث قرار داده‌اند، اما بررسی ساختاریافته‌ای متمرکز صرفاً بر مدیریت نشتی ارائه نکرده‌اند.

مدیریت نشتی در شبکه‌های توزیع آب

مدیریت و کاهش نشتی‌ها برای استفاده پایدار از منابع آب و بهبود کارایی اقتصادی اهمیت حیاتی دارد. نشتی در شبکه‌های توزیع آب (WDNs) ناشی از ترکیبی از عوامل داخلی و خارجی است (القحطانی و همکاران، ۲۰۲۰). عوامل داخلی شامل پیری و فرسودگی اجزای زیرساخت می‌شوند که خستگی مواد، خوردگی و نگهداری ناکافی این مشکل را تشدید می‌کنند. عوامل خارجی شامل شرایط محیطی مانند جابجایی خاک و لرزش‌ها

هستند که شبکه را تحت تنش قرار می‌دهند. شرایط هیدرولیکی، مانند افزایش ناگهانی فشار، می‌تواند شکاف‌ها را گسترش دهد، در حالی که فعالیت‌های ساختمانی ممکن است به لوله‌ها آسیب وارد کند (فراه و شهرور، ۲۰۲۴؛ نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۳؛ کورلاپاتی و همکاران، ۲۰۲۲).

سیاست مؤسسه چارترد مدیریت آب و محیط زیست (CIWEM) بیان می‌کند که مدیریت ناکارآمد فشار و عدم کنترل فعال نشتی می‌تواند میزان نشتی در WDN‌ها را افزایش دهد. فشارهای بالا می‌تواند شکاف‌های موجود را گسترش دهد و تغییرات دما ممکن است باعث انبساط یا انقباض لوله‌ها شود که منجر به شکست‌های مکرر می‌گردد (فراه و شهرور، ۲۰۲۴؛ گائو و همکاران، ۲۰۲۲).

نگم و همکاران (۲۰۲۳)، گوپتا و کولات (۲۰۱۸) و لامبرت (۱۹۹۴) نشتی‌ها را به دو دسته طبقه‌بندی کرده‌اند: نشتی‌های گزارش‌شده که آسان برای شناسایی هستند و نشتی‌های گزارش‌نشده که دشوارترند. نشتی‌های گزارش‌نشده عمدتاً زیرزمینی و با جریان متوسط رخ می‌دهند و منبع اصلی هدررفت آب به شمار می‌آیند (لامبرت، ۱۹۹۴؛ فارلی و تراو، ۲۰۰۵). این نشتی‌ها شامل انواع انفجاری و زمینه‌ای هستند؛ نشتی‌های زمینه‌ای جریان‌های کوچک و مداوم از لوله‌های فرسوده هستند که تشخیص آن‌ها دشوار است، در حالی که نشتی‌های انفجاری رهاسازی ناگهانی و با حجم بالا دارند و نیاز به تعمیر فوری دارند (نگم و همکاران، ۲۰۲۳؛ لامبرت، ۱۹۹۴؛ چان و همکاران، ۲۰۱۹؛ آددجی و همکاران، ۲۰۱۷).

لامبرت و موریسون (۱۹۹۶) بیان کرده‌اند که نشتی‌های زمینه‌ای جریان‌های کوچک ($> 0.5 \text{ m}^3/\text{h}$) دارند و تعمیر آن‌ها از نظر اقتصادی مقرون به صرفه نیست، در حالی که نشتی‌های انفجاری جریان‌های بزرگ‌تر ($< 0.5 \text{ m}^3/\text{h}$) با مدت زمان‌های مختلف دارند.

برای مدیریت نشتی، شرکت‌های آب از رویکرد ساختاریافته‌ای استفاده می‌کنند که شامل سه مرحله ارزیابی، تشخیص و پیشگیری است. ارزیابی نشتی، زیان‌های آب را کمی‌سازی کرده و بین زیان‌های واقعی و ظاهری تمایز قائل می‌شود (آددجی و همکاران، ۲۰۱۷؛ یو و همکاران، ۲۰۲۱؛ بهاگات و همکاران، ۲۰۱۹؛ آمواتی و همکاران، ۲۰۱۸).

تشخیص شامل سه مرحله شناسایی، مکان‌یابی و دقیق‌سازی (ILP) است (ال-واشالی و همکاران، ۲۰۱۶؛ نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۰؛ همیلتون، ۲۰۰۹). در مرحله شناسایی، سیگنال‌های نشتی از سایر سیگنال‌های شبکه تمایز داده می‌شوند، در حالی که مکان‌یابی، نشتی را به یک ناحیه کلی مانند ناحیه اندازه‌گیری منطقه‌ای (DMA) محدود می‌کند. دقیق‌سازی مکان دقیق نشتی را تا حدود ۲۰ سانتی‌متر تعیین

می‌کند که جایگزین مرحله مکان‌یابی ۳۰ سانتی‌متری قبلی شده است (نگم و همکاران، ۲۰۲۳؛ الزهَب و زاید، ۲۰۱۹).

مرحله نهایی، پیشگیری، بر کاهش نشتی‌های آینده از طریق مداخلاتی مانند مدیریت فشار، زمان‌بندی پمپ، ارتقای لوله‌ها و استراتژی‌های نگهداری تمرکز دارد تا تاب‌آوری شبکه افزایش یافته و کنترل پایدار نشتی ممکن شود (نگم و همکاران، ۲۰۲۳؛ گوپتا و کولات، ۲۰۱۸؛ گائو و همکاران، ۲۰۲۲؛ زمان و همکاران، ۲۰۲۰؛ برموز و همکاران، ۲۰۲۲).

روش‌های ارزیابی نشتی

ارزیابی نشتی عموماً در دو مرحله انجام می‌شود: رویکرد بالا به پایین و رویکرد پایین به بالا (ال-واشالی و همکاران، ۲۰۱۶؛ گوپتا و کولات، ۲۰۱۸؛ ال-واشالی و همکاران، ۲۰۱۸).

رویکرد بالا به پایین ساده‌ترین روش است و با محاسبه آب غیردرآمدی (NRW) بر اساس برکه تعادل آب IWA آغاز می‌شود (ال-واشالی و همکاران، ۲۰۱۶؛ گوپتا و کولات، ۲۰۱۸؛ ال-واشالی و همکاران، ۲۰۱۸). NRW با کسر مصرف مجاز فاکتور شده (BAC) از حجم ورودی سیستم (SIV) تعیین می‌شود (یو و همکاران، ۲۰۲۱؛ فراه و شهرور، ۲۰۱۷). این مقدار سپس به زیان‌های ظاهری (AL) و زیان‌های واقعی (RL) تقسیم می‌گردد. زیان‌های ظاهری معمولاً ناشی از خطاهای کنتورها، اشتباهات فاکتورگیری یا مصرف غیرمجاز هستند، در حالی که زیان‌های واقعی مربوط به نشتی‌های فیزیکی شبکه است. با استفاده از فرضیات آگاهانه یا داده‌های میدانی، حجم AL ابتدا تخمین زده شده و سپس RL به‌عنوان بخش باقی‌مانده NRW محاسبه می‌شود. این رویکرد نمایی کلی و سطح بالا ارائه می‌دهد و به حداقل تحقیقات میدانی نیاز دارد، اما وابستگی بالایی به کیفیت داده‌های ورودی و فرضیات دارد.

پس از رویکرد بالا به پایین، رویکرد پایین به بالا برای ارزیابی دقیق‌تر نشتی در ناحیه اندازه‌گیری منطقه‌ای (DMA) انتخاب شده اعمال می‌شود. یکی از روش‌های پرکاربرد، تحلیل جریان حداقل شبانه (MNF) است که با اندازه‌گیری جریان در ساعات کم‌مصرف (معمولاً بین ۲ تا ۴ صبح) و کسر مصرف مشروع مورد انتظار، میزان نشتی را تخمین می‌زند (ال-واشالی و همکاران، ۲۰۱۶؛ گوپتا و کولات، ۲۰۱۸؛ ال-واشالی و همکاران، ۲۰۱۸؛ فراه و شهرور، ۲۰۱۷؛ ال-واشالی و همکاران، ۲۰۲۰).

روش تخمین انفجار و زمینه (BABE) زیان‌ها را بر اساس روندهای جریان به نشتی‌های انفجاری کوتاه‌مدت و نشتی‌های زمینه‌ای بلندمدت تجزیه می‌کند (لامبرت، ۱۹۹۴). رویکرد دیگری، تعادل آب-فاضلاب، زیان‌های ظاهری را با مقایسه داده‌های تأمین با خروجی‌های فاضلاب تخمین زده و استفاده خارجی و نفوذ را نیز لحاظ می‌کند (گوپتا و کولات، ۲۰۱۸؛ بهاگات و همکاران، ۲۰۱۹؛ ال-واشالی و همکاران، ۲۰۱۸؛ آمواتی و همکاران، ۲۰۱۸).

اگرچه تکنیک‌های پایین به بالا دقت فضایی و زمانی بالاتری ارائه می‌دهند، اما نیازمند ابزارآلات بیشتر و تلاش میدانی گسترده هستند. پس از کمی‌سازی زیان‌ها، شرکت‌های آب قادر خواهند بود به مرحله مکان‌یابی و تشخیص پیش بروند تا منابع دقیق زیان‌های واقعی در سیستم شناسایی شوند.

روش‌های تشخیص نشتی

در ادبیات، تکنیک‌های تشخیص نشتی عموماً به دو دسته اصلی تقسیم می‌شوند: روش‌های مبتنی بر سخت‌افزار و روش‌های مبتنی بر نرم‌افزار. معیار طبقه‌بندی روش‌های مبتنی بر سخت‌افزار بر اساس ویژگی‌های دستگاه‌های مورد استفاده است، در حالی که روش‌های مبتنی بر نرم‌افزار بر اساس رویکردهای مدل‌محور و داده‌محور دسته‌بندی می‌شوند. یک سیستم طبقه‌بندی سلسله‌مراتبی دقیق برای روش‌های تشخیص نشتی در منابعی مانند (نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۰) ارائه شده است.

روش‌های تشخیص نشتی مبتنی بر سخت‌افزار

تکنیک‌های مبتنی بر سخت‌افزار برای شناسایی نشتی‌ها در شبکه‌های توزیع آب نقش حیاتی دارند. این روش‌ها از حسگرها و فناوری‌های مختلف برای تشخیص نشتی استفاده کرده و داده‌های زمان واقعی برای پاسخ سریع فراهم می‌کنند. نمونه‌هایی از این فناوری‌ها شامل دستگاه‌های روباتیک داخل لوله و حسگرهای خارج لوله مانند دستگاه‌های صوتی، رادار، مادون قرمز و سامانه‌های سنجش از دور هستند (یوسف و هو، ۲۰۲۲؛ نکمنی و همکاران، ۲۰۲۰).

جدول زیر روش‌های مبتنی بر سخت‌افزار بررسی شده در ادبیات را با اصول کاری، کاربردها، مزایا و معایب آن‌ها خلاصه می‌کند، در حالی که شکل ۶ چندین روش مبتنی بر سخت‌افزار یافت‌شده در ادبیات را نشان می‌دهد.

روش	اصل	کاربردها	مزایا	معایب	مرجع
انتشار صوتی	تشخیص نشتی‌ها با گوش دادن به صداهای خاص داخل لوله از طریق ابزارهایی مانند هیدروفون‌ها، چوب‌های گوش دادن، شتاب‌سنج‌ها و همبستگی‌کننده‌ها. ترکیب میکروفون‌ها یا همبستگی‌کننده‌ها برای مکان‌یابی دقیق نشتی.	تشخیص نشتی در سیستم‌های تحت فشار.	تشخیص زمان واقعی نشتی‌ها.	مناسب برای نشتی‌های بزرگ نیست.	(نگم و همکاران، ۲۰۲۳؛ یوسف و هو، ۲۰۲۲)
فیبر نوری	تشخیص تغییرات در دما، فشار یا کرنش در دیواره‌های لوله.	نظارت بر خطوط لوله برای نشتی.	نظارت همزمان بر فشار و دما. پوشش کیلومترها از خط لوله در ساعت‌ها. تحمل شرایط سخت.	نصب گران‌قیمت. فقط در خطوط لوله خطی قابل استفاده.	(یوسف و هو، ۲۰۲۲؛ اسلام و همکاران، ۲۰۲۲)
امواج فشار منفی	تشخیص نشتی‌ها با اندازه‌گیری افت ناگهانی فشار، با استفاده از حسگرها برای مکان‌یابی کارآمد نشتی‌ها.	تشخیص نشتی در خطوط لوله.	دقت بالا و قابلیت مکان‌یابی نشتی‌ها.	دقت به جنس لوله، قطر و پیچیدگی شبکه وابسته است.	(فرح و شهرور، ۲۰۲۴)
تلویزیون مدار بسته (CCTV)	استفاده از دوربین‌ها برای تشخیص نشتی‌ها.	بازرسی خطوط لوله.	مشاهده مستقیم وضعیت لوله.	زمان‌بر و بسیار پرهزینه. سطح پایینی از قابلیت اطمینان.	(یوسف و هو، ۲۰۲۲)
رادار نفوذ زمین (GPR)	استفاده از امواج رادیویی برای تصویربرداری زیرسطحی و تشخیص بازتاب‌ها، شناسایی شکاف‌های خاک برای مکان‌یابی نشتی‌های لوله.	تشخیص نشتی در لوله‌های مدفون.	قابلیت تشخیص نشتی در بیشتر لوله‌ها از طریق تصاویر با وضوح بالا.	عمق نفوذ با نوع خاک متفاوت است. نیاز به اپراتور با تجربه و هزینه عملیاتی بالا.	(یوسف و هو، ۲۰۲۲؛ القحطانی و همکاران، ۲۰۲۰)
ترموگرافی مادون قرمز	استفاده از دوربین‌های مادون قرمز برای تشخیص نشتی‌ها با ثبت تصاویر سطوح خنک‌تر و شناسایی تفاوت‌های دمایی.	استفاده برای تشخیص نشتی تحت شرایط	هزینه کمتر و قابلیت استفاده در کاربردهای زمان واقعی. تکنیک غیرتماسی و غیرتخریبی.	نیاز به تجربه اپراتور. تشخیص به نوع خاک وابسته و دقت تحت تأثیر شرایط آب و هوایی است.	(نگم و همکاران، ۲۰۲۳؛ القحطانی و همکاران، ۲۰۲۰؛ اسلام

و همکاران، (۲۰۲۲)			مختلف سطحی.		
(جوزف و همکاران، ۲۰۲۲؛ یوسف و هو، ۲۰۲۲)	محدودیت به دلیل محدوده RFID.	مصرف انرژی پایین و ارتباطات بی سیم.	نظارت بر خطوط لوله در مناطق که دسترسی سخت است.	تشخیص تغییرات محیطی و انتقال سیگنال‌ها به خواننده RFID؛ نیاز به نصب دارد.	شناسایی فرکانس رادیویی (RFID)
(یوسف و هو، ۲۰۲۲)	پرهزینه و وابسته به مکان نشی در لوله. مسائل کیفیت آب ممکن است در دسترسی به لوله داخلی رخ دهد.	دقت بالا؛ قابلیت تشخیص نشی در لوله‌های با اندازه‌های مختلف.	ارائه مکان دقیق نشی‌ها.	ترکیب میکروفون‌ها یا همبستگی‌کننده‌ها برای تشخیص دقیق نشی. رویکردهای اصلی شامل همبستگی‌کننده‌های نوین نشی (LNCs)، تکنیک گاز ردیاب (TGT) و صوتی نصب‌شده روی خوک (PMA).	روش‌های دقیق‌ساز ی نشی

روش‌های تشخیص نشی مبتنی بر نرم‌افزار

طبق منابع (نگم و همکاران، ۲۰۲۳؛ یوسف و هو، ۲۰۲۲؛ سخاوتی و همکاران، ۲۰۲۲)، روش‌های مبتنی بر نرم‌افزار از الگوریتم‌ها و تحلیل داده برای شناسایی نشی‌ها در شبکه‌های توزیع آب (WDN) استفاده می‌کنند و بر دو رویکرد اصلی مبتنی بر مدل و داده‌محور تکیه دارند.

روش‌های مبتنی بر مدل از مدل‌های هیدرولیکی برای تشخیص و مکان‌یابی نشی بهره می‌برند. نرم‌افزارهای مدل‌سازی شامل **WaterGEMS**، **InfoWorks WS**، **LOOP**، **EPANET** و **OLGA**، **PIPEPHASE** و **Aspen PIPE**TM برای جریان چندفازی هستند (زمان و همکاران، ۲۰۲۰)، که امکان آزمون‌های آنی و بلندمدت را فراهم می‌کنند و ممکن است چند مرحله کالیبراسیون و اصلاح مدل نیاز باشد. پس از کالیبراسیون موفق، استراتژی‌های مختلف تشخیص نشی می‌توانند برای پیش‌بینی مکان‌های احتمالی نشی و حجم آن‌ها به کار گرفته شوند (نگم و همکاران، ۲۰۲۳). این استراتژی‌ها شامل تشخیص موج فشار منفی (**NPW**)، بردار باقیمانده فشار، روش مبتنی بر حساسیت، مبتنی بر طبقه‌بند و روش‌های

کالیبراسیون هستند (نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۰؛ سخاوتی و همکاران، ۲۰۲۲؛ کامون و همکاران، ۲۰۲۲).

روش‌های داده‌محور بدون نیاز به مدل از تکنیک‌های یادگیری ماشین (ML) و یادگیری عمیق (DL) برای شناسایی نشتی استفاده می‌کنند (کامون و همکاران، ۲۰۲۲؛ هو و همکاران، ۲۰۲۱؛ جوزف و همکاران، ۲۰۲۳). این رویکرد شامل جمع‌آوری داده، پیش‌پردازش و تبدیل آن‌ها قبل از طبقه‌بندی و پیش‌بینی نشتی هاست. تکنیک‌های ML می‌توانند نظارت‌شده، بدون نظارت یا یادگیری تقویتی باشند و DL نیز مبتنی بر داده عمل می‌کند. یادگیری تقویتی عمیق (DRL) ترکیبی از RL و DL برای تصمیم‌گیری متوالی ارائه می‌دهد (نگم و همکاران، ۲۰۲۴؛ نگم و همکاران، ۲۰۲۳؛ پروواز و همکاران، ۲۰۲۳؛ ماونگکانگ و همکاران، ۲۰۲۳؛ بلفادیل و همکاران، ۲۰۲۳؛ هاجگاتو و همکاران، ۲۰۲۰).

رویکردهای داده‌محور برای تشخیص نشتی در WDN‌ها را می‌توان به چهار زیرگروه تقسیم کرد: پیش‌بینی، طبقه‌بندی، آماری و پردازش سیگنال (نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۰؛ یوسف و هو، ۲۰۲۲؛ کامون و همکاران، ۲۰۲۲؛ هو و همکاران، ۲۰۲۱؛ نیمری و همکاران، ۲۰۲۳).

روش‌های پیش‌بینی و طبقه‌بندی رفتار سیستم را با الگوریتم‌هایی مانند رگرسیون بردار پشتیبان (SVR)، فیلتر کالمن (KF)، شبکه‌های چگالی مخلوط (MDN)، سیستم‌های استنتاج فازی (FIS)، سیستم‌های استنتاج بیزی (BIS)، شبکه‌های عصبی بازگشتی (RNN) و شبکه‌های حافظه کوتاه‌مدت بلند (LSTM) پیش‌بینی می‌کنند. روش‌های آماری با استفاده از کنترل فرآیند آماری (SPC)، تحلیل مؤلفه اصلی (PCA) و تحلیل مؤلفه مستقل (ICA) ناهنجاری‌ها را تشخیص می‌دهند.

روش‌های طبقه‌بندی الگوهای نشتی را با شبکه‌های عصبی مصنوعی (ANN)، شبکه‌های عصبی کانولوشنی (CNN)، شبکه‌های عصبی تأخیری زمانی، نقشه‌های خودسازمان‌دهنده (SOM) و ماشین‌های بردار پشتیبان (SVM) تمایز می‌دهند.

روش‌های پردازش سیگنال سیگنال‌های حسگر را با تبدیل فوریه کوتاه‌زمان (STFT)، تبدیل موجک (WT)، DWT، ادراک‌کننده چندلایه (MLP) و همجوشی (D-S Dempster-Shafer) تحلیل می‌کنند (نگم و همکاران، ۲۰۲۳؛ زمان و همکاران، ۲۰۲۰؛ یوسف و هو، ۲۰۲۲؛ کامون و همکاران، ۲۰۲۲؛ هو و همکاران، ۲۰۲۱؛ نیمری و همکاران، ۲۰۲۳).

تکنیک‌های هیبریدی ترکیبی از مدل‌های مبتنی بر هیدرولیک و داده‌محور هستند، مانند استفاده از EPANET همراه با یادگیری تقویتی عمیق. این رویکرد از شبیه‌سازی و داده‌های زمان واقعی بهره می‌برد، کیفیت آب را

بهبود می‌بخشد، مصرف انرژی را کاهش می‌دهد، کارایی پمپ را بهینه می‌کند و پیشگیری از نشتی را افزایش می‌دهد (نگم و همکاران، ۲۰۲۴؛ بلفادیل و همکاران، ۲۰۲۳؛ هاجگاتو و همکاران، ۲۰۲۰؛ هو و همکاران، ۲۰۲۳).

رویکردهای مبتنی بر مدل برای شرایطی مناسب هستند که داده‌های شبکه محدود اما مدل‌های هیدرولیکی در دسترس باشد، در حالی که روش‌های داده‌محور برای شبکه‌هایی با داده‌های تاریخی قابل توجه کاربرد دارند. روش هیبریدی از مزایای هر دو رویکرد بهره می‌برد (نگم و همکاران، ۲۰۲۴).

روش	اصل	مزایا	معایب	مرجع
روش‌های آماری	نظارت بر خوانش‌های حسگر برای اطمینان از عملیات عادی، زیرا انحراف از الگوهای استاندارد ممکن است نشان‌دهنده وجود نشتی باشد.	استفاده از الگوریتم‌های هوشمند. قابلیت تشخیص چندنشتی.	نیاز به پایگاه داده بزرگ برای عملکرد بهتر. مناسب برای خطوط لوله فاقد ورودی‌های پایگاه داده نیست.	(سکاواتی و همکاران، ۲۰۲۲)
مبتنی بر ماتریس حساسیت	مبتنی بر اندازه‌گیری فشار و تحلیل حساسیت WDN ها.	تشخیص آسان نشتی تحت شرایط ایده‌آل.	عدم قطعیت در تقاضاهای گره‌ای و اندازه‌گیری نویز.	(هو و همکاران، ۲۰۲۱)
تعادل حجمی	جستجو برای تفاوت بین ورودی و خروجی برای تشخیص نشتی.	ساده و مبتنی بر اصل حفظ جرم.	کمتر مؤثر در سیستم‌های پیچیده که تقاضا متغیر است.	(سکاواتی و همکاران، ۲۰۲۲؛ جوزف و همکاران، ۲۰۲۳)
موج فشار منفی	انجام تحلیل سیگنال‌های موج فشار تولیدشده برای تشخیص نشتی‌ها.	سرمایه‌گذاری و هزینه نگهداری تجهیزات پایین.	دقت تشخیص ضعیف و نیاز به قرارگیری استراتژیک حسگر.	(نگم و همکاران، ۲۰۲۳؛ سکاواتی و همکاران، ۲۰۲۲؛ جوزف و همکاران، ۲۰۲۳)
روش گذرا زمان واقعی	استفاده از شبیه‌سازی‌هایی که رفتار پویای شبکه‌های توزیع آب را مدل‌سازی می‌کنند برای شناسایی نشتی‌ها.	تشخیص و مکان‌یابی زمان واقعی نشتی.	شبیه‌سازی‌ها به دلیل پیچیدگی کالبراسیون آسان نیستند و نیاز به قدرت محاسباتی بالا دارند.	(نگم و همکاران، ۲۰۲۳؛ کورلاپاتی و همکاران، ۲۰۲۲؛ سکاواتی و همکاران، ۲۰۲۲)
تحلیل نقطه فشار	شناسایی نشتی‌های خط لوله با مشاهده کاهش فشارهایی که زیر آستانه مشخصی در سراسر سیستم قرار می‌گیرند.	آسان برای استفاده و نصب سریع.	نمی‌تواند نشتی‌های کوچک را تشخیص دهد.	(سکاواتی و همکاران، ۲۰۲۲؛ رومروبن و همکاران، ۲۰۲۳)
روش‌های فازی	استفاده از اصول منطق فازی برای تفسیر داده‌های نامطمئن.	دقت بالا و خروجی‌ها آسان برای تفسیر.	پیچیدگی محاسباتی بالا.	(یوسف و هو، ۲۰۲۲)

دینامیک سیالات محاسباتی	استفاده از تحلیل عددی و ساختارهای داده برای مدل سازی جریان آزاد جریان.	مؤثر در فضاهای با ابعاد بالا و نیاز به مدل های آماری صریح ندارد.	سخت برای پیش بینی نشستی ها در خطوط لوله.	(یوسف و هو، ۲۰۲۲)
روش تعادل آب	روش تعادل آب زیان های آب را با مقایسه حجم ورودی کل با مصرف حساب شده و مصارف محاسبه می کند.	مؤثر در کمی سازی زیان آب کل.	سخت برای دقیق سازی نشستی ها.	(فرح و شهرور، ۲۰۲۴)
ماشین بردار پشتیبان (SVM)	استفاده از روش شناسی های طبقه بندی و رگرسیون برای طبقه بندی داده ها به دسته های نشتی و غیرنشتی.	می تواند داده های نویزی با عدم پیش بینی پذیری قابل توجه را پردازش کند.	ممکن است برای نقاط داده هم پوشان کمتر مؤثر باشد.	(یوسف و هو، ۲۰۲۲؛ کامون و همکاران، ۲۰۲۲؛ جوزف و همکاران، ۲۰۲۳)
فیلتر کالمن	استفاده از سری مشاهدات برای تخمین وضعیت سیستم و شناسایی نشتی ها بر اساس داده های جمع آوری شده.	ساده برای درک و پیاده سازی.	فرض می کند که سیستم ممکن است رفتار خطی نشان دهد، که همیشه این طور نیست.	(کامون و همکاران، ۲۰۲۲؛ جوزف و همکاران، ۲۰۲۳)
KNN	تشخیص نشتی ها از طریق مقایسه اطلاعات روز جاری با روندهای تاریخی نشتی.	می تواند روابط غیر خطی پیچیده را با انعطاف پذیری مدل سازی کند.	ممکن است در مدیریت داده های با ابعاد بالا مبارزه کند و به ویژه به نویز درون داده حساس است.	(یوسف و هو، ۲۰۲۲؛ کامون و همکاران، ۲۰۲۲)
ANNها	تقلید از مغز انسان برای پردازش پیش بینی و تشخیص نشتی ها. مبتنی بر داده های ورودی.	الگوها و ناهنجاری ها را در داده های تصویری به دقت تشخیص می دهد.	نیاز به طراحی دقیق زیرا عملکرد به متغیرهای زیادی وابسته است.	(یوسف و هو، ۲۰۲۲؛ جوزف و همکاران، ۲۰۲۳)
CNNها	تشخیص نشتی ها از داده های فضایی، مانند تصاویر از حسگرها.	تشخیص آسان نشتی تحت شرایط ایده آل.	نیاز به منابع محاسباتی قابل توجه با مجموعه داده های بزرگ برای آموزش.	(یوسف و هو، ۲۰۲۲؛ جوزف و همکاران، ۲۰۲۳)

روش های پیشگیری از نشتی (کنترل)

کنترل نشتی با کاهش احتمال و شدت رخ داده ها، تأثیر نشتی ها بر شبکه های توزیع آب را کاهش می دهد. مدیریت دارایی و مدیریت فشار ابزارهای کلیدی برای پیشگیری هستند، اگرچه نوسازی دارایی ها هزینه بر و زمان بر است (آدِجی و همکاران، ۲۰۱۷). مدیریت فشار به طور گسترده به عنوان مؤثرترین و اقتصادی ترین

تکنیک برای کنترل پیشگیرانه شناخته می‌شود، زیرا فشار سیستم عامل اصلی نشتی‌های زمینه‌ای و انفجاری است و مطالعات تجربی همبستگی قوی بین نرخ نشتی و سر فشار نشان داده‌اند (نگم و همکاران، ۲۰۲۳؛ گائو و همکاران، ۲۰۲۲).

رویکرد جامع‌تر از مفهوم ناحیه ثابت و ناحیه متغیر (**FAVAD**) توسط می (۱۹۹۴) توسعه یافت (لامبرت، ۱۹۹۴؛ تورنتون و لامبرت، ۲۰۰۵، ۲۰۰۶، ۲۰۰۷). کاهش فشار بیش از حد نه تنها نرخ نشتی را کاهش می‌دهد، بلکه خطر انفجارهای جدید، مصرف انرژی، هزینه‌های عملیاتی و انتشار کربن را نیز کاهش می‌دهد (آدِجی و همکاران، ۲۰۱۷؛ تورنتون و لامبرت، ۲۰۰۵).

مدیریت فشار (**PM**) با استفاده از اجزای فعال‌کننده مانند شیرهای کاهش فشار (**PRVs**)، شیرهای حفظ فشار (**PSVs**) و پمپ‌ها به عنوان توربین‌ها (**PATs**) اعمال می‌شود و امکان کنترل استاتیک و پویا فشارها در داخل **DMAs** و سراسر شبکه را فراهم می‌کند (تورنتون و لامبرت، ۲۰۰۵؛ ویسنه و همکاران، ۲۰۱۶).

مدیریت فشار مدرن از تنظیمات ثابت به استراتژی‌های کنترل پویا و زمان واقعی شامل کنترل فشار خروجی ثابت (**FOPC**)، کنترل فشار مدوله شده زمانی (**TMPC**)، کنترل فشار مدوله شده جریانی (**FMPC**)، کنترل فشار حلقه بسته (**CLPC**)، کنترل‌کننده‌های بدون پارامتر و رویکردهای مبتنی بر بهینه‌سازی تکامل‌یافته است. این استراتژی‌ها در پیچیدگی، پاسخگویی و هزینه پیاده‌سازی متفاوت هستند (گائو و همکاران، ۲۰۲۲؛ ویسنه و همکاران، ۲۰۱۶).

تکنیک‌های **PM** شامل **PRVs**، **DMAs** و پمپ‌های سرعت متغیر (**VSPs**) هستند که به حداقل رساندن نشتی کمک می‌کنند. روش‌های بهینه‌سازی شامل رویکردهای ریاضی و متاهیوریستیک هستند. در روش‌های ریاضی، مشکلات با معادلات هیدرولیکی تعریف شده و از برنامه‌ریزی خطی (**LP**)، برنامه‌ریزی غیرخطی (**NLP**)، برنامه‌ریزی خطی عدد صحیح مخلوط (**MILP**) و برنامه‌ریزی غیرخطی عدد صحیح مخلوط (**MINLP**) استفاده می‌شود. تکنیک‌های متاهیوریستیک شامل الگوریتم ژنتیک (**GA**) و شبیه‌سازی آنیلینگ (**SA**) هستند که مستقل از شبیه‌سازهای هیدرولیکی عمل می‌کنند. **GA** با استفاده از تکامل تصادفی و **SA** با کاهش تدریجی پذیرش نتایج کمتر بهینه، راه‌حل‌ها را پیمایش می‌کنند (آراوجو و همکاران، ۲۰۰۶؛ نازیف و همکاران، ۲۰۱۰).

تجارب عملی نشان داده‌اند که **PRV**ها می‌توانند تأثیر قابل توجهی در کاهش نشتی داشته باشند. جرمن و همکاران (۱۹۸۵) کاهش ۱۸٪ نشتی را با نصب چهار تا شش شیر در **WDS** بنچمارک گزارش کردند. لیبراتور و سِچی (۲۰۰۹) با استفاده از الگوریتم چندهدفه **NSGA-II**، مکان و تنظیمات **PRV**ها را بهینه کردند و ۱۹٪ کاهش نشتی به دست آمد. کوولی و همکاران (۲۰۱۶) روش مرجع فشار (**PRM**) را برای کاهش بار محاسباتی

پیشنهاد کردند که انتخاب سایت **PRV** را ساده می‌کرد و به کاهش ۲۰،۰۸٪ نشتی در شبکه **Campos do Conde II** در برزیل انجامید.

روش‌های هیبریدی ترکیبی از **GA** و برنامه‌ریزی خطی (**LP**) یا یادگیری تقویتی عمیق (**DRL**) نیز توسعه یافته‌اند تا بهینه‌سازی قرارگیری شیرها و تنظیمات کنترل فشار را انجام دهند (نیکولینی و همکاران، ۲۰۱۱؛ نگم و همکاران، ۲۰۲۴؛ بلفادیل و همکاران، ۲۰۲۳). کاربردهای واقعی شامل **La Calera** در شیلی بود که بهبود ۱۰،۱۲٪ در جریان حداقل شبانه و کاهش ۵۲٪ در رویدادهای فشار زیر هدف را نشان داد.

در بخش پمپ‌ها، اولانیک و همکاران (۱۹۹۶) مزایای پمپ‌های سرعت متغیر را در مدیریت فشار و کاهش نشتی نشان دادند، اما هشدار دادند که کاهش فشار در ساعات اوج می‌تواند کفایت خدمات را به خطر بیندازد. به دنبال آن، پاشا و لنسی (۲۰۰۹) با الگوریتم **GA** سطوح تانک آب در **WDS** تهران را بهینه کردند و نشتی را از ۱۱٪ به ۵٪ کاهش دادند. پیاده‌سازی‌های پیشرفته‌تر مانند نرم‌افزار **OPIR** در پوزنان (سکورکوف و همکاران، ۲۰۱۰) زمان‌بندی پمپ و کنترل **PRV** پویا را ممکن کرد و ۲۰٪ کاهش نشتی زمینه‌ای و صرفه‌جویی انرژی ۲۱،۵۰۰ یورو در سال را فراهم کرد. فرناندز و همکاران (۲۰۲۰) نیز با جایگزینی **PCV**‌ها با پمپ‌های سرعت متغیر و شبیه‌سازی **EPANET**، ۲۷۰،۱۹۲،۱۹ **kWh**/سال بازیابی انرژی، با بازده اقتصادی بالا و قابلیت هیدرولیکی مناسب، به دست آوردند.

این مطالعات نشان می‌دهند که چارچوب‌های مدیریت فشار مبتنی بر بهینه‌سازی می‌توانند همزمان کاهش نشتی و مصرف انرژی، افزایش کارایی شبکه و پایداری سیستم‌های توزیع آب را تضمین کنند.

معیارهای ارزیابی و عملکرد روش‌های مدیریت نشتی

کارایی روش‌های مختلف مدیریت نشتی را می‌توان با استفاده از معیارهای متعددی ارزیابی کرد، از جمله دقت، قابلیت‌های مکان‌یابی، پتانسیل نظارت زمان واقعی، هزینه و نرخ هشدارهای کاذب. این معیارها برای تعیین مناسب بودن یک روش خاص برای کاربردهای خاص در شبکه‌های توزیع آب (**WDNs**) اهمیت حیاتی دارند.

در حوزه تشخیص نشتی، روش‌هایی مانند همبستگی‌کننده‌های نويز و ثبت‌کننده‌ها دقت بالا و قابلیت‌های مکان‌یابی قابل اعتماد ارائه می‌دهند، همراه با امکان نظارت زمان واقعی. با این حال، هزینه‌ها متفاوت است؛ همبستگی‌کننده‌ها گران‌تر و ثبت‌کننده‌ها مقرون‌به‌صرفه‌تر هستند (فراه و شهرو، ۲۰۲۴، گوپتا و کولات، ۲۰۱۸، زمان و همکاران، ۲۰۲۰، فن و همکاران، ۲۰۲۲). ابزارهای سنتی مانند چوب‌های گوش دادن دقت مناسبی دارند اما فاقد قابلیت نظارت زمان واقعی هستند و در محیط‌های پویا محدودیت دارند (فراه و شهرو، ۲۰۲۴، الزهاب و

زاید، ۲۰۱۹). تکنیک‌های پیشرفته مانند فیبر نوری و ترموگرافی مادون قرمز دقت بالاتر و نرخ هشدار کاذب پایین ارائه می‌کنند، اما هزینه نصب و عملیاتی آن‌ها بالا است (فراه و شهر، ۲۰۲۴، زمان و همکاران، ۲۰۲۰، یوسف و هو، ۲۰۲۲، کورلاپاتی و همکاران، ۲۰۲۲). به همین ترتیب، رادار نفوذ زمین (GPR) و روش‌های گاز ردیاب مکان‌یابی عالی دارند اما محدودیت‌های هزینه و نرخ هشدار کاذب متوسط، کاربرد گسترده آن‌ها را کاهش می‌دهد (نجم و همکاران، ۲۰۲۳، زمان و همکاران، ۲۰۲۰، یوسف و هو، ۲۰۲۲، القحطانی و همکاران، ۲۰۲۰).

در روش‌های مبتنی بر نرم‌افزار، شبکه‌های عصبی مصنوعی (ANN) و شبکه‌های عصبی کانولوشنی (CNN) دقت بالا و قابلیت نظارت زمان واقعی همراه با نرخ هشدار کاذب پایین ارائه می‌دهند (فراه و شهر، ۲۰۲۴، یوسف و هو، ۲۰۲۲، جوزف و همکاران، ۲۰۲۳). با این حال، هزینه محاسباتی و نیازهای داده‌ای بالا، استقرار عملی آن‌ها را چالش‌برانگیز می‌کند. روش‌هایی مانند ماشین‌های بردار پشتیبان (SVM) و سیستم‌های فازی عملکرد خوبی در دقت و مکان‌یابی دارند و روش‌های فازی دقت بالا و نرخ هشدار کاذب پایینی نشان می‌دهند (فراه و شهر، ۲۰۲۴، یوسف و هو، ۲۰۲۲، الزهاب و زاید، ۲۰۱۹، جوزف و همکاران، ۲۰۲۳). رویکردهای دیگر مانند فیلتر کالمن و k-نزدیک‌ترین همسایه (KNN) در دقت و نرخ هشدار کاذب متوازن هستند، اما هزینه‌های محاسباتی و پیاده‌سازی متفاوت دارند. روش‌های ساده‌تر مانند تعادل آب و تحلیل نقطه فشار مقرون‌به‌صرفه هستند اما محدودیت‌هایی در دقت و مکان‌یابی دارند (یوسف و هو، ۲۰۲۲، هو و همکاران، ۲۰۲۱، جوزف و همکاران، ۲۰۲۳). روش‌های پیشرفته‌تر مانند دینامیک سیالات محاسباتی (CFD) دقت و مکان‌یابی بهتری ارائه می‌دهند اما با هزینه و تقاضای محاسباتی بالا همراه هستند (یوسف و هو، ۲۰۲۲، فو و همکاران، ۲۰۲۰).

در پایین‌ترین سطح، روش‌های سنتی مانند تعادل آب و تحلیل نقطه فشار کم‌هزینه و آسان برای پیاده‌سازی هستند، اما محدودیت در دقت و مکان‌یابی آن‌ها، استفاده از آن‌ها در WDN‌های پیچیده را محدود می‌کند (فراه و شهر، ۲۰۲۴، نجم و همکاران، ۲۰۲۳، هو و همکاران، ۲۰۲۱، اودوسینا و همکاران، ۲۰۰۸).

در حوزه پیشگیری از نشتی، کنترل فشار مزایای اثبات‌شده دارد اما محدودیت‌هایی مانند وابستگی به مدل‌های دقیق، تقاضای محاسباتی بالا، سازگاری محدود با شرایط متغیر شبکه و نیاز به زیرساخت و داده‌های گسترده دارد. این روش‌ها در کاربردهای زمان واقعی به ویژه در شبکه‌های بزرگ یا پویا محدودیت دارند (موستل و همکاران، ۲۰۲۰، گوپتا و همکاران، ۲۰۲۰، مالا-جتماروا و همکاران، ۲۰۱۸، آدجی و همکاران، ۲۰۱۷). الگوریتم‌های پیشرفته بهینه‌سازی مانند الگوریتم‌های ژنتیک (GA) فشرده هستند، نتایج بهینه را تضمین

نمی‌کنند و به تعداد زیادی نمونه نیاز دارند، که زمان اجرای آن‌ها را افزایش می‌دهد (مالا-جتماروا و همکاران، ۲۰۱۸، چوگ و همکاران، ۲۰۱۹، کتوش و همکاران، ۲۰۲۱، پاتل، ۲۰۲۳).

برای غلبه بر محدودیت‌های روش‌های سنتی، تحقیقات اخیر به سمت تکنیک‌های نوظهور یادگیری ماشین، به ویژه یادگیری تقویتی (RL) و ترکیب آن با یادگیری عمیق (DRL) متمرکز شده است (لی، ۲۰۱۸، فرانسوا-لاوه و همکاران، ۲۰۱۸، کریشن، ۲۰۲۳، گارنیه و همکاران، ۲۰۲۱، پانزر و بندر، ۲۰۲۲). این رویکردها امکان ارائه راه‌حل‌های بدون مدل، مقیاس‌پذیر و سیاست‌های کنترل بهینه از طریق تعامل با محیط را فراهم می‌کنند، وابستگی به پارامترهای پیش‌تعریف‌شده را کاهش می‌دهند و سازگاری زمان واقعی را ممکن می‌کنند (نجم و همکاران، ۲۰۲۴، بلفادیل و همکاران، ۲۰۲۳، نجم و همکاران، ۲۰۲۳، هو و همکاران، ۲۰۲۳، موستل و همکاران، ۲۰۲۰).

DRL قدرت نمایشی یادگیری عمیق را با استراتژی آزمون‌وخطای یادگیری تقویتی ترکیب می‌کند، که نوید مدیریت مسائل کنترل پیچیده و غیرخطی را می‌دهد (بلفادیل و همکاران، ۲۰۲۳) و در زمینه‌هایی مانند رباتیک، سیستم‌های کنترل و زیرساخت‌های هوشمند با موفقیت اعمال شده است (نجم و همکاران، ۲۰۲۴). در **WDN**ها، **DRL** برای بهینه‌سازی سیستم و پیشگیری از نشتی از طریق تنظیم فشار، کنترل شیر و بهینه‌سازی پمپ استفاده شده است (نجم و همکاران، ۲۰۲۴، بلفادیل و همکاران، ۲۰۲۳، نجم و همکاران، ۲۰۲۳، هو و همکاران، ۲۰۲۳، حاج‌گاتو و همکاران، ۲۰۲۰، پروازه و همکاران، ۲۰۲۳، ماونگکانگ و همکاران، ۲۰۲۳، پاتل و همکاران، ۲۰۲۳). با وجود این پیشرفت‌ها، کاربرد **DRL** به طور خاص در مدیریت جامع نشتی هنوز کمتر کاوش شده است و زمینه‌ای نویدبخش برای تحقیقات آینده ارائه می‌دهد.

مطالعات موردی DRL در سیستم‌های آب شهری

برای گذار از نظریه به عمل، بررسی مثال‌های واقعی از اجرای **DRL** ضروری است. قدرت **DRL** در انعطاف‌پذیری و توانایی ارائه منافع قابل سنجش در کل چرخه آب شهری نهفته است. جدول زیر، تأثیر ملموس **DRL** در چهار حوزه اصلی **UWS** را نشان می‌دهد: (نجم، ما، و آگی دیس، ۲۰۲۴)

حوزه UWS	کاربرد	الگوریتم DRL	نتایج و مزایای کمی
شبکه‌های توزیع آب	کنترل پمپ	DDQN, PPO, E-PPO, KA-PPO	کاهش نوسانات سطح مخازن، کاهش مصرف انرژی، حفظ فشار، بهینه‌سازی سن آب. $E-PPO$ ۶.۱٪ صرفه‌جویی انرژی بیشتر نسبت به PPO استاندارد داشت.

کیفیت آب	PQDQN	عملکرد بهتر از الگوریتم‌های چندسیاستی پیشرفته در مسئله بهینه‌سازی چندهدفه پویا برای پایداری کیفیت آب.
مدیریت دارایی پس از حادثه	GCN-DQN	امتیاز بالاتر شاخص تاب‌آوری سیستم (SRI) با یافتن توالی تعمیر بهینه پس از زلزله در مقایسه با استراتژی‌های سنتی.
سیستم‌های رواناب شهری	DDPG	کاهش ۳۲٪ سیلاب نسبت به سیستم غیر فعال و ۱۹٪ نسبت به کنترل مبتنی بر قوانین.
افزایش قابلیت اطمینان	DQN, DDQN, PPO, AYC, Voting	روش «رأی‌گیری» با چند عامل DRL قابلیت اطمینان کنترل سیل و CSO را بهبود داد.
بهره‌وری محاسباتی	DDPG	سیاست‌های کنترلی ۸۸ برابر سریع‌تر از مدل کنترل پیش‌بین اجرا شدند.
بهینه‌سازی انرژی و محیط	DQN, Deep SARSA	الگوریتم DQN همزمان ۳۶.۵۳٪ بهره اقتصادی و ۰.۲۳٪ کارایی محیطی افزایش داد.
کنترل فرآیند (اکسیژن محلول)	Multi-agent DDPG	تابع پاداش مبتنی بر ارزیابی چرخه عمر، اثرات محیطی را به حداقل رساند.
کنترل فرآیند (pH و سطح مخزن)	Multi-agent DDPG	عملکرد بهتر و نوسانات کمتر نسبت به کنترل‌کننده‌های سنتی PI.
تأمین آب خام	PPO	کاهش مصرف انرژی ۸.۳۳٪ و کاهش حجم متوسط شن بیش از ۳۷٪ نسبت به استراتژی دستی کارشناسی.

کاربردهای DRL در بخش آب

یادگیری تقویتی عمیق (DRL) توانایی تحول‌آفرینی در حوزه‌های متعدد را دارد و مشکلات پیچیده و تصمیم‌گیری‌های متوالی را به‌طور مؤثر حل می‌کند. در مقایسه با سایر صنایع، کاربرد DRL در بخش آب شهری به‌طور فزاینده‌ای در حال گسترش است و تحقیقات اخیر نشان می‌دهد که این روش می‌تواند در بهینه‌سازی عملیات، کاهش هزینه‌ها و بهبود تاب‌آوری سیستم‌های آب نقش مؤثری داشته باشد. شکل ۱۳ خلاصه‌ای از کاربردهای DRL در شبکه‌های آب شهری ارائه می‌دهد.

DRL در سیستم‌های آب طوفانی

(مولاپودی و همکاران، ۲۰۲۰) DRL را برای کنترل زمان واقعی سیستم‌های آب طوفانی شهری اعمال کردند. آنها یک الگوریتم کنترل مبتنی بر DRL با استفاده از شبکه‌های Q عمیق توسعه دادند تا زیرساخت‌های آب طوفانی را به‌صورت خودکار مدیریت کنند. مدل با استفاده از چارچوب شبیه‌سازی مشترک مبتنی بر Python

که **TensorFlow** و **SWMM** را ادغام می‌کند، آموزش داده شد و به عامل اجازه داد تا با حوضه‌های شبیه‌سازی شده تحت هزاران سناریوی طوفانی تعامل کند. طراحی توابع پاداش و انتخاب ساختار شبکه عصبی مناسب، بهبود قابل توجهی در عملکرد سیاست‌های کنترل ارائه داد و نشان داد که سیستم‌های کنترل نشده عملکرد پایین‌تری در شرایط طوفانی دارند. این مطالعه همچنین چالش‌های مقیاس‌پذیری **DRL** در شبکه‌های آب پیچیده را برجسته کرد.

(سالیبا و همکاران، ۲۰۲۰) از الگوریتم گرادیان سیاست قطعی عمیق (**DDPG**) با داده‌های بارش تاریخی برای کاهش حجم سیلاب استفاده کرد و کاهش ۷۰.۵ درصدی حجم سیلاب را نسبت به سیستم‌های غیرفعال به دست آورد. مطالعه نشان داد که الگوریتم **DDPG** در کنترل زمان واقعی برتری دارد و نسبت به نويز داده‌ها مقاوم است. (سادلر و همکاران، ۲۰۲۰) از الگوریتم کنترل پیش‌بینی مدل (**MPC**) استفاده کرد که حجم سیلاب را ۳۲ درصد و حداکثر حجم سیلاب گره را ۵۲ درصد کاهش داد. **DDPG** کنترل سریع و مؤثر ارائه داد، در حالی که **MPC** در مواجهه با سناریوهای افزایش سطح دریا کارآمدتر بود.

(بوز و همکاران، ۲۰۲۱) چارچوب **deep-RL** را در یک مدل مبتنی بر فیزیک با دو حوضچه نگهداری قابل کنترل پیاده کرد و ۳۲ درصد کاهش سیلاب نسبت به سیستم غیرفعال داشت. سرعت آموزش **DRL** ۸۸ برابر سریع‌تر از **MPC** بود و کنترل مبتنی بر قاعده ۱۹ درصد عملکرد پایین‌تری ارائه داد.

(تیان و همکاران، ۲۰۲۲) یک چارچوب ادغامی **multi-RL** و **MPC** برای کنترل زمان واقعی و کاهش سیلاب طراحی کرد. این چارچوب پنج الگوریتم **RL** را مقایسه کرد، سیستم امنیتی برای تصمیم‌گیری‌های کنترل پیاده‌سازی نمود، سیستم هیبریدی رأی‌گیری طراحی کرد و آزمون‌های استحکام انجام داد.

DRL در شبکه‌های توزیع آب

در زمینه سیستم‌های توزیع آب (**WDS**)، **DRL** برای بهینه‌سازی زمان واقعی عملیات پمپ و مدیریت فشار استفاده شده است.

(حاج‌گاتو و همکاران، ۲۰۲۰) بیان کردند که **DRL** می‌تواند عملیات پمپ را در زمان واقعی بهینه کند و عملکردی قابل مقایسه با روش‌های متداول به دست آورد، اما با سرعت دو برابر. آنها از شبکه **Q** عمیق دولی (**D-DQN**) برای بهینه‌سازی سرعت پمپ استفاده کردند تا کارایی هیدرولیکی در شرایط تقاضای تصادفی حفظ شود. الگوریتم جریان ورودی و خروجی مخزن را حداقل می‌کند و فشار قابل قبول در گره‌ها را حفظ می‌کند. پاداش‌ها شامل رضایت مصرف‌کننده، کارایی پمپ و تعادل تأمین است. آزمایش‌ها در شبکه‌های کوچک

(Anytown) و بزرگ (D-town) نشان داد که **D-DQN** عملکردی قابل مقایسه با تکامل دیفرانسیل (**DE**) دارد و بهتر از **PSO** و جستجوی تصادفی عمل می‌کند. برخلاف روش‌های سنتی، این الگوریتم از داده‌های زنده برای کنترل زمان واقعی استفاده می‌کند.

(موستل و همکاران، ۲۰۲۰) **DRL** را برای بهینه‌سازی شیرهای کاهش فشار (**PRVs**) بدون مدل اعمال کرد تا توزیع فشار بهینه پیش‌بینی شود. زمان و همکاران، ۲۰۲۳ به چالش زمان‌بندی ناکارآمد در **WDS** پرداختند که باعث هدررفت انرژی، سرریز و عدم رضایت تقاضا می‌شود. آنها یادگیری تقویتی عمیق با تقریب تابع برای مدیریت انفجار حالت‌ها و عامل **LSTM** را برای بهینه‌سازی مصرف انرژی و حفظ ایمنی عملیات پیاده کردند. نتایج نشان داد عامل **RL** عملکرد بهتری نسبت به کنترل‌کننده پایه و کنترل فازی داشت.

(نجم و همکاران، ۲۰۲۳) **Q-learning** را برای بهینه‌سازی نقاط تنظیم شیر جهت کنترل فشار فعال پیاده کرد. عامل **RL** توانست تنظیمات شیر را اصلاح کند تا فشار متوسط کاهش یابد و با آستانه قانونی **OFWAT** مطابقت داشته باشد. این منجر به کاهش ۲ درصدی فشار متوسط سیستم با حداقل تغییرات دو شیر شد.

(بلغادیل و همکاران، ۲۰۲۳) چارچوب **DRL-EPANET** را با شبکه **Q** دوئلی شاخه‌ای (**BDQ**) برای کنترل فشار در **WDS** توسعه داد. نوع **BDQ** با اقدامات ثابت (**BDQF**) عملکرد بهتری در سناریوهای اقدامات پراکنده ارائه کرد. این چارچوب در ۱۰ شبکه واقعی تا ۲۶ درصد بهبود فشار متوسط ایجاد کرد و توانست عدم قطعیت‌ها مانند ترکیب‌گی لوله و نوسانات تقاضا را مدیریت کند.

(هو و همکاران، ۲۰۲۳a) چارچوب **DRL** بهبود یافته **E-PPO** را برای زمان‌بندی پمپ زمان واقعی پیشنهاد کرد که یادگیری زمان‌بندی‌های زیربهینه و جریمه سطح مخزن را شامل می‌شود. این چارچوب هزینه‌های انرژی را تا ۱۱.۱۴ درصد کاهش داد و سطح آب بهینه را حفظ کرد. (هو و همکاران، ۲۰۲۳b) زمان‌بندی پمپ و شیر را به عنوان **MDP** چندعاملی مشارکتی مدل کرد و با استفاده از **MADDPG** زیان آب کاهش یافته و پاسخ سریع و مستحکم‌تر از روش‌های **GA**، **PSO** و **DE** ارائه شد.

(ژو و همکاران، ۲۰۲۱) چارچوب **KA-PPO** را پیشنهاد کرد که داده‌های تاریخی **WDN** را در الگوریتم بهینه‌سازی سیاست مجاور با استفاده از فشارهای گره‌ای ادغام می‌کند. این روش بر روی یک سیستم دوپمپ ۲۲ گره‌ای عملکرد بهتری نسبت به **Nelder-Mead** نشان داد. (پاتل و همکاران، ۲۰۲۳) یادگیری تقویتی هیبریدی را برای پایداری پمپ در شبکه‌های واقعی اعمال کرد. این مطالعات نشان‌دهنده پتانسیل **DRL** در بهینه‌سازی سیستم‌های آب و کاهش هزینه‌ها هستند.

DRL در سیستم های کیفیت آب

DRL در بهینه سازی کیفیت آب نیز کاربرد دارد:

- (حسن و همکاران، ۲۰۱۹) الگوریتم **parity-Q DQN** را برای شناسایی نواحی آسیب پذیر بر اساس تاب آوری کیفیت آب در سائوپائولو اعمال کرد. تست بد سازگار با **RL** با محیط **DST** طراحی شد و نقشه برداری رابطه هدف (**ORM**) برای هدایت یادگیری سیاست به کار رفت. **DRL** عملکرد بهتری نسبت به **MP-DQN**، **MO-MCTS** و **MPQ** ارائه داد.
- (نام و همکاران، ۲۰۲۰) سیستم خودکار مبتنی بر **DQN** برای بهینه سازی هوادهی در **MBR** فاضلاب طراحی شد و مصرف انرژی بیش از ۳۳ درصد کاهش یافت.
- (آلوس گولارت و دوترا پیرا، ۲۰۲۰) و (پنجاپورن پون و همکاران، ۲۰۲۲) کنترل **pH** و سطح در راکتورها را با **DRL** و **DDPG** بهبود دادند و پایداری بیشتری نسبت به کنترل کننده های **PI** نشان دادند.
- (لی و همکاران، ۲۰۲۳) **DRL** را برای کنترل پمپاژ آب خام تحت بار رسوبی بالا به کار گرفت و مصرف انرژی و جامدات معلق کاهش یافت.
- (آپونته-رنگیفو و همکاران، ۲۰۲۳) با استفاده از **actor-critic DRL** و یادگیری انتقال، هوادهی در تصفیه فاضلاب بهینه شد و عملکرد بهتری نسبت به روش های سنتی نشان داد.
- (یانز لوئیس و همکاران، ۲۰۲۴) وسایل سطحی خودکار چندعاملی را با فرآیندهای گاوسی محلی و یادگیری تقویتی برای بهبود نظارت کیفیت آب ترکیب کرد و کاهش ۲۴-۲۰ درصدی خطا مشاهده شد.
- (یه و همکاران، ۲۰۲۴) **DRL** را با مدل سنجش جهانی مبتنی بر **CNN** برای نظارت کیفیت آب در حوضه های رودخانه ادغام کرد و بهینه سازی قرارگیری حسگرها و استنباط غلظت **TN** را بهبود داد.
- در کل، یادگیری تقویتی عمیق پتانسیل قابل توجهی برای تحول بخش آب دارد. با این حال، کاربرد **DRL** در **WDN** ها هنوز در مراحل اولیه است. این شبکه ها نیازمند نظارت بی وقفه، تصمیم گیری سریع و توانایی پیمایش شرایط نامطمئن و پویا هستند. ادغام **DRL** در مدیریت **WDN** ها نه تنها مفید بلکه برای وظایف حیاتی مانند تشخیص و پیشگیری از نشتی ضروری است. با رفع چالش های موجود، می توان سیستم های توزیع آب کارآمدتر، پایدارتر و قابل اعتمادتر ایجاد کرد.

چالش‌های DRL در شبکه‌های توزیع آب (WDN)

پیاده‌سازی یادگیری تقویتی عمیق (DRL) در شبکه‌های توزیع آب (WDN) چندین چالش کلیدی دارد که برای مدیریت مؤثر نشتی و بهینه‌سازی عملکرد سیستم باید به آنها پرداخت (نجم و همکاران، ۲۰۲۴؛ بلغادیل و همکاران، ۲۰۲۳؛ هو و همکاران، ۲۰۲۳؛ حاج‌گاتو و همکاران، ۲۰۲۰):

۱. در دسترس بودن و کیفیت داده‌ها

داده‌های ناقص یا نادرست می‌توانند عملکرد یادگیری تقویتی عمیق را به شدت کاهش دهند. داده‌های برچسب‌دار با کیفیت بالا برای آموزش حیاتی هستند، اما جمع‌آوری آنها دشوار است زیرا اندازه‌گیری‌ها پراکنده و نویزی هستند و تحت تأثیر عوامل محیطی قرار می‌گیرند. کمبود داده‌های تاریخی آموزش مدل‌های یادگیری تقویتی عمیق را پیچیده‌تر کرده و توانایی ایجاد مدل‌های مقاوم را کاهش می‌دهد.

۲. شکاف شبیه‌سازی به واقعیت

بسیاری از مطالعات یادگیری تقویتی عمیق در محیط‌های شبیه‌سازی محدود شده‌اند. اگرچه شبیه‌سازی‌ها محیط امنی برای آموزش ارائه می‌دهند، اغلب پیچیدگی و نوسانات سیستم‌های واقعی را کاملاً بازتاب نمی‌دهند. این شکاف باعث می‌شود که استقرار عملی یادگیری تقویتی عمیق دشوار باشد. رفع این شکاف نیازمند تکنیک‌های تعمیم سیاست، سازگاری دامنه و یادگیری انتقال است.

۳. ادغام شبیه‌ساز هیدرولیکی

ادغام یادگیری تقویتی عمیق با شبیه‌سازهای هیدرولیکی مانند اپانت (EPANET) ضروری است، اما بار محاسباتی شبیه‌سازی‌ها باعث تأخیر و کاهش کارایی می‌شود. این موضوع بر آموزش و پاسخ زمان واقعی عامل تأثیرگذار است.

۴. مقیاس‌پذیری

با افزایش اندازه شبکه، تعداد حالات و اقدامات ممکن به طور نمایی افزایش می‌یابد و الگوریتم‌های یادگیری تقویتی عمیق معمولی ممکن است کارایی خود را از دست بدهند. استفاده از یادگیری تقویتی عمیق سلسله‌مراتبی می‌تواند یادگیری در چندین سطح انتزاعی را ممکن سازد و مقیاس‌پذیری شبکه‌های بزرگ‌تر را بهبود دهد.

۵. پیچیدگی محاسباتی

آموزش یادگیری تقویتی عمیق شامل کاوش هزاران حالت و اقدام ممکن است که نیاز به منابع محاسباتی قابل توجه دارد. کمبود قدرت محاسباتی می‌تواند آموزش را محدود کرده و قابلیت تعمیم مدل را کاهش دهد.

۶. حساسیت به معماری شبکه عصبی

ساختار شبکه عصبی شامل تعداد لایه‌ها، نورون‌ها و ابرپارامترها نقش حیاتی در عملکرد یادگیری تقویتی عمیق دارد. تعیین بهترین معماری معمولاً با آزمون و خطا انجام می‌شود که زمان‌بر است و روش سیستماتیک ندارد.

۷. طراحی تابع پاداش

تابع پاداش اغلب به صورت دستی و هیوریستیک طراحی می‌شود که نیازمند آزمون و خطای گسترده و تخصص دامنه است. این روش طول چرخه توسعه را افزایش می‌دهد و ریسک یادگیری زیربهبود را بالا می‌برد. تکنیک‌هایی مانند یادگیری تقویتی معکوس، متایادگیری یا استخراج ترجیحات از متخصصان می‌توانند طراحی خودکار و ساختاریافته تابع پاداش را امکان‌پذیر کنند.

۸. مدیریت عدم قطعیت

شبکه‌های توزیع آب با نوسانات تقاضا، وقوع نشتی‌ها و شکست حسگرها مواجه هستند. سیستم یادگیری تقویتی عمیق باید نسبت به این نوسانات مقاوم باشد و قادر به تشخیص ناهنجاری‌ها برای حفظ قابلیت اعتماد باشد.

۹. مشکل تخصیص اعتبار

پاداش‌ها در محیط‌های پویا اغلب مدت‌ها پس از اقدام علت‌ساز رخ می‌دهند و تخصیص اعتبار را دشوار می‌کند. این موضوع یادگیری وابستگی‌های بلندمدت را پیچیده می‌کند و نیازمند معماری‌های ویژه برای مدیریت وابستگی طولانی است.

۱۰. تعادل کاوش در مقابل بهره‌برداری

عامل‌های یادگیری تقویتی عمیق ممکن است به جای کاوش بهینه جهانی، به بهره‌برداری از پاداش‌های فوری بپردازند و در بهینه‌های محلی گیر کنند. معرفی تصادفی بودن در رفتار عامل می‌تواند امکان کاوش بهتر و دستیابی به بهینه‌های جهانی را فراهم کند.

۱۱. چالش‌های خاص نشتی

نشتی‌های زمینه‌ای خصوصیات منحصربه‌فردی دارند؛ پراکنده، طولانی و اغلب غیرقابل شناسایی هستند. برخلاف نشتی‌های انفجاری که نشانه‌های هیدرولیکی واضح دارند، نشتی‌های زمینه‌ای اغلب خاموش ادامه

می‌یابند و پاداش کمی ارائه می‌دهند، که یادگیری یادگیری تقویتی عمیق را برای پیشگیری و کنترل نشتی پیچیده می‌کند.

ملاحظات استراتژیک برای پذیرش DRL

ادغام یادگیری تقویتی عمیق (DRL) در سیستم‌های آب شهری یک اقدام استراتژیک است، نه صرفاً فنی. چالش‌های مرتبط، موانع نیستند بلکه متغیرهای شناخته شده‌ای هستند که با برنامه‌ریزی مناسب قابل مدیریتاند (نجم، ما، و آگی دیس، ۲۰۲۴):

- اطمینان از آماده‌سازی داده‌ها و یکپارچگی زیرساخت
 - وابستگی به داده‌های با کیفیت بالا: الگوریتم‌های یادگیری تقویتی عمیق نیازمند داده‌های سنسور دقیق و مستمر هستند.
 - حساسیت به داده‌های نادرست: داده‌های اشتباه می‌توانند اقدامات مضر یا غیرمؤثر ایجاد کنند.
 - عمومی‌سازی محدود: مدل آموزش‌دیده برای یک شبکه ممکن است مستقیماً قابل استفاده در شبکه دیگر نباشد.
- ایجاد اعتماد از طریق قابلیت اطمینان الگوریتم
 - بی‌ثباتی ذاتی یادگیری تقویتی عمیق: چالش‌هایی مانند «سه‌گانه مرگبار»، «مسئله تخصیص اعتبار» و «تعادل کاوش و بهره‌برداری».
 - ارزیابی قبل از اجرا: آزمایش دقیق پیش از کنترل زیرساخت حیاتی ضروری است.
 - سازگاری با تغییرات فصلی: ممکن است نیاز به بازآموزی دوره‌ای باشد.
- مدیریت پیچیدگی و طراحی مدل
 - طراحی تابع پاداش چندهدفه: دشوار برای تعادل اهداف رقابتی مانند هزینه انرژی، کیفیت آب و فشار سیستم.
 - انتخاب‌های پیچیده الگوریتمی: شامل معماری شبکه عصبی و ده‌ها ابرپارامتر.

دسته بندی پیشنهادی مقالات

پس از انجام بررسی های پیشین، در گام نخست، ابعاد و ویژگی های کلیدی مطالعات مورد تحلیل مشخص می گردند.

پس از شناسایی این ابعاد، ضروری است که دسته بندی نظام مندی بر روی مقالات اعمال شود. این دسته بندی امکان مقایسه دقیق مطالعات را فراهم می آورد و در نهایت، به شناسایی شکاف های موجود در ادبیات پژوهش (research gaps) منجر می شود.

ابعاد به طور کل در ۹ دسته بندی قرار گرفته و در ادامه شرح داده شده است.

حوزه کاربرد	هدف پژوهش
این بعد، سیستم اصلی و دامنه عملیاتی مطالعه را تعریف می کند.	این بعد، هدف اصلی فنی یا عملیاتی مطالعه را مشخص می نماید.
- مدیریت شبکه توزیع آب (WDN) - مدیریت فشار - مدیریت نشت - کنترل عملیاتی	- مدیریت نشت - کاهش نشت - ارزیابی نشت - تشخیص نشت - کنترل و بهینه سازی فشار - کاهش هزینه های عملیاتی - کمینه سازی هزینه انرژی - تاب آوری و استحکام سیستم - پاسخ به شکست لوله - مدیریت تغییرات تقاضا - حفاظت از کیفیت آب (در داخل شبکه توزیع آب) - کاهش آلودگی - کنترل سن آب
رویکرد شناختی	نوع داده
این بعد، رویکرد اصلی علمی یا محاسباتی به کار گرفته شده را شناسایی می کند.	این بعد، ماهیت داده های مورد استفاده برای مدل سازی و ارزیابی را توصیف می کند.
- کنترل هوشمند - یادگیری تقویتی (RL) - مبتنی بر ارزش (Q-) - مبتنی بر سیاست (PPO, TRPO, REINFORCE) - بازیگر-منتقد (A2C, DDPG, SAC, TD3)	- داده های هیدرولیکی شبیه سازی شده - داده های عملیاتی واقعی - داده های حسگر SCADA - داده های مبتنی بر رویداد - الگوهای تقاضا - رویدادهای شکست یا اختلال

	▪ یادگیری تقویتی چندعامل (MARL) ○ شبکه‌های عصبی مصنوعی (ANN) ○ تکامل عصبی (Neuro-Evolution) • بهینه‌سازی متاهوریستیک ○ الگوریتم ژنتیک (GA) ○ بهینه‌سازی ازدحام ذرات (PSO) ○ تکامل تفاضلی (DE) ○ بهینه‌سازی شاهین هریس (HHO) • کنترل مبتنی بر مدل ○ کنترل مبتنی بر قاعده ○ کنترل مبتنی بر بهینه‌سازی • مدل‌سازی و شبیه‌سازی هیدرولیکی (حمایتی)
محیط مطالعه این بعد، زمینه سیستم را که مطالعه در آن انجام شده است، مشخص می‌نماید. • شبکه توزیع آب شبیه‌سازی شده ○ شبکه‌های معیار (مانند Net۳, Anytown, D-Town) ○ مدل‌های شبکه واقعی • شبکه توزیع آب شهری عملیاتی (موارد محدود)	متغیرهای کنترل / تصمیم‌گیری این بعد، پارامترهای عملیاتی که به طور فعال دستکاری می‌شوند را شناسایی می‌کند. • شیرهای کاهش فشار (PRVs) • پمپ‌ها ○ وضعیت روشن/خاموش ○ کنترل سرعت متغیر • شیرهای دروازه‌ای • متغیرهای زمان‌بندی عملیاتی
ویژگی‌های مسئله این بعد، پیچیدگی ذاتی مسئله پژوهش را ترسیم می‌کند. • رفتار دینامیک سیستم • روابط هیدرولیکی غیرخطی • کنترل واقعی‌زمان یا نزدیک به واقعی‌زمان • بهینه‌سازی چند هدفه • فضای حالت / عمل با ابعاد بالا • عدم قطعیت سیستم و تغییرات تقاضا	تمرکز ارزیابی عملکرد این بعد، معیارهای ارزیابی مورد استفاده را دسته‌بندی می‌کند. • معیارهای عملکرد هیدرولیکی • معیارهای تلفات آب • معیارهای انرژی و اقتصادی • معیارهای تاب‌آوری و قابلیت اطمینان • معیارهای عملکرد محاسباتی
محدودیت‌ها این بعد، چالش‌های معمولاً گزارش‌شده را شناسایی می‌کند. • هزینه محاسباتی بالا در حین آموزش • شکاف شبیه‌سازی به واقعیت • پیچیدگی طراحی تابع پاداش • حساسیت به ابرپارامترها • تفسیرپذیری محدود	مزایا این بعد، نقاط قوت گزارش‌شده رویکردهای پیشنهادی را برجسته می‌سازد. • تصمیم‌گیری تطبیقی و داده‌محور • قابلیت مدیریت پیچیدگی سیستم • کاهش وابستگی به تنظیم دستی • بهبود کارایی عملیاتی

بررسی شکاف های تحقیقاتی

مرور نظام‌مند ادبیات نشان می‌دهد که علی‌رغم پیشرفت‌های اخیر در به‌کارگیری یادگیری تقویتی عمیق برای مدیریت فشار در شبکه‌های توزیع آب، هنوز فاصله معناداری میان راهکارهای پیشنهادی و الزامات بهره‌برداری واقعی از این سامانه‌های زیرساختی وجود دارد. این فاصله، ناشی از مجموعه‌ای از شکاف‌های تحقیقاتی ساختاری است که ضرورت توسعه رویکردهای کنترلی پایدارتر، تطبیقی‌تر و قابل‌اعتمادتر را برجسته می‌سازد.

نخستین شکاف اساسی، وابستگی شدید روش‌های کنترلی متداول و حتی برخی رویکردهای یادگیری‌محور به مدل‌های دقیق هیدرولیکی است. روش‌های بهینه‌سازی کلاسیک و کنترل پیش‌بین، عملکرد خود را بر پایه یک مدل از پیش کالیبره‌شده بنا می‌کنند؛ مدلی که در عمل به دلیل تغییرات مستمر در شرایط بهره‌برداری، الگوهای مصرف و فرسودگی زیرساخت، به سرعت اعتبار خود را از دست می‌دهد. اگرچه یادگیری تقویتی عمیق به عنوان یک چارچوب بدون مدل معرفی شده است، اما بسیاری از مطالعات اولیه در این حوزه همچنان به ساختارهایی متکی هستند که به طور غیرمستقیم از فروض مدل‌محور تأثیر می‌پذیرند یا نسبت به خطاهای مدل حساس باقی می‌مانند. این مسئله نشان می‌دهد که نیاز به الگوریتمی با پایداری ذاتی در فرآیند یادگیری و مقاومت در برابر نوسانات محیطی همچنان برطرف نشده است.

دومین شکاف مهم، ناپایداری فرآیند آموزش در بسیاری از الگوریتم‌های **DRL** مورد استفاده برای کنترل فشار است. شبکه‌های توزیع آب، سامانه‌هایی ایمنی‌محور محسوب می‌شوند که در آن‌ها تغییرات ناگهانی یا افراطی در تنظیمات شیرهای فشارشکن می‌تواند به بروز شرایط بحرانی منجر شود. با این حال، برخی الگوریتم‌های رایج مانند **DDPG** یا روش‌های مبتنی بر ارزش، به نوسانات شدید در سیاست کنترلی، حساسیت به تنظیم ابرپارامترها و واگرایی در فرآیند یادگیری دچار هستند. این ناپایداری‌ها مانعی جدی برای اعتمادپذیری و قابلیت استقرار این روش‌ها در کاربردهای واقعی ایجاد می‌کند.

در این زمینه، الگوریتم **(Proximal Policy Optimization (PPO** به طور مستقیم این شکاف را هدف قرار می‌دهد. سازوکار به‌روزرسانی سیاست در **PPO**، که بر پایه تابع هدف جانشین بریده‌شده (**Clipped Surrogate Objective**) بنا شده است، به صورت صریح از اعمال تغییرات بزرگ و ناگهانی در سیاست جلوگیری می‌کند. این ویژگی موجب می‌شود فرآیند یادگیری به صورت تدریجی، پایدار و قابل کنترل انجام شود؛ خصوصیتی که برای کنترل بلادرنگ شیرهای فشارشکن در شبکه‌های واقعی حیاتی است.

سومین شکاف کلیدی، عدم کارایی بسیاری از الگوریتم‌های موجود در مواجهه با فضای عمل پیوسته و چندبعدی است. مدیریت هم‌زمان چندین **PRV** ذاتاً یک مسئله با فضای عمل پیوسته و وابستگی‌های متقابل میان

عملگرهاست. روش‌های مبتنی بر فضای عمل گسسته، نظیر **DQN**، برای چنین مسئله‌ای نیازمند ساده‌سازی‌های شدید هستند که منجر به کاهش دقت کنترلی و افزایش بار محاسباتی می‌شود. در مقابل، **PPO** به‌عنوان یک الگوریتم گرادیان سیاست، به‌طور ذاتی برای فضاهای عمل پیوسته طراحی شده و امکان یادگیری مستقیم سیاست‌های کنترلی نرم، هموار و چندمتغیره را فراهم می‌کند. این قابلیت، **PPO** را به گزینه‌ای مناسب برای مدیریت فشار در شبکه‌های بزرگ‌مقیاس با تعداد زیاد **PRV** تبدیل می‌سازد.

شکاف چهارم، چالش شکاف شبیه‌سازی-واقعیت و حساسیت سیاست‌های یادگرفته‌شده به عدم قطعیت‌های محیطی است. بیشتر مطالعات موجود، سیاست‌های کنترلی را در محیط‌های شبیه‌سازی‌شده ایده‌آل آموزش داده‌اند و ارزیابی محدودی از پایداری این سیاست‌ها در شرایط غیرقطعی ارائه کرده‌اند. از آنجا که **PPO** یک الگوریتم **on-policy** است، فرآیند یادگیری آن به‌طور مداوم بر اساس داده‌های جدید تولیدشده توسط سیاست فعلی انجام می‌شود. این ویژگی امکان انطباق تدریجی سیاست با تغییرات محیط و کاهش حساسیت به ناهنجاری‌های گذرا را فراهم می‌کند و می‌تواند گامی مؤثر در جهت کاهش شکاف میان شبیه‌سازی و واقعیت تلقی شود.

در نهایت، نیاز به یک چارچوب یکپارچه و قابل‌اتکا برای تعامل بلادرنگ میان عامل یادگیری و شبیه‌ساز هیدرولیکی به‌عنوان یکی دیگر از شکاف‌های اصلی شناسایی می‌شود. یکپارچه‌سازی **PPO** با شبیه‌ساز **EPANET** در قالب یک حلقه بسته یادگیری-کنترل، این امکان را فراهم می‌سازد که عامل **DRL** در یک محیط استاندارد صنعتی، رفتار کنترلی خود را به‌صورت تدریجی بهبود دهد. چنین چارچوبی نه‌تنها از نظر پژوهشی نوآورانه است، بلکه از منظر کاربردی نیز مسیر انتقال فناوری به صنعت آب را هموار می‌کند.

در جمع‌بندی، می‌توان گفت که الگوریتم **PPO** (**Proximal Policy Optimization**) پاسخی مستقیم و هدفمند به شکاف‌های شناسایی‌شده در ادبیات مدیریت فشار شبکه‌های توزیع آب است. پایداری آموزش، سازگاری با فضای عمل پیوسته، مقاومت در برابر نوسانات محیطی و قابلیت یکپارچه‌سازی مؤثر با **EPANET**، همگی **PPO** را به گزینه‌ای منطقی و موجه برای توسعه یک سامانه کنترلی هوشمند، تطبیقی و قابل‌استقرار در دنیای واقعی تبدیل می‌کنند.

منابع

- اعرابی، پیمان؛ پیرزاده، بهاره؛ جعفری‌اصیل، جعفر (۱۴۰۰). «توسازی و ارتقای سیستم‌های توزیع آب شهری با رویکرد بهینه‌سازی چندهدفه (مطالعه موردی: بخشی از شبکه توزیع آب شهر زاهدان)». نشریه آب و فاضلاب، دوره ۳۲، شماره ۶.
- سرکرده، حامد؛ خداشناس، سعیدرضا (۱۳۸۷). «مدیریت و کنترل نشت در شبکه‌های آبرسانی شهری (یک دیدگاه استراتژیک)». چهاردهمین کنفرانس دانشجویان مهندسی عمران سراسر کشور.
- یوسفی‌خوش‌قلب، احسان؛ مصلحی، ایمان؛ جلیلی‌قاضی‌زاده، محمدرضا؛ غمخوارهانی (۱۴۰۰). «مروری بر روش‌های تحلیل اقتصادی نشت در شبکه‌های توزیع آب». نشریه تحقیقات منابع آب ایران، دوره ۱۷، شماره ۱.
- سلگی، محمد، بزرگ‌حداد، امید، قاسمی‌ابیازنی، پریسا (۱۳۹۶). بهره‌برداری بهینه از شبکه‌های توزیع آب شهری تحت شرایط کمبود به روش تامین نوبتی. مجله آب و فاضلاب، ۲۸ (۱۰۹).
- مرکز پژوهش‌های مجلس (۱۳۹۸) بررسی آخرین وضعیت آب شرب در کشور از جنبه‌های مختلف، معاونت پژوهش‌های زیربنایی و امور تولیدی، دفتر مطالعات زیربنایی.
- تابش، مسعود، جعفری، هادی، دلاور، محمود رضا (۱۳۸۸) مدل مدیریت حوادث شبکه‌های توزیع آب با استفاده از سیستم‌های اطلاعات جغرافیایی (GIS)، نشریه آب و فاضلاب، دوره ۲۰، شماره ۲.
- جمشیدی، شروین (۱۳۹۳) کاهش تلفات شبکه توزیع آب شهری با استفاده از مدیریت فشار، اولین کنفرانس ملی مهندسی محیط زیست.
- اسدیانی‌یکتا، امیرحسین و تابش، مسعود (۱۳۸۹). «یک مدل تلفیقی جامع برای محاسبه و مدیریت نشت در شبکه‌های توزیع آب شهری». نشریه مهندسی عمران و نقشه‌برداری (دانشکده فنی)، دوره ۴۴، شماره ۱.
- سرکرده، حامد؛ خداشناس، سعیدرضا (۱۳۸۷). «مدیریت و کنترل نشت در شبکه‌های آبرسانی شهری (یک دیدگاه استراتژیک)». چهاردهمین کنفرانس دانشجویان مهندسی عمران سراسر کشور.
- عادلی، محمد؛ کمره‌ای، بهرام؛ جلیل‌زاده، رضا؛ رستمی، زینب (۱۳۹۵). «بررسی میزان حوادث و تلفات آب در شبکه توزیع آب شرب شهر ازنا و عوامل مؤثر بر آن در سال‌های ۱۳۸۷ تا ۱۳۹۳». مجله تحقیقات سلامت در جامعه، ۲ (۳): ۶۹-۷۷.

رائی فقیهی، نیوشا؛ تابش، مسعود؛ روزبھانی، عباس؛ روغنی، بردیا؛ حیدرزاده، رضا؛ صالحی، ستار (۱۳۹۹). «بررسی عوامل مؤثر بر پیدایش و افزایش آب بدون درآمد با استفاده از شبکه‌های بیزین (مطالعه موردی: شرکت آب و فاضلاب منطقه ۴ تهران)». مجله مهندسی منابع آب، سال سیزدهم، شماره ۱.

حقیقی، محمد؛ شانه‌ساز، محمدجواد؛ امیری، بهنام (۱۳۸۳). «بررسی علل مدیریتی بالا بودن پرت آب در شبکه‌های آبیاری شهرستان کرج». مؤسسه تحقیقات و آموزش مدیریت.

منزوی، محمدتقی (۱۳۸۸). «تأمین آب شهری». ویرایش هفدهم، تهران: انتشارات دانشگاه تهران.

مرکز پژوهش‌های مجلس شورای اسلامی. (۱۳۹۷). بررسی آخرین وضعیت آب شرب در کشور از جنبه‌های مختلف (گزارش شماره ۱۶۲۳۱). دفتر مطالعات زیربنایی.

سلطانی اصل، م. و فغفور مغربی، م. (۱۳۸۸). مدیریت هوشمند فشار به منظور کاهش نشت در شبکه‌های آبرسانی، مطالعه موردی: منطقه سرافرازان مشهد. آب و فاضلاب، ۲۰(۳) (مسلسل ۷۱).

تابش، م. و واسطی، م. (۱۳۸۵). کاهش میزان نشت در شبکه‌های توزیع آب شهری از طریق حداقل نمودن فشار اضافی در شبکه. تحقیقات منابع آب ایران. ۲(۲) (مسلسل ۵).

فرشیدخواه، ط.، قائینی حصاروئی، م. & فدائی کرمانی، ا. (۱۳۹۸). امکان‌سنجی و بررسی نقش شیرهای فشار شکن بر کاهش تلفات آب در شبکه توزیع آب. در یازدهمین کنگره ملی مهندسی عمران.

اسدی، ا. (۱۳۹۸). مدیریت فشار در شبکه‌های توزیع آب با برنامه زمان‌بندی کنترل شیرآلات جهت کاهش میزان نشت (پایان‌نامه کارشناسی ارشد). دانشگاه شهید مدنی آذربایجان، دانشکده فنی و مهندسی.

Abdy Sayyed, M. A. H., Gupta, R., & Tanyimboh, T. T. (۲۰۱۵). Noniterative application of EPANET for pressure dependent modelling of water distribution systems. **Water Resources Management**, ۲۹(۹), ۳۲۲۷–۳۲۴۲. <https://doi.org/10.1007/s11269-015-0992-0>.

Al Qahtani, T., Yaakob, M. S., Yidris, N., Sulaiman, S., & Ahmad, K. A. (۲۰۲۰). A review on water leakage detection method in the water distribution network. **Journal of Advanced Research in Fluid Mechanics and Thermal Sciences**, ۶۸(۲), ۱۵۲–۱۶۳.

Berardi, L., Laucelli, D., Simone, A., Perrone, G., & Giustolisi, O. (۲۰۱۹). Integrated pressure control strategies for sustainable management of water distribution networks. **E3S Web of Conferences**, ۱۵, Article ۰۶۰۰۵.

<https://doi.org/10.1051/e3sconf/20191506005>

Bucci, M. A., Semeraro, O., Allauzen, A., Wisniewski, G., Cordier, L., & Mathelin, L. (۲۰۱۹). Control of chaotic systems by deep reinforcement learning. **Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences**, ۴۷۵(۲۲۳۱), Article ۲۰۱۹۰۳۵۱. <https://doi.org/10.1098/rspa.2019.0351>

Farah, E., & Shahrour, I. (۲۰۲۴). Water leak detection: A comprehensive review of methods, challenges, and future directions. **Water**, ۱۶(۲۰), Article ۲۹۷۵. <https://doi.org/10.3390/w16202975>

Guo, S., Zhang, T.-Q., Shao, W.-Y., Zhu, D. Z., & Duan, Y.-Y. (۲۰۱۳). Two-dimensional pipe leakage through a line crack in water distribution systems. **Journal of Zhejiang University-SCIENCE A**, ۱۶(۵), ۳۷۱–۳۷۶. <https://doi.org/10.1631/jzus.A1200227>

Hajgató, G., Paál, G., & Gyires-Tóth, B. (۲۰۲۰). Deep reinforcement learning for real-time optimization of pumps in water distribution systems. **Journal of Water Resources Planning and Management**, ۱۴۶(۱۱), Article ۰۴۰۲۰۰۷۹. [https://doi.org/10.1061/\(ASCE\)WR.1943-5452.0001287](https://doi.org/10.1061/(ASCE)WR.1943-5452.0001287)

Hu, J., Cai, H., Zeng, D., Yan, H., Gong, J., & Wang, H. (۲۰۲۰). Deep reinforcement learning-based valve scheduling for pollution isolation in water distribution network. **Mathematical Biosciences and Engineering**, ۱۷(۱), ۷۶۸–۷۸۶. <https://doi.org/10.3934/mbe.2020006>

Islam, M. R., Azam, S., Shanmugam, B., & Mathur, D. (۲۰۲۲). A review on current technologies and future direction of water leakage detection in water distribution network. **IEEE Access**, ۱۰, ۱۰۷۱۷۷–۱۰۷۲۰۱. <https://doi.org/10.1109/ACCESS.2022.3212769>

Javed, A., Wu, W., Sun, Q., & Dai, Z. (۲۰۲۵). Leak management in water distribution networks through deep reinforcement learning: A review. **Water**, ۱۷(۱۳), Article ۱۹۲۸. <https://doi.org/۱۰.۳۳۹۰/w۱۷۱۳۱۹۲۸>

Joseph, K., Sharma, A. K., & van Staden, R. (۲۰۲۲). Development of an intelligent urban water network system. **Water**, ۱۴(۹), Article ۱۳۲۰. <https://doi.org/۱۰.۳۳۹۰/w۱۴۰۹۱۳۲۰>

Liemberger, R., & Wyatt, A. (۲۰۱۹). Quantifying the global non-revenue water problem. **Water Supply**, ۱۹(۳), ۸۳۱–۸۳۷. <https://doi.org/۱۰.۲۱۶۶/ws.۲۰۱۸.۱۲۹>

Mosetlhe, T. C., Hamam, Y., Du, S., & Monacelli, E. (۲۰۲۰). A survey of pressure control approaches in water supply systems. **Water**, ۱۲(۶), Article ۱۷۳۲. <https://doi.org/۱۰.۳۳۹۰/w۱۲۰۶۱۷۳۲>

Negm, A., Ma, X., & Aggidis, G. (۲۰۲۳). Review of leakage detection in water distribution networks. **IOP Conference Series: Earth and Environmental Science**, ۱۱۳۶, Article ۰۱۲۰۵۲. <https://doi.org/۱۰.۱۰۸۸/۱۷۵۵-۱۳۱۵/۱۱۳۶/۱۰۱۲۰۵۲>

Negm, A., Ma, X., & Aggidis, G. (۲۰۲۴). Deep reinforcement learning challenges and opportunities for urban water systems. **Water Research**, ۲۵۳, Article ۱۲۱۱۴۵. <https://doi.org/۱۰.۱۰۱۶/j.watres.۲۰۲۴.۱۲۱۱۴۵>

Ociepa, E., Mrowiec, M., & Deska, I. (۲۰۱۹). Analysis of water losses and assessment of initiatives aimed at their reduction in selected water supply systems. **Water**, ۱۱(۵), Article ۱۰۳۷. <https://doi.org/۱۰.۳۳۹۰/w۱۱۰۵۱۰۳۷>

Ravichandiran, S. (۲۰۲۰). *Deep reinforcement learning with Python* (۲nd ed.). Packt Publishing.

Rossman, L. A. (۲۰۰۰). *EPANET ۲ users manual* (EPA/۶۰۰/R-۰۰/۰۵۷). U.S. Environmental Protection Agency.

Statescu, F., Boboc, V., Tatu, G., Sârbu, G., Marcoie, N., & Toma, D. (۲۰۲۴). Improving pressure monitoring and control in order to reduce water loss in water urban public systems. **IOP Conference Series: Materials Science and Engineering**, ۱۳۰۴(۱), Article ۰۱۲۰۳۱. <https://doi.org/10.1088/1757-899X/1304/1/012031>

Vicente, D. J., Garrote, L., Sánchez, R., & Santillán, D. (۲۰۱۶). Pressure management in water distribution systems: Current status, proposals, and future trends. **Journal of Water Resources Planning and Management**, ۱۴۲(۲), Article ۰۴۰۱۵۰۶۱. [https://doi.org/10.1061/\(ASCE\)WR.1943-5452.0000589](https://doi.org/10.1061/(ASCE)WR.1943-5452.0000589)

Walski, T. M., Chase, D. V., Savic, D. A., Grayman, W., Beckwith, S., & Koelle, E. (۲۰۰۳). *Advanced water distribution modeling and management*. Haestad Press.

Yussof, N. A. M., & Ho, H. W. (۲۰۲۲). Review of water leak detection methods in smart building applications. **Buildings**, ۱۲(۱۰), Article ۱۵۳۵. <https://doi.org/10.3390/buildings12101535>